

Automatic ISUP Grade Classification in Prostate Histopathological Images Using EfficientNet and Ordinal Focal Loss

Woshington Rodrigues ^{1*}, Armando Luz ², José Araújo ³, João Diniz ⁴ and Antonio Filho ⁵

¹ Universidade Federal do Piauí (UFPI); woshingtonvaldeci@gmail.com

² Universidade Federal do Piauí (UFPI); armandoluzborges@ufpi.edu.br

³ Universidade Federal do Piauí (UFPI); jose.denes@ufpi.edu.br

⁴ Instituto Federal do Maranhão (IFMA); joao.bandeira@ifma.edu.br

⁵ Universidade Federal do Piauí (UFPI); antoniooseas@ufpi.edu.br

* Correspondence: woshingtonvaldeci@gmail.com;

Abstract

The automatic classification of ISUP grade groups in prostate histopathological images is a challenging problem due to high similarity between adjacent classes, dataset imbalance, and label noise. This work proposes a pipeline based on EfficientNet convolutional neural networks combined with a hybrid loss function that integrates ordinal regression and Focal Loss. Initially, a noise-filtering strategy based on the entropy of predictions from multiple EfficientNet models was applied, thereby identifying samples with high uncertainty in the training set. Subsequently, the problem was modeled as an ordinal regression task to capture the hierarchical relationship among ISUP grades. The experiments were conducted using the PANDA dataset. The results demonstrate that removing noisy samples improved the baseline model's performance from $\kappa = 0.826$ to $\kappa = 0.833$. Using an ordinal loss further improved performance, yielding $\kappa = 0.851$. The best configuration, combining ordinal loss and focal Loss, achieved $\kappa = 0.857$ and an accuracy of 0.669, while also reducing errors between distant classes and concentrating confusions among adjacent grades.

Keywords: Prostate cancer; Histopathological image classification; EfficientNet; Ordinal regression; Focal loss; Digital pathology; PANDA dataset

Received:

Revised:

Accepted:

Published:

Citation: Rodrigues, W.; Luz, A.; Araújo, J.; Diniz, J.; Filho, A. Automatic ISUP Grade Classification in Prostate Histopathological Images Using EfficientNet and Ordinal Focal Loss. *Journal Not Specified* **2025**, *1*, 0. <https://doi.org/>

Copyright: © 2026 by the authors. Submitted to *Journal Not Specified* for possible open access publication under the terms and conditions of the Creative Commons Attribution (CC BY) license (<https://creativecommons.org/licenses/by/4.0/>).

1. Introduction

O câncer de próstata é uma das neoplasias malignas mais comuns em homens, representando um importante desafio de saúde pública [1]. Estatísticas reportadas pela Agência Internacional para Pesquisa em Câncer indicam que, em 2022, essa neoplasia foi a quarta mais comum no mundo, correspondendo a 7,3% de todos os casos de câncer [2]. Nesse contexto, a classificação tumoral desempenha um papel central na definição do manejo clínico e no prognóstico. O sistema de Gleason, baseado na soma dos dois padrões histológicos predominantes, evoluiu para o sistema de classificação proposto pela Sociedade Internacional de Patologia Urológica (ISUP), organizado em cinco grupos variando de 1 a 5. Esse sistema fornece uma melhor estratificação prognóstica e é amplamente adotado na prática clínica [3].

A avaliação histopatológica tradicional de imagens de lâmina inteira (Whole-Slide Images - WSIs) baseia-se na análise manual realizada por patologistas. Devido ao grande número de campos que devem ser examinados em uma única lâmina, o processo de

avaliação torna-se uma tarefa repetitiva que exige longas jornadas de trabalho, atenção sustentada e conhecimento especializado. A fadiga decorrente da análise prolongada pode introduzir variabilidade inter e intraobservador nos resultados, influenciando diretamente o manejo clínico dos pacientes [4]. Consequentemente, nos últimos anos, tem havido um crescimento significativo no uso de técnicas de Inteligência Artificial (IA) para automatizar a análise de exames histopatológicos e auxiliar no diagnóstico do câncer de próstata, com o objetivo de mitigar essas limitações [5].

Nesse cenário, as Redes Neurais Convolucionais (CNNs) têm representado o estado da arte na análise de imagens médicas [6], sendo capazes de extrair características relevantes e combinar padrões visuais complexos para identificar condições patológicas específicas [7]. Essa capacidade torna a abordagem promissora para a análise automatizada de padrões de Gleason e grupos de grau ISUP, reduzindo a variabilidade inerente à avaliação convencional. Com base nessa premissa, técnicas de *deep learning* para classificação do câncer de próstata têm sido amplamente investigadas na literatura, com avanços relevantes em WSIs, estratégias de extração de patches e mecanismos de agregação multi-escala. Por exemplo, no contexto de aprendizado fracamente supervisionado, [16] propuseram o framework GCN-MIL, que utiliza uma Graph Neural Network para agregar características espaciais de patches em lâminas WSI. O modelo incorpora uma estratégia de treinamento robusto que filtra iterativamente amostras com alta incerteza para mitigar o impacto de rótulos ruidosos, alcançando um coeficiente kappa quadrático de 0.931 no conjunto interno do desafio PANDA. No entanto, a abordagem utiliza a função de perda tradicional *Cross-Entropy*, que trata os graus ISUP como classes nominais independentes e ignora a hierarquia biológica da progressão do câncer.

Em uma validação clínica independente com 593 imagens do *Seoul National University Hospital*, [22] avaliaram o sistema DeepDx Prostate, alcançando um kappa quadrático de 0.922 na classificação de Gleason. Contudo, a generalização do modelo foi limitada pela homogeneidade do conjunto de dados institucional e por uma tendência de superestimar casos do Grupo de Grau 1 (GG1). Buscando a predição indireta de risco, [23] investigaram o uso de *deep learning* para identificar pacientes com risco de câncer a partir de lâminas previamente classificadas como benignas. O método alcançou uma AUC de 0.739 para predição de risco, revelando padrões morfológicos sutis, mas foi limitado pela dependência de um único domínio institucional.

Para lidar com a variabilidade de escala das estruturas glandulares, [24] propuseram uma arquitetura *Pyramidal CNN* composta por três redes rasas operando em diferentes tamanhos de patch. Embora o método tenha alcançado aproximadamente 0.77 de acurácia na classificação de padrões, foi limitado por rotulação semi-automática e desempenho moderado em classes mais complexas. Em paralelo, visando melhorar a interpretabilidade, [21] avaliaram arquiteturas combinadas com técnicas de *Explainable AI* (*Grad-CAM*) utilizando o conjunto SICAPv2. O modelo VGG19 alcançou o melhor desempenho (AUC-ROC de 0.85), embora o estudo não tenha incluído validação clínica externa. Seguindo uma estratégia de simplificação, [17] formularam o problema como uma tarefa de classificação binária (tecidos benignos vs. malignos). Utilizando *fine-tuning* em modelos InceptionResNetV2 com a função de perda *binary cross-entropy*, alcançaram 91,8% de acurácia, enfatizando a detecção em detrimento da classificação multiclasse de Gleason.

Em arquiteturas mais avançadas, a incorporação de mecanismos de atenção também tem ganhado destaque. [20] propuseram um modelo baseado na EfficientNet-B4 com mecanismo de atenção por canal (Eff4-Attn), alcançando 93,32% de acurácia em uma tarefa de classificação com oito classes utilizando imagens do *DiagSet*. No entanto, o estudo baseia-se exclusivamente em patches isolados e sofre com desbalanceamento de classes. Complementarmente, [25] investigaram o uso de *Vision Transformers* (ViT) em um

subconjunto do conjunto PANDA, alcançando acurácia superior a 85% na classificação de patches, destacando a capacidade dos mecanismos de atenção em capturar dependências contextuais globais.

Apesar dos avanços recentes, diversas lacunas metodológicas ainda permanecem. Muitos estudos tratam o problema como uma tarefa de classificação nominal e utilizam funções de perda tradicionais, desconsiderando a natureza ordinal dos graus ISUP. Como consequência, erros de predição são penalizados de forma uniforme, sem considerar a magnitude da discrepância entre classes, o que não reflete adequadamente sua relevância clínica. Além disso, muitas abordagens não incorporam mecanismos robustos de filtragem de ruído ou modelagem de incerteza, aspectos importantes devido à presença de artefatos e inconsistências em conjuntos de dados públicos.

Para abordar essas limitações, este trabalho propõe um pipeline para a classificação automática dos grupos de grau ISUP em imagens histopatológicas. As principais contribuições são: (i) uma função de perda híbrida que combina penalização ordinal e *focal loss*, considerando a natureza hierárquica do problema e o desbalanceamento de classes; (ii) uma estratégia de remoção de ruído baseada na incerteza estimada a partir da média das predições de modelos EfficientNet (B0, B1, B2 e B3); e (iii) uma avaliação comparativa das arquiteturas EfficientNet B0, B3 e B7, visando obter um modelo de inferência mais robusto e consistente.

2. Materials and Methods

Esta seção apresenta os procedimentos metodológicos utilizados para desenvolver e avaliar a abordagem proposta. O método, ilustrado na Figura 1, foi estruturado em quatro etapas principais: (i) materiais, (ii) pré-processamento, (iii) extração de características e treinamento do modelo, e (iv) avaliação de desempenho. Cada etapa é descrita em detalhes nas subseções a seguir.




Figure 1. Método proposto

2.1. Materiais

Neste estudo, foi utilizado o conjunto de dados PANDA (*Prostate Cancer Grade Assessment*), que consiste em aproximadamente 10.616 imagens histopatológicas de lâminas inteiras (WSIs) de biópsias de próstata [8]. Esse conjunto foi disponibilizado como parte do desafio PANDA na plataforma Kaggle e tem sido amplamente utilizado em pesquisas sobre classificação automática do câncer de próstata.

As imagens do dataset são anotadas com escores e graus de Gleason, fornecendo rótulos clínicos utilizados para a classificação da doença. Neste estudo, foi utilizada apenas a versão pública do dataset, sem acesso ao conjunto de teste privado disponibilizado durante o desafio.

Os dados foram coletados de dois centros médicos, *Radboud University Medical Center* e *Karolinska Institute*, introduzindo variabilidade institucional nas imagens. Essa variabilidade está associada a diferenças nos protocolos de preparação das lâminas, nos procedimentos de digitalização e nos critérios de anotação, tornando o cenário experimental mais próximo da prática clínica real.

Além disso, o dataset contém ruído inerente ao processo de aquisição e anotação das lâminas. Artefatos visuais incluem marcações de caneta feitas por patologistas durante a análise, conforme ilustrado na Figura 2. Também existem fontes de ruído relacionadas à rotulagem, como discordâncias entre anotadores na atribuição dos graus histopatológicos.

Esses fatores aumentam a complexidade da tarefa de classificação automática e refletem desafios presentes na prática de patologia digital.




Figure 2. Exemplo de artefato visual presente em uma WSI do dataset PANDA. À esquerda, a lâmina completa com a região de interesse destacada em vermelho. À direita, uma visualização ampliada revela uma marca de caneta sobre o tecido prostático.

Outro aspecto relevante do dataset é a distribuição desigual das amostras entre as seis classes de graduação (ISUP 0 a ISUP 5). Esse desbalanceamento é evidenciado na Tabela 3, que apresenta a distribuição de amostras por classe. A maioria dos exemplos está concentrada nas classes ISUP 0 e ISUP 1.




Figure 3. Distribuição de amostras no dataset PANDA

2.2. Pré-processamento

O fluxo de pré-processamento consistiu em duas etapas sequenciais: filtragem de ruído nos rótulos e extração de patches. Inicialmente, o dataset foi dividido em treino (85%) e teste (15%), garantindo independência entre o ajuste do modelo e a avaliação final. Após essa divisão, o conjunto de treino continha 9.024 instâncias, enquanto o conjunto de teste, utilizado para avaliação, possuía 1.592 instâncias.

2.2.1. Filtragem de Ruído Baseada em Entropia

Conforme discutido na Seção 2.1, o dataset PANDA contém ruído de rótulos devido a anotações manuais e laudos inconclusivos. Para mitigar esse impacto, foi adotada uma estratégia baseada em incerteza preditiva.

Foram treinadas quatro variantes EfficientNet (B0, B1, B2 e B3), reservando 20% do conjunto de treino para validação interna. Cada modelo gerou probabilidades para todas as amostras.

A incerteza foi quantificada usando entropia de Shannon:

$$H = \frac{1}{C} \sum_{c=1}^C -[p_c \log(p_c) + (1 - p_c) \log(1 - p_c)] \quad (1)$$

Amostras com maior entropia indicam maior incerteza. Os 10% com maior entropia foram definidos como *hard samples*.

2.2.2. Extração de Patches

Após a filtragem, foi realizada a geração de patches. Como mostrado na Figura 4, grande parte da WSI é fundo branco.




Figure 4. Exemplo de WSI com grande área sem tecido.

Foi utilizado tamanho fixo de 256×256 . Os patches foram ordenados por densidade de tecido e organizados em grades.




Figure 5. Extração de patches: 5×5 , 6×6 e 7×7 .

A configuração 6×6 foi escolhida como melhor compromisso.

2.3. Extração de Características e Treinamento

A EfficientNet-B0 foi usada como modelo base. Posteriormente, B3 e B7 foram avaliadas.

O problema foi reformulado como regressão ordinal.

Para um grau k , o rótulo é codificado como vetor cumulativo: exemplo: classe 3 $\rightarrow [1, 1, 1, 0, 0]$.

A função de perda combina *focal loss*:

$$\mathcal{L}_{focal} = -\frac{1}{K} \sum_{i=1}^K \alpha_i (1 - p_i)^\gamma \log(p_i)$$

com penalização ordinal:

$$\hat{y} = \sum_{i=1}^K \hat{p}_i$$

$$|\hat{y} - y|$$

Função final:

$$\mathcal{L} = \lambda \cdot \mathcal{L}_{focal} + \beta \cdot |\hat{y} - y|$$

2.4. Avaliação de Desempenho

A avaliação foi realizada com Accuracy e κ_{quad} .

Para análise estatística, foi aplicado bootstrap com 1.000 reamostragens, estimando média, desvio padrão e intervalo de confiança de 90%.

3. Results

Esta seção apresenta os resultados experimentais obtidos a partir da aplicação da metodologia descrita na Seção 2. O objetivo é validar as abordagens propostas e analisar o comportamento do modelo sob diferentes condições. Inicialmente, são descritos o ambiente computacional e os hiperparâmetros utilizados no treinamento do modelo base. Em seguida, investiga-se o impacto da etapa de remoção de ruído e das diferentes formulações da função de perda no desempenho preditivo. Por fim, é conduzido um estudo comparativo abrangente entre diferentes arquiteturas EfficientNet, avaliando o trade-off entre custo computacional e efetividade.

3.1. Ambiente Experimental

Os experimentos foram conduzidos em uma estação de trabalho Linux equipada com um processador AMD Ryzen 5 5600X, 32 GB de memória RAM DDR4 (3200 MHz) e uma GPU NVIDIA GeForce RTX 3060 (12 GB de VRAM), dedicada à aceleração do treinamento dos modelos de aprendizado profundo. O desenvolvimento foi realizado em Python utilizando o framework PyTorch integrado ao CUDA 12.8. Para o processamento de imagens histopatológicas, foi utilizada a biblioteca OpenSlide para leitura das imagens e extração de patches. As métricas de avaliação foram calculadas com o scikit-learn e as análises visuais foram geradas com o Matplotlib.

3.2. Configuração de Hiperparâmetros

A etapa inicial da experimentação consistiu em uma busca em grade (*grid search*) para identificar a configuração de hiperparâmetros que maximizasse a convergência e a generalização do modelo base, mitigando o risco de overfitting. Os valores explorados e a configuração final selecionada estão resumidos na Tabela 1. Essa configuração ótima foi definida como padrão e mantida constante nos experimentos subsequentes para garantir a comparabilidade dos resultados.

A taxa de aprendizado inicial definida como 3×10^{-4} , em conjunto com o otimizador Adam, proporcionou a melhor estabilidade durante a minimização da função de perda (BCE). Para o *fine-tuning*, o descongelamento das últimas 150 camadas da rede apresentou o melhor equilíbrio. Além disso, uma camada de *dropout* com probabilidade de retenção de 0.4 mostrou-se a estratégia de regularização mais eficaz. O tamanho do batch foi limitado a duas amostras devido às restrições de memória da GPU. Para mitigar flutuações nas atualizações de gradiente causadas pelo pequeno batch size, o treinamento foi configurado para até 50 épocas, utilizando *early stopping* com paciência de 7 épocas sem melhoria na métrica de validação.

Para mitigar o tamanho limitado do conjunto de dados e melhorar a generalização, foi aplicada *data augmentation* durante o treinamento utilizando a biblioteca Albumenta-

tions. As transformações incluem transposições aleatórias, flips horizontais e verticais, aumentando a variabilidade das amostras e reduzindo o overfitting.

Parâmetro	Valores avaliados	Valor selecionado
Taxa de aprendizado	3×10^{-4} , 3×10^{-3} , 1×10^{-4}	3×10^{-4}
Número de épocas	50	50
Camadas descongeladas	100, 150	150
Dropout	0.4, 0.5, 0.6	0.4
Tamanho do batch	2	2
Função de perda	BCE	BCE
Otimizador	Adam	Adam

Table 1. Hiperparâmetros avaliados e configuração selecionada para os experimentos.

3.3. Impacto da Filtragem de Ruído e das Funções de Perda

Com o conjunto ótimo de hiperparâmetros definido, o modelo base foi treinado utilizando a arquitetura EfficientNet-B0 e a função de perda BCE. Esse modelo alcançou uma acurácia de 0.592 e um coeficiente Kappa de 0.826. No contexto da classificação ISUP, esse valor é considerado altamente satisfatório e competitivo, superando significativamente a variabilidade entre patologistas reportada na literatura.

A etapa de filtragem baseada em entropia identificou 903 amostras (10%) com maior incerteza. A remoção parcial (20%) dessas amostras resultou em melhora de desempenho, como mostrado na Figura 6.




Figure 6. Desempenho sob diferentes níveis de remoção de ruído.




Figure 7. Imagem identificada como ruidosa pelo método.

A substituição da BCE pela função ordinal aumentou o Kappa para 0.851, concentrando erros entre classes adjacentes, comportamento desejável clinicamente.

A função híbrida (Ordinal + Focal) alcançou o melhor desempenho global:

3.4. Comparação entre Arquiteturas EfficientNet

A EfficientNet-B0 apresentou melhor desempenho geral:




Figure 8. Matrizes de confusão (BCE vs ordinal).

Configuração	Kappa	Acurácia	F1	Prec
BCE	0.826	0.592	0.537	0.5
BCE + Ruído	0.833	0.638	0.572	0.5
Ordinal	0.851	0.608	0.559	0.5
Ordinal + Focal	0.857	0.669	0.612	0.6

Table 2. Impacto das estratégias propostas

Arquitetura	Kappa	Acurácia	F1	Precisão
B0	0.857	0.669	0.612	0.628
B3	0.849	0.661	0.555	0.605
B7	0.842	0.654	0.556	0.561

Table 3. Comparação entre arquiteturas

Os resultados mostram que hiperparâmetros não escalam linearmente com a profundidade do modelo, reforçando a necessidade de ajustes específicos por arquitetura.

4. Discussion

A classificação automatizada dos grupos de grau ISUP enfrenta desafios significativos devido à alta similaridade visual entre graus adjacentes, à subjetividade inerente à avaliação humana e ao desbalanceamento natural dos conjuntos de dados clínicos. Os resultados deste estudo demonstram que a combinação de uma função de perda com penalização ordinal e técnicas de filtragem de ruído constitui uma abordagem robusta para superar essas limitações.

4.1. Desempenho e Comparação com Trabalhos Relacionados

Os estudos apresentados na Tabela 4 destacam diferentes trade-offs entre complexidade do modelo, formulação da tarefa e aplicabilidade clínica. Abordagens iniciais, como [24], dependem de pipelines computacionalmente intensivos que processam milhões de




Figure 9. Curvas de loss e kappa




Figure 10. Matrices de confusão normalizadas

patches e múltiplas CNNs, limitando a escalabilidade. De forma semelhante, [25] e [21] operam no nível de patch, simplificando o problema e ignorando o contexto global do tecido, que é essencial para uma classificação confiável de imagens de lâmina inteira (WSI).

Outros trabalhos adotam arquiteturas mais complexas no nível de WSI. Por exemplo, [16] combina modelos convolucionais e baseados em grafos, alcançando um alto Kappa interno (0.931), mas com queda significativa na validação externa (0.801), indicando sensibilidade a mudanças de domínio. De forma semelhante, [28] reporta um Kappa competitivo (0.881) utilizando um ensemble baseado em múltiplas instâncias (MIL); no entanto, esse resultado é obtido sob um esquema de balanceamento artificial aplicado antes da divisão do conjunto de dados, o que altera a distribuição natural dos dados. Como o desbalanceamento de classes é intrínseco à classificação do câncer de próstata, essa estratégia pode levar a uma superestimação do desempenho e a uma menor robustez em cenários reais. Da mesma forma, [27] alcança um Kappa de 0.884 utilizando aprendizado auto-supervisionado, mas depende de subconjuntos curados, o que pode impactar a generalização.

Além disso, [26] incorpora uma etapa de segmentação com DeepLabV3 seguida por um classificador Random Forest, alcançando um alto Kappa (0.921). No entanto, essa abordagem depende de anotações em nível de pixel, limitando sua escalabilidade. Por outro lado, [20] reporta uma acurácia muito elevada (até 0.961), mas aborda uma tarefa simplificada (binária ou com número reduzido de classes), tornando a comparação com a classificação completa ISUP menos significativa.




Figure 11. Curvas de treinamento

Em contraste, o método proposto alcança um Kappa de 0.857 utilizando uma arquitetura relativamente simples e computacionalmente eficiente, a EfficientNet-B0. O método aborda o problema completo de classificação ISUP no nível de WSI, sem depender de anotações em nível de pixel, balanceamento artificial ou simplificação da tarefa. O uso da função de perda Ordinal Focal incentiva erros entre classes adjacentes, melhorando a consistência clínica. Embora o modelo proposto apresente menor acurácia do que algumas abordagens simplificadas, ele fornece uma avaliação mais realista e clinicamente relevante, oferecendo um melhor equilíbrio entre desempenho, robustez e aplicabilidade prática.

Estudo	Dataset	Modelo	Nível	Tarefa	Acc.	Kappa	
[24]	Radboud	Pyramidal CNN	Patch → WSI	Gleason / GG	0.773	-	
[25]	PANDA	ViT	Patch	Gleason	0.800	-	
[16]	PANDA	ResNet50 + GCN	WSI	ISUP (6)	-	0.931 (Int.) / 0.801 (Ext.)	
[20]	DiagSet	EffNet-B4 + ECA	Patch	Binário / 4 classes	0.961 / 0.948		-
[21]	SICAPv2	VGG19	Patch	Gleason	0.780		-
[28]	PANDA	EffNet-B1 + MIL + Ensemble	WSI	ISUP (6)	-	0.881	
[26]	PANDA	EffNet-B0 + DeepLabV3 + RF	WSI + Seg	ISUP (6)	-	0.921	
[27]	PANDA / SICAPv2	TSOR	WSI	ISUP (6)	-	0.884	
Proposto (Base)	PANDA	EffNet-B0 + Ordinal Focal Loss	WSI	ISUP (6)	0.669	0.857	

Table 4. Comparação entre o método proposto e trabalhos recentes.

4.2. Impacto da Função de Perda Ordinal e da Filtragem de Ruído

A transição da função de perda BCE para a formulação híbrida (ordinal + focal) produziu a maior melhoria no desempenho do modelo. Do ponto de vista clínico, distinguir entre ISUP 2 e ISUP 3 possui implicações prognósticas diferentes quando comparado a uma confusão entre ISUP 1 e ISUP 5. A função de perda ordinal incentiva o modelo a respeitar essa relação hierárquica entre as classes. Além disso, a estratégia de filtragem baseada em entropia reforçou a importância da qualidade dos dados de treinamento. A remoção de amostras com alta incerteza reduziu a influência de rótulos potencialmente ruidosos e melhorou o desempenho do modelo, sem a necessidade de expansão do conjunto de dados.

4.3. Eficiência Computacional e Seleção da Arquitetura

Ao comparar arquiteturas da família EfficientNet, o aumento da complexidade do modelo não resultou em melhoria de desempenho; pelo contrário, foi observada uma leve degradação nas variantes mais profundas (como mostrado na Tabela 3). A EfficientNet-B0 apresentou o melhor equilíbrio entre desempenho preditivo e estabilidade estatística. Esses resultados sugerem que arquiteturas mais complexas (como B3 e B7) podem ser mais suscetíveis ao overfitting nesse contexto ou podem exigir ajustes mais refinados para atingir seu potencial máximo. Para aplicações práticas em laboratórios de patologia, a escolha da EfficientNet-B0 é vantajosa devido ao menor custo computacional e menor tempo de inferência.

4.4. Limitações e Trabalhos Futuros

Apesar dos resultados promissores, uma limitação importante deste estudo é a ausência de validação externa em dados provenientes de instituições independentes. Embora o conjunto PANDA inclua amostras de dois centros diferentes, ambos são incorporados no processo de treinamento, o que não reflete completamente cenários reais de implantação com condições de aquisição não vistas. Estudos anteriores demonstraram que modelos treinados no PANDA podem apresentar queda significativa de desempenho em validação externa (por exemplo, uma redução de aproximadamente 0.13 no Kappa de Cohen reportada em [16]). Portanto, a capacidade de generalização do modelo proposto para diferentes ambientes clínicos permanece incerta, e os resultados apresentados devem ser interpretados como desempenho interno.

Trabalhos futuros devem priorizar a avaliação em conjuntos de dados externos para verificar robustez e aplicabilidade clínica. Além disso, arquiteturas baseadas em transformadores e estratégias de ensemble podem ser exploradas para melhorar ainda mais o desempenho e a estabilidade.

5. Conclusion

Neste estudo, foi desenvolvida uma metodologia robusta para a classificação automática dos graus ISUP em imagens histopatológicas de próstata, abordando desafios relevantes, incluindo desbalanceamento de classes, ruído nos rótulos e a natureza ordinal da progressão tumoral. A introdução de uma função de perda híbrida, combinando regressão ordinal e *focal loss*, melhorou o desempenho do modelo ao capturar explicitamente a relação hierárquica entre os graus de malignidade. A combinação dessa estratégia com a filtragem de ruído baseada em entropia mostrou-se altamente eficaz. De forma geral, a abordagem proposta elevou o índice κ_{quad} de 0.826 para 0.857 (aproximadamente 3%) e a acurácia de 0.592 para 0.669 (aproximadamente 7%) em comparação com o modelo base.

Ao alinhar a penalização de erros com a relevância clínica por meio da coerência ordinal e ao enfatizar a qualidade dos dados, o método estabelece uma base sólida para a análise patológica automatizada. O sistema demonstra forte potencial como uma ferramenta computacionalmente viável e clinicamente coerente para apoiar a tomada de decisão diagnóstica no câncer de próstata.

Author Contributions: Conceptualization, W.R.; methodology, W.R. and A.L.; investigation, W.R.; writing-original draft preparation, W.R. and A.L.; writing-review and editing, J.D.; supervision, J.A. and A.F. All authors have read and agreed to the published version of the manuscript.

Funding: This research received no external funding.

Institutional Review Board Statement: Not applicable.

Informed Consent Statement: Not applicable.

Data Availability Statement: Publicly available datasets were analyzed in this study. The data presented in this study are openly available in the PANDA Challenge dataset at <https://www.kaggle.com/c/prostate-cancer-grade-assessment> (accessed on 13 March 2026). All processed results and model configurations used for analysis are available from the corresponding author upon reasonable request.

Acknowledgments: During the preparation of this manuscript, the authors used Gemini for the purposes of English language editing and text formatting. The authors have reviewed and edited the output and take full responsibility for the content of this publication.

Conflicts of Interest: The authors declare no conflict of interest.

Abbreviations

The following abbreviations are used in this manuscript:

ISUP	International Society of Urological Pathology
WSI	Whole Slide Image
CNN	Convolutional Neural Network
GCN	Graph Convolutional Network
AI	Artificial Intelligence
BCE	Binary Cross Entropy
GG	Grade Group
PANDA	Prostate Cancer Grade Assessment
ViT	Vision Transformers

References

1.

R. L. Siegel, A. N. Giaquinto, and A. Jemal, "Cancer statistics, 2024," *CA: A Cancer Journal for Clinicians*, vol. 74, no. 1, pp. 12–49, 2024.

2.

F. Bray *et al.*, "Global cancer statistics 2022: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries," *CA: A Cancer Journal for Clinicians*, vol. 74, no. 3, pp. 229–263, 2024.

3.

J. I. Epstein *et al.*, "The 2014 International Society of Urological Pathology (ISUP) Consensus Conference on Gleason Grading of Prostatic Carcinoma: Definition of Grading Patterns and Proposal for a New Grading System," *The American Journal of Surgical Pathology*, vol. 40, no. 2, pp. 244–252, 2016.

4.

W. Bulten *et al.*, "Automated deep-learning system for Gleason grading of prostate cancer using biopsies: a diagnostic study," *The Lancet Oncology*, vol. 21, no. 2, pp. 233–241, 2020.

5.

O. S. Albahri *et al.*, "Expert System Research for Prostate Cancer: A Literature Review," *Computers in Biology and Medicine*, vol. 145, p. 105487, 2022.

6.

G. Campanella *et al.*, "Clinical-grade computational pathology using weakly supervised deep learning on whole slide images," *Nature Medicine*, vol. 25, no. 9, pp. 1301–1309, 2019.

7.

F. H. Araújo *et al.*, "Active contours for overlapping cervical cell segmentation," *International Journal of Biomedical Engineering and Technology*, vol. 35, no. 1, pp. 70–92, 2021.

8.

PANDA Challenge, "Prostate cANcer graDe Assessment Challenge," Kaggle, 2020.

9.

I. Ali, A. Khan, M. Khan, R. Ahmad, and I. Ullah, "Shannon Entropy in Artificial Intelligence and Its Applications Based on Information Theory," *Entropy*, vol. 25, no. 2, p. 364, 2023.

10.

T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal loss for dense object detection," in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 2980–2988.

11.

A. S. Dina, A. B. Siddique, and D. Manivannan, "A deep learning approach for intrusion detection in Internet of Things using focal loss function," *Internet of Things*, vol. 22, p. 100699, 2023.

12.

X. Chen, "A transfer learning-based deep focal multiclass network for psychological emotion recognition in community-correction populations," *Alexandria Engineering Journal*, vol. 135, pp. 235–242, 2026.

13.

P. Baldi *et al.*, "Assessing the accuracy of prediction algorithms for classification: an overview," *Bioinformatics*, vol. 16, no. 5, pp. 412–424, 2000.

14.

J. Cohen, "Weighted kappa: Nominal scale agreement with provision for scaled disagreement or partial credit," *Psychological Bulletin*, vol. 70, no. 4, pp. 213–220, 1968.

15.

B. Efron, "Bootstrap Methods: Another Look at the Jackknife," *The Annals of Statistics*, vol. 7, no. 1, pp. 1–26, 1979.

16. J. Xiang *et al.*, “Automatic diagnosis and grading of Prostate Cancer with weakly supervised learning on whole slide images,” *Computers in Biology and Medicine*, vol. 152, p. 106340, 2023. 357
17. A. Afifi, M. Alrahmawy, and A. El-Baz, “Prostate Cancer Detection Using Deep Learning Models on Histopathological Image Slides: An Experimental Analysis,” *International Journal of Advanced Computer Science and Applications*, vol. 15, no. 1, 2024. 358
18. Ozkan, T. A., Eruyar, A. T., Cebeci, O. O., Memik, O., Ozcan, L., & Kuskonmaz, I. [cite: 5] (2016) [cite: 6]. Interobserver variability in Gleason histological grading of prostate cancer[cite: 4]. *Scandinavian Journal of Urology*, 50(6), 420–424[cite: 6]. 359
19. Cinar, I., & Cinar, E. (2025). Assessment of interobserver variability in Gleason grading for prostate carcinoma. *North Clinics of Istanbul*, 12(3), 337–343. 360
20. Alici-Karaca, D. and Akay, B. (2024). An efficient deep learning model for prostate cancer diagnosis. *IEEE Access*, 12:150776–150790. 361
21. Kosoko, I., Garg, A., Jain, S., and Hewage, P. (2024). Leveraging deep learning and explainable ai for diagnosis of prostate cancer. In *Proceedings of the International Conference on Applied Artificial Intelligence in Medical Imaging*, Bolton, United Kingdom. 362
22. Jung, M., Jin, M.-S., Kim, C., Lee, C., Nikas, I. P., Park, J. H., and Ryu, H. S. Artificial intelligence system shows performance at the level of uropathologists for the detection and grading of prostate cancer in core needle biopsy: an independent external validation study. *Modern Pathology*, v. 35, n. 10, p. 1449–1457, 2022. DOI: <https://doi.org/10.1038/s41379-022-01077-9>. 363
23. Liu, B., Wang, Y., Weitz, P., Grönberg, H., Eklund, M., and Rantalainen, M. Using deep learning to detect patients at risk for prostate cancer despite benign biopsies. *iScience*, v. 25, p. 104663, 2022. DOI: <https://doi.org/10.1016/j.isci.2022.104663>. 364
24. Arvaniti, E., Fricker, K. S., Moret, M., Rupp, N., Hermanns, T., Fankhauser, C., Wey, N., Wild, P. J., Rüschhoff, J., and Claassen, M. A pyramidal CNN-based Gleason grading system using digitized prostate biopsy specimens. *IEEE Transactions on Medical Imaging*, v. 37, n. 3, 2018. 365
25. Ikromjanov, K., Sumon, R. I., Bhattacharjee, S., Kim, H.-C., Hwang, Y.-B., and Choi, H.-K. Whole slide image analysis and detection of prostate cancer using vision transformers. In: *Proceedings of the International Conference on Medical Imaging and AI*, 2021. 366
26. Kabir, S., Sarmun, R., Al Saady, R. M., Vranic, S., Murugappan, M., Chowdhury, M. E. H. Automating Prostate Cancer Grading: A Novel Deep Learning Framework for Automatic Prostate Cancer Grade Assessment using Classification and Segmentation. *Journal of Imaging Informatics in Medicine*, 38:3992–4014, 2025. doi:10.1007/s10278-025-01429-2. 367
27. Bhattacharyya, R., Pal, S., Mitra, S. Efficient Self-Supervised Grading of Prostate Cancer Pathology. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 2026. doi:10.1109/TSMC.2026.3662748. 368
28. Bhattacharyya, R., Roy, P., Banerji, S., Mitra, S. Efficient Grading of Prostate Cancer WSI with Deep Learning. In *Medical Imaging 2024: Digital and Computational Pathology*, SPIE, 2024. doi:10.1117/12.3006835. 369

Disclaimer/Publisher’s Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content. 370