

¹ Affiliation 1; e-mail@e-mail.com

² Affiliation 2; e-mail@e-mail.com

* Correspondence: e-mail@e-mail.com; Tel.: (optional; include country code; if there are multiple corresponding authors, add author initials) +xx-xxxx-xxx-xxxx (F.L.)

Abstract

A single paragraph of about 200 words maximum. For research articles, abstracts should give a pertinent overview of the work. We strongly encourage authors to use the following style of structured abstracts, but without headings: (1) Background: place the question addressed in a broad context and highlight the purpose of the study; (2) Methods: describe briefly the main methods or treatments applied; (3) Results: summarize the article's main findings; (4) Conclusions: indicate the main conclusions or interpretations. The abstract should be an objective representation of the article, it must not contain results which are not presented and substantiated in the main text and should not exaggerate the main conclusions.

Keywords: keyword 1; keyword 2; keyword 3 (List three to ten pertinent keywords specific to the article; yet reasonably common within the subject discipline.)

1. Introduction

O câncer de próstata é uma das neoplasias malignas mais comuns em homens, representando um desafio relevante para a saúde pública [1]. A graduação tumoral desempenha papel central na definição do manejo clínico e do prognóstico. O sistema de Gleason, baseado na soma dos dois padrões histológicos mais prevalentes (Gleason score), evoluiu para o sistema de graus da ISUP (1–5), que oferece melhor estratificação prognóstica e é amplamente utilizado na prática clínica [2].

A avaliação histopatológica tradicional de lâminas inteiras (WSIs) depende de análise manual por patologistas, um processo sujeito à variabilidade inter e intra-observador [6], demorado e limitado pela disponibilidade de especialistas. Essas restrições motivaram o desenvolvimento de métodos automatizados baseados em aprendizado profundo.

Redes neurais convolucionais (CNNs) têm se destacado na análise de imagens médicas [7], incluindo na graduação automatizada dos padrões de Gleason e dos graus ISUP [6,8]. Entre as arquiteturas modernas, a família EfficientNet [3] apresenta excelente relação entre precisão e custo computacional, graças ao escalonamento composto da rede e ao uso de blocos MBConv com squeeze-and-excitation [5].

Neste trabalho, investigamos a classificação automatizada dos graus ISUP, avaliando variantes do EfficientNet (B0, B3 e B7) no conjunto PANDA [9]. Utilizamos transfer learning, estratégias de fine-tuning, técnicas de treinamento avançadas e métodos de ensemble para aprimorar a robustez do modelo.

As principais contribuições incluem: (1) uma análise sistemática de variantes do EfficientNet para classificação ISUP; (2) a comparação de técnicas de treinamento, incluindo remoção de ruído, SWA [11] e perda focal; (3) o desenvolvimento de ensembles para

Received:

Revised:

Accepted:

Published:

Citation: Lastname, F.; Lastname, F.; Lastname, F. Title. *Journal Not Specified* **2025**, *1*, 0. <https://doi.org/>

Copyright: © 2025 by the authors.

Submitted to *Journal Not Specified* for possible open access publication under the terms and conditions of the Creative Commons Attribution (CC BY) license (<https://creativecommons.org/licenses/by/4.0/>).

melhorar a estabilidade das predições; e (4) a implementação de uma função de perda que combina componentes ordinais e focais. O desempenho é avaliado principalmente pelo kappa quadrático ponderado (QWK) [10], métrica apropriada para tarefas de classificação ordinal, além de acurácia, F1-score, precisão e recall.

2. Related Works

A aplicação de técnicas de aprendizado profundo à classificação automatizada de câncer de próstata tem sido amplamente investigada, com avanços significativos especialmente no uso de WSIs, estratégias baseadas em patches e mecanismos de agregação multi-escala.

Bulten et al. [6] desenvolveram um sistema de deep learning para a graduação Gleason automatizada, utilizando um dataset com 5.759 biópsias provenientes do Radboud University Medical Center, estratificadas em conjuntos de treinamento (4.712), validação (497) e teste (535). O método, baseado em uma arquitetura U-Net estendida com rotulagem semissupervisionada, obteve κ_{quad} de 0,918 no teste interno. A validação do sistema incluiu ainda um estudo de observadores, superando o desempenho de 10 entre 15 patologistas, e a aplicação em um dataset externo independente do Hospital Universitário de Zurique, $\kappa_{quad} > 0,700$.

Nagpal et al. [8] desenvolveram um sistema de deep learning em dois estágios (CNN InceptionV3 e k-NN) para a graduação Gleason, utilizando dados provenientes do TCGA e de dois centros médicos dos EUA. O modelo foi treinado com 112 milhões de patches anotados e extraídos de 1.226 lâminas e validado em uma coorte independente de 331 lâminas de prostatectomia. O sistema alcançou acurácia de 0,70 contra um padrão de referência especializado, superando significativamente a média de 0,61 obtida por um painel de 29 patologistas ($p = 0,002$) e demonstrando superioridade na estratificação de risco clínico.

Abordagens diretamente baseadas em patches evoluíram rapidamente. Kott et al. [15] realizaram um estudo piloto para desenvolver um algoritmo de deep learning focado especificamente em biópsias de próstata, utilizando ResNet-18. O modelo foi treinado e validado com 14.803 patches de imagem extraídos de 85 WSIs de 25 pacientes de uma única instituição. O sistema alcançou 91,5% de acurácia no diagnóstico de malignidade (AUC de 0,83) e 85,4% de acurácia na graduação Gleason multiclasse (Benigno vs. 3 vs. 4 vs. 5).

Lucas et al. [16] propuseram uma abordagem baseada na arquitetura CNN Inception-v3 para a detecção de padrões Gleason e determinação automatizada de Grupos de Grau em biópsias de próstata. Utilizando um dataset de 96 seções de tecido de 38 pacientes, anotadas detalhadamente em nível de pixel, o método gerou mapas de probabilidade para calcular a composição da biópsia. O sistema alcançou acurácia de 92% para detecção de malignidade e 90% para a distinção entre padrões de baixo ($GP \leq 3$) e alto grau ($GP \geq 4$). Na classificação final do Grupo de Grau da lâmina, o modelo alcançou κ_{quad} de 0,70.

Hammouda et al. [19] propuseram um sistema para a classificação de Grupos de Grau utilizando uma CNN piramidal de três escalas e uma estratégia de classificação pixel-wise com votação majoritária. O modelo foi desenvolvido com 608 imagens de WSIs provenientes do Radboud University Medical Center, aplicando-se uma estratégia de balanceamento para mitigar a predominância do padrão stroma. A abordagem, que integra pré-processamento com realce de bordas, alcançou 94% de acurácia na determinação final dos Grupos de Grau e destacou-se pela eficiência computacional, operando com cerca de 1 milhão de parâmetros.

Outros trabalhos ampliaram o foco para WSIs completas. Singhal et al. [18] desenvolveram um sistema de deep learning para graduação em biópsias baseado em U-Net com codificador ResNeXt50, utilizando estratégias de treinamento agnóstico ao domínio e

aprendizado ativo para mitigar variações de coloração. O modelo foi desenvolvido com 6.670 WSIs de três instituições distintas e demonstrou alta capacidade de generalização ao atingir acurácia de 83,1% e κ_{quad} 0,93 em um dataset externo, além de manter AUCs superiores a 0,93 na estratificação de risco clínico entre diferentes centros.

3. Materials and Methods

A metodologia adotada neste estudo consiste em um pipeline estruturado para a classificação automática dos graus ISUP em imagens histopatológicas de próstata, conforme ilustrado na Figura 1. Inicialmente, o conjunto de dados PANDA é adquirido e submetido a etapas de pré-processamento, seguido pela divisão em treino e teste. Em seguida, aplica-se uma filtragem para redução de ruído, com o objetivo de remover imagens potencialmente inconclusivas que poderiam comprometer o processo de aprendizagem dos modelos. Após essa etapa, as lâminas completas são fragmentadas em patches, reduzindo a dimensionalidade espacial e tornando o treinamento computacionalmente mais eficiente. Na fase de modelagem, diferentes classificadores individuais são treinados empregando distintas estratégias de aprendizado. Por fim, utiliza-se uma abordagem de ensemble para combinar as previsões desses modelos, resultando em uma solução mais robusta e estável.




Figure 1

3.1. Dataset Acquisition

Utilizamos o conjunto de dados do Prostate cANcer graDe Assessment (PANDA) [9], composto por 10.616 whole-slide images (WSIs) de biópsias de próstata digitalizadas em alta resolução (20×). Cada imagem foi anotada segundo o sistema de graduação ISUP (0–5), no qual o grau 0 indica ausência de malignidade, enquanto os graus 1 a 5 representam níveis crescentes de agressividade tumoral.

A Tabela 1 apresenta a distribuição das classes do conjunto de dados. Observa-se um desbalanceamento significativo entre os rótulos, com predominância da classe 0 (aproximadamente 27%). Em contraste, as classes associadas a graus clínicos mais avançados (ISUP 4 e 5) representam, cada uma, menos de 12% do total.

As imagens do PANDA são provenientes de dois centros médicos distintos: Radboud University Medical Center e Karolinska Institutet. Segundo os autores [9], as lâminas

do Radboud foram anotadas por estudantes treinados, enquanto as do Karolinska foram rotuladas por patologistas experientes. Essa heterogeneidade introduz variabilidade interinstitucional nas anotações. Além disso, o conjunto público apresenta diferentes formas de ruído, incluindo anotações excessivamente inclusivas e marcas de caneta próximas a regiões tumorais, o que pode afetar a qualidade do treinamento dos modelos.

Table 1. Characteristics of the PANDA dataset used in this study.

	Karolinska	Radboud	Total
ISUP Grade			
0	1,520 (27.9%)	1,372 (26.6%)	2,892 (27.24%)
1	1,404 (25.7%)	1,262 (24.4%)	2,666 (25.11%)
2	690 (12.6%)	653 (12.7%)	1,343 (12.65%)
3	635 (11.6%)	607 (11.8%)	1,242 (11.70%)
4	641 (11.7%)	608 (11.8%)	1,249 (11.77%)
5	566 (10.3%)	658 (12.7%)	1,224 (11.53%)
Total	5,456 (51.3%)	5,160 (48.7%)	10,616 (100%)

3.2. Preprocessing

O pipeline de pré-processamento foi estruturado sequencialmente para garantir a integridade da avaliação e a qualidade das amostras. O processo inicia-se com o particionamento estratificado dos dados, seguido por uma etapa de filtragem baseada em incerteza (entropia) para a remoção de instâncias ruidosas. Por fim, para lidar com a alta dimensionalidade das lâminas e ampliar a variabilidade do conjunto de treino, aplicam-se a extração de patches e técnicas de aumento de dados.

3.2.1. Data Partitioning and Noise Filtering

Inicialmente, aplicou-se uma divisão estratificada do dataset, preservando a distribuição das classes. Um subconjunto de 15% das imagens foi reservado como hold-out set para a avaliação final, enquanto os 85% restantes compuseram o conjunto de desenvolvimento.

Dada a presença de rótulos ruidosos e a complexidade de discriminação de certas amostras (Seção 3.1), implementou-se uma filtragem baseada na Entropia de Shannon. Na Teoria da Informação aplicada à Inteligência Artificial, a entropia quantifica o nível de incerteza e desordem associado às predições [14]. Valores elevados dessa métrica indicam uma distribuição de probabilidade uniforme entre as classes, sinalizando a incapacidade do modelo em caracterizar a instância com segurança. Dessa forma, utilizou-se a entropia como um indicador de dificuldade, permitindo a identificação e remoção sistemática de amostras ruidosas.

A filtragem ocorreu em três passos:

- **Cálculo da entropia:** treinou-se um modelo EfficientNet-B0 pré-treinado no ImageNet e calculou-se a entropia para todas as amostras do conjunto de desenvolvimento.
- **Definição de limiar:** avaliou-se a remoção dos 10%, 5% e 2% das instâncias com maior entropia.
- **Seleção final:** o limiar de 2% apresentou o melhor compromisso entre redução de ruído e preservação de dados.

Após a remoção das amostras ruidosas, o conjunto de desenvolvimento (8.844 instâncias) foi subdividido estratificadamente em 80% para treinamento e 20% para validação. A Tabela 2 apresenta a distribuição final utilizada no estudo.

Table 2. Dataset distribution after noise filtering (2% threshold)

Subset	% of Total	Action	No. of Images
Test	15%	Preserved	1,590
<i>Development Set (Post-Filtering)</i>			
Training	≈68%	Augmentation	7,075
Validation	≈17%	Evaluation	1,769
Total Used	100%	-	10,434

3.2.2. Patch extraction

Considerando o tamanho das WSIs e a presença de áreas não informativas, foi aplicado um pré-processamento para otimizar o uso computacional e preservar regiões relevantes para o diagnóstico. Inicialmente, foram extraídos patches fixos de 256×256 pixels, selecionados com base em critérios empíricos de intensidade média e saturação nos canais RGB, a fim de eliminar regiões de fundo, artefatos e áreas sem coloração diagnóstica. A Figura 2 ilustra a imagem histopatológica original utilizada como base para a extração dos patches e a imagem composta resultante após a extração e o rearranjo dos patches, permitindo uma compreensão visual do processo.




Figure 2. Original histopathological image (a) and composite image after patch extraction and rearrangement (b).

Para cada lâmina, foram extraídos 36 patches, número definido por meio de experimentos preliminares que avaliaram o impacto da quantidade de regiões na representatividade morfológica e na viabilidade computacional. Para estabelecer essa escolha, três configurações foram comparadas: 25, 36 e 49 patches por lâmina, conforme ilustrado na Figura 3.




Figure 3. Representation of patch extraction with different quantities. The image shows three examples: (a) with 25 patches, (b) with 36 patches, and (c) with 49 patches, displayed from left to right.

A extração com 25 patches produziu uma composição compacta, consequentemente gerando menos dados a serem analisados, o que pode reduzir a demanda por recursos computacionais durante o treinamento e a validação do modelo. Entretanto, essa configuração limita a cobertura da lâmina, resultando em perda significativa de padrões morfológicos relevantes para a classificação. Por outro lado, a extração com 49 patches ampliou a área analisada, mas aumentou os custos computacionais e de armazenamento, além de incluir muitas regiões vazias ou redundantes que podem afetar a eficiência do processamento. Adicionalmente, a inclusão de áreas periféricas com baixo conteúdo discriminativo pode comprometer a qualidade da representação ao diluir ou saturar características importantes.

Assim, a configuração intermediária com 36 patches equilibra adequadamente a cobertura da diversidade morfológica e a eficiência computacional, abrangendo a maior parte das informações relevantes sem sobrecarregar a imagem com regiões irrelevantes. Por essa razão, essa configuração foi adotada como padrão neste trabalho. Após a extração, os patches foram reorganizados e concatenados em uma única imagem composta. Diferentemente de abordagens que preservam a distribuição espacial original, neste estudo os patches foram ordenados com base na quantidade de informação morfológica contida em cada um, estimada a partir de medidas de intensidade e saturação nos canais RGB.

3.3. Single Classifiers

Na fase inicial dos experimentos, adotou-se o modelo EfficientNet-B0 como referência para a otimização dos hiperparâmetros. Inicialmente, estabeleceu-se um baseline utilizando a função de perda Binary Cross-Entropy (BCE). Esta escolha baseou-se na natureza do problema, considerando que, embora uma lâmina possa apresentar múltiplos graus de lesão, a graduação final da biópsia é determinada pelo padrão de Gleason primário (mais frequente) e secundário, conforme estabelecido pelo sistema ISUP [2].

Durante o treinamento deste baseline, foram avaliadas diversas estratégias, incluindo Stochastic Weight Averaging (SWA), Test Time Augmentation (TTA), além de variações na taxa de aprendizado, número de épocas, otimizadores e espaços de cores. Em todos os experimentos, o modelo apresentou convergência prematura (entre as épocas 7 e 10), seguida de overfitting, conforme ilustrado na Figura 5.



Figure 4. Curva de evolução do treinamento do modelo baseline.

A hipótese principal para esse comportamento reside no fato de a BCE Loss tratar as classes como entidades nominais independentes. Consequentemente, o modelo é penalizado de forma idêntica ao confundir ISUP 0 com ISUP 1 (erro clínico menor) e ao confundir ISUP 0 com ISUP 5 (erro clínico grave). Essa limitação motivou a adoção de uma abordagem baseada em Regressão Ordinal.

A arquitetura proposta utiliza a Regressão Ordinal para modelar a natureza contínua e hierárquica do sistema de graduação ISUP. O problema de K classes é transformado em $K - 1$ tarefas de classificação binária, onde a k -ésima saída representa a probabilidade

condicional $P(y > k)$. Os rótulos de destino (y) são mapeados para vetores ordinais $V = [v_0, \dots, v_{K-2}]$, definidos formalmente como:

$$v_k = \begin{cases} 1, & \text{se } y > k \\ 0, & \text{caso contrário} \end{cases}$$

Desta forma, um grau ISUP 3 é codificado como $[1, 1, 1, 0, 0]$.

Esta estrutura impõe uma restrição de monotonicidade aos rótulos, impedindo configurações logicamente inconsistentes e permitindo que o modelo apreenda as relações hierárquicas entre os graus de severidade do câncer. A implementação da Ordinal Loss elevou o desempenho do modelo, superando o resultado anterior de 0.838 para 0.851 de Kappa. Subsequentemente, integrou-se a técnica de Focal Loss [12] à abordagem ordinal. Projetada para mitigar o desbalanceamento de classes, a Focal Loss remodela a entropia cruzada padrão adicionando um fator de modulação $(1 - p_t)^\gamma$ que reduz o peso relativo de exemplos fáceis (bem classificados), forçando o modelo a focar o treinamento em exemplos difíceis e mal classificados. Com essa integração, atingiu-se um Kappa de 0.857, considerada a configuração ótima para a arquitetura B0. Finalmente, esta mesma estrutura de pipeline (taxa de aprendizado, épocas, otimizador e função de perda) foi aplicada a modelos de maior capacidade (EfficientNet-B3 e B7). Os resultados obtidos foram de 0.848 e 0.844, respectivamente, indicando que o aumento da complexidade do modelo sem ajustes adicionais não resultou em ganho de desempenho neste cenário.




Figure 5. Loss e Kappa para o melhor modelo individual de classificação.

3.4. Ensemble

Visando maximizar o desempenho preditivo, implementou-se um ensemble dos modelos EfficientNet-B0, B3 e B7. A literatura respalda essa abordagem pela sua superioridade em robustez e generalização frente a modelos isolados[13]. Entre as estratégias de combinação avaliadas (média simples, ponderada, máximo e voto majoritário), a média simples obteve o melhor desempenho, com $k = 0,8796$ (IC 95%: 0,8581–0,8983). Este resultado superou os modelos individuais B0 $k = 0,856$, B3 $k = 0,848$ e B7 $k = 0,844$.

4. Results

Table 3. Comparação de desempenho: Kappa e Acurácia (com Desvio Padrão e Intervalo de Confiança).

Model	Kappa			Acurácia		
	Resultado	Std	IC 95%	Resultado	Std	IC 95%
Ensemble-Mean	0,8796	0,0102	[0,8581; 0,8983]	0,6980	0,0114	[0,6767; 0,7214]
Ensemble-Weighted	0,8787	0,0096	[0,8581; 0,8957]	0,6927	0,0117	[0,6692; 0,7145]
Ensemble-Vote	0,8598	0,0119	[0,8358; 0,8829]	0,6922	0,0115	[0,6686; 0,7151]
B0-Entropy-Ordinal-Focal	0,8564	0,0112	[0,8334; 0,8768]	0,6602	0,0120	[0,6358; 0,6830]
B3-Entropy-Ordinal-Focal	0,8483	0,0121	[0,8241; 0,8707]	0,6603	0,0119	[0,6384; 0,6837]
B7-Entropy-Ordinal-Focal	0,8443	0,0114	[0,8210; 0,8655]	0,6028	0,0123	[0,5786; 0,6283]
Ensemble-Max	0,8391	0,0111	[0,8159; 0,8594]	0,5828	0,0120	[0,5597; 0,6050]

5. Conclusion

References

1. Siegel, R. L.; Giaquinto, A. N.; Jemal, A. Cancer statistics, 2024. *CA: A Cancer Journal for Clinicians* **2024**, *74*, 12–49.

2. Epstein, J. I.; Egevad, L.; Amin, M. B.; Delahunt, B.; Srigley, J. R.; Humphrey, P. A. The 2014 International Society of Urological Pathology (ISUP) Consensus Conference on Gleason Grading of Prostatic Carcinoma: Definition of Grading Patterns and Proposal for a New Grading System. *The American Journal of Surgical Pathology* **2016**, *40*, 244–252.

3. Tan, M.; Le, Q. V. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. In *Proceedings of the 36th International Conference on Machine Learning, Long Beach, CA, USA, 9–15 June 2019*; pp. 6105–6114.

4. He, K.; Zhang, X.; Ren, S.; Sun, J. Deep Residual Learning for Image Recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Las Vegas, NV, USA, 27–30 June 2016*; pp. 770–778.

5. Hu, J.; Shen, L.; Sun, G. Squeeze-and-Excitation Networks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Salt Lake City, UT, USA, 18–23 June 2018*; pp. 7132–7141.

6. Bulten, W.; Pinckaers, H.; van Boven, H.; Vink, R.; de Bel, T.; van Ginneken, B.; van der Laak, J.; Hulsbergen-van de Kaa, C.; Litjens, G. Automated deep-learning system for Gleason grading of prostate cancer using biopsies: a diagnostic study. *The Lancet Oncology* **2020**, *21*, 233–241.

7. Campanella, G.; Hanna, M. G.; Geneslaw, L.; Mirafior, A.; Werneck Krauss Silva, V.; Busam, K. J.; Brogi, E.; Reuter, V. E.; Klimstra, D. S.; Fuchs, T. J. Clinical-grade computational pathology using weakly supervised deep learning on whole slide images. *Nature Medicine* **2019**, *25*, 1301–1309.

8. Nagpal, K.; Foote, D.; Liu, Y.; Chen, P. H. C.; Wulczyn, E.; Tan, F.; Olson, N.; Smith, J. L.; Mohtashamian, A.; Wren, J. H.; Corrado, G. S.; MacDonald, L.; Peng, L. H.; Amin, M. B.; Evans, A. J.; Sangoi, A. R.; Mermel, C. H.; Hipp, J. D.; Stumpe, M. C. Development and validation of a deep learning algorithm for improving Gleason scoring of prostate cancer. *npj Digital Medicine* **2019**, *2*, 48.

9. PANDA Challenge. Prostate cANcer graDe Assessment Challenge. Kaggle, 2020. Available online: <https://www.kaggle.com/c/prostate-cancer-grade-assessment> (accessed on 1 January 2024).

10. Cohen, J. Weighted kappa: Nominal scale agreement with provision for scaled disagreement or partial credit. *Psychological Bulletin* **1968**, *70*, 213–220.

11. Izmailov, P.; Podoprikin, D.; Garipov, T.; Vetrov, D.; Wilson, A. G. Averaging Weights Leads to Wider Optima and Better Generalization. In *Proceedings of the 34th Conference on Uncertainty in Artificial Intelligence, Monterey, CA, USA, 6–10 August 2018*; pp. 876–885.

12. T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, “Focal loss for dense object detection,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 2980–2988.

13. Mian, Q.; Yang, X.; Zhang, H.; Su, H.; Yang, G.; Bianchi, F.; Bølviken, A.; Riegler, M.; Halvorsen, P. *Ensemble learning: A systematic review and meta-analysis*. Engineering Applications of Artificial Intelligence, v. 132, p. 107812, 2024.

14. Ali, I.; Khan, A.; Khan, M.; Ahmad, R.; Ullah, I. Shannon Entropy in Artificial Intelligence and Its Applications Based on Information Theory. *Entropy*, 25(2): 364, 2023.

15. Kott, O.; Linsley, D.; Amin, A.; Karagounis, A.; Jeffers, C.; Golijanin, D.; Serre, T.; Gershman, B. Development of a Deep Learning Algorithm for the Histopathologic Diagnosis and Gleason Grading of Prostate Cancer Biopsies: A Pilot Study. *European Urology Focus* **2019**, *5*, 79–83.

16. Lucas, M.; Jansen, I.; Savci-Heijink, C. D.; Meijer, S. L.; de Boer, O. J.; van Leeuwen, T. G.; de Bruin, D. M.; Marquering, H. A. Deep learning for automatic Gleason pattern classification for grade group determination of prostate biopsies. *Virchows Archiv* **2019**, *475*, 77–83.

17. Xie, W.; Rundo, L.; Szmul, A.; Iglesias, J. E.; Ouyang, C.; Hu, Y.; Gayo, I.; Barratt, D. C.; Clarkson, M. J.; Nachev, P.; Ourselin, S.; Vercauteren, T. Deep Learning with Uncertainty Quantification for Dice Coefficient Prediction in Prostate Cancer Biopsy Images. *IEEE Journal of Biomedical and Health Informatics* **2024**, *28*, 234–245. 258 259 260
18. Singhal, N.; Soni, S.; Bonthu, S.; Chattopadhyay, N.; Samanta, P.; Joshi, U.; Jojera, A.; Chharchhodawala, T.; Agarwal, A.; Desai, M.; Ganpule, A. A deep learning system for prostate cancer diagnosis and grading in whole slide images of core needle biopsies. *Scientific Reports* **2022**, *12*, 3383. 261 262 263
19. Hammouda, K.; Khalifa, F.; El-Melegy, M.; Ghazal, M.; Darwish, H. E.; Abou El-Ghar, M.; El-Baz, A. A Deep Learning Pipeline for Grade Groups Classification Using Digitized Prostate Biopsy Specimens. *Sensors* **2021**, *21*, 6708. 264 265

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content. 266 267 268