

Efficient-EF-OFL: An Entropy-Based Filtering and Ordinal Focal Loss Approach with EfficientNet for Prostate Lesion Classification

Woshington V S Rodrigues¹ , José D. L. Araújo² , Antonio O. C. Filho³ and Armando Luz Borges⁴ 

¹ Federal University of Piauí (UFPI), Brazil; woshington@ifpi.edu.br

² Federal University of Piauí (UFPI), Brazil; jose.denes@ufpi.edu.br

³ Federal University of Piauí (UFPI), Brazil; antoniooseas@gmail.com

⁴ Federal University of Piauí (UFPI), Brazil; armandoluzborges@ufpi.edu.br

* Correspondence: woshington@ifpi.edu.br

Abstract

Automated ISUP grade classification in prostate biopsy whole-slide images remains challenging due to high morphological variability, label noise, and inter-institutional heterogeneity. This study proposes an efficient pipeline combining entropy-based noise filtering, systematic patch extraction, ordinal regression, and focal loss to enhance robustness in learning from large-scale data. Variants of the EfficientNet architecture (B0, B3, and B7) were trained using a unified strategy, and their outputs were aggregated through ensemble methods. Experiments were conducted on the multicentric PANDA dataset, comprising 10,616 WSIs. The best individual model (EfficientNet-B0 with ordinal focal loss) achieved a QWK of 0.856, while deeper variants did not yield further improvements. The simple-average ensemble surpassed all single models, reaching a QWK of 0.879 and producing the most clinically coherent confusion matrix, with misclassifications largely restricted to adjacent ISUP grades. These results demonstrate that combining ordinal modeling, noise filtering, and lightweight architectures provides an advantageous balance between accuracy, stability, and computational efficiency. Although competitive with state-of-the-art approaches, the method requires validation on external datasets to further assess generalizability. Future directions include specialized models for intermediate grades and the exploration of transformer-based architectures.

Keywords: Prostate cancer; ISUP grading; EfficientNet; Ordinal Regression, Ensemble Learning; Noise Filtering

Received:

Revised:

Accepted:

Published:

Citation: Lastname, F.; Lastname, F.; Lastname, F. Efficient-EF-OFL: An Entropy-Based Filtering and Ordinal Focal Loss Approach with EfficientNet for Prostate Lesion Classification. *Journal Not Specified* **2025**, *1*, 0. <https://doi.org/>

Copyright: © 2025 by the authors. Submitted to *Journal Not Specified* for possible open access publication under the terms and conditions of the Creative Commons Attribution (CC BY) license (<https://creativecommons.org/licenses/by/4.0/>).

1. Introduction

O câncer de próstata é uma das neoplasias malignas mais comuns em homens, representando um desafio relevante para a saúde pública [1]. A graduação tumoral desempenha papel central na definição do manejo clínico e do prognóstico. O sistema de Gleason, baseado na soma dos dois padrões histológicos mais prevalentes (Gleason score), evoluiu para o sistema de graus da ISUP (0–5), que oferece melhor estratificação prognóstica e é amplamente utilizado na prática clínica [2].

A avaliação histopatológica tradicional de lâminas inteiras (WSIs) depende de análise manual por patologistas, um processo sujeito à variabilidade inter e intra-observador [3], demorado e limitado pela disponibilidade de especialistas. Essas restrições motivaram o desenvolvimento de métodos automatizados baseados em aprendizado profundo.

Redes neurais convolucionais (CNNs) têm se destacado na análise de imagens médicas [4], incluindo na graduação automatizada dos padrões de Gleason e dos graus ISUP [3,5]. Entre as arquiteturas modernas, a família EfficientNet [6] apresenta excelente relação entre precisão e custo computacional, graças ao escalonamento composto da rede e ao uso de blocos MBConv com squeeze-and-excitation [7].

Neste trabalho, investigamos a classificação automatizada dos graus ISUP, avaliando variantes do EfficientNet (B0, B3 e B7) no conjunto PANDA [8]. Utilizamos transfer learning, estratégias de fine-tuning, técnicas de treinamento avançadas e métodos de ensemble para aprimorar a robustez do modelo.

As principais contribuições incluem: (1) a implementação de uma função de perda que combina componentes ordinais e focais; (2) a comparação de técnicas de treinamento, incluindo remoção de ruído, SWA [9] e perda focal; (3) o desenvolvimento de ensembles para melhorar a estabilidade das predições; e (4) uma análise sistemática de variantes do EfficientNet para classificação ISUP. O desempenho é avaliado principalmente pelo kappa quadrático ponderado (QWK) [10], métrica apropriada para tarefas de classificação ordinal, e acurácia.

2. Related Works

A aplicação de técnicas de aprendizado profundo à classificação automatizada de câncer de próstata tem sido amplamente investigada, com avanços significativos especialmente no uso de WSIs, estratégias baseadas em patches e mecanismos de agregação multi-escala.

Bulten et al. [3] desenvolveram um sistema de deep learning para a graduação Gleason automatizada, utilizando um dataset com 5.759 biópsias provenientes do Radboud University Medical Center, estratificadas em conjuntos de treinamento (4.712), validação (497) e teste (535). O método, baseado em uma arquitetura U-Net estendida com rotulagem semissupervisionada, obteve κ_{quad} de 0,918 no teste interno. A validação do sistema incluiu ainda um estudo de observadores, superando o desempenho de 10 entre 15 patologistas, e a aplicação em um dataset externo independente do Hospital Universitário de Zurique, $\kappa_{quad} > 0,700$.

Nagpal et al. [5] desenvolveram um sistema de deep learning em dois estágios (CNN InceptionV3 e k-NN) para a graduação Gleason, utilizando dados provenientes do TCGA e de dois centros médicos dos EUA. O modelo foi treinado com 112 milhões de patches anotados e extraídos de 1.226 lâminas e validado em uma coorte independente de 331 lâminas de prostatectomia. O sistema alcançou acurácia de 0,70 contra um padrão de referência especializado, superando significativamente a média de 0,61 obtida por um painel de 29 patologistas ($p = 0,002$) e demonstrando superioridade na estratificação de risco clínico.

Abordagens diretamente baseadas em patches evoluíram rapidamente. Kott et al. [11] realizaram um estudo piloto para desenvolver um algoritmo de deep learning focado especificamente em biópsias de próstata, utilizando ResNet-18. O modelo foi treinado e validado com 14.803 patches de imagem extraídos de 85 WSIs de 25 pacientes de uma única instituição. O sistema alcançou 91,5% de acurácia no diagnóstico de malignidade (AUC de 0,83) e 85,4% de acurácia na graduação Gleason multiclasse (Benigno vs. 3 vs. 4 vs. 5).

Lucas et al. [12] propuseram uma abordagem baseada na arquitetura CNN Inception-v3 para a detecção de padrões Gleason e determinação automatizada de Grupos de Grau em biópsias de próstata. Utilizando um dataset de 96 seções de tecido de 38 pacientes, anotadas detalhadamente em nível de pixel, o método gerou mapas de probabilidade para calcular a composição da biópsia. O sistema alcançou acurácia de 92% para detecção de

maligndade e 90% para a distinção entre padrões de baixo ($GP \leq 3$) e alto grau ($GP \geq 4$). Na classificação final do Grupo de Grau da lâmina, o modelo alcançou κ_{quad} de 0,70.

Hammouda et al. [13] propuseram um sistema para a classificação de Grupos de Grau utilizando uma CNN piramidal de três escalas e uma estratégia de classificação pixel-wise com votação majoritária. O modelo foi desenvolvido com 608 imagens de WSIs provenientes do Radboud University Medical Center, aplicando-se uma estratégia de balanceamento para mitigar a predominância do padrão stroma. A abordagem, que integra pré-processamento com realce de bordas, alcançou 94% de acurácia na determinação final dos Grupos de Grau e destacou-se pela eficiência computacional, operando com cerca de 1 milhão de parâmetros.


Outros trabalhos ampliaram o foco para WSIs completas. Singhal et al. [14] desenvolveram um sistema de deep learning para graduação em biópsias baseado em U-Net com codificador ResNeXt50, utilizando estratégias de treinamento agnóstico ao domínio e active learning para mitigar variações de coloração. O modelo foi desenvolvido com 6.670 WSIs de três instituições distintas e demonstrou alta capacidade de generalização ao atingir acurácia de 83,1% e κ_{quad} 0,93 em um dataset externo, além de manter AUCs superiores a 0,93 na estratificação de risco clínico entre diferentes centros.

Apesar dos avanços, a área ainda enfrenta limitações quanto à escala dos dados e à metodologia. Muitos estudos dependem de datasets pequenos [11],[12], o que compromete a generalização. Mesmo trabalhos robustos focados em adaptação de domínio, como Singhal et al. [14], exploram pouco a eficiência das arquiteturas e o uso de regressão ordinal. Além disso, o potencial de técnicas de filtragem de ruído e curadoria baseada em incerteza permanece subexplorado em comparação às abordagens tradicionais de classificação e segmentação.

Diante desse cenário, este trabalho se diferencia ao realizar uma avaliação sistemática de múltiplas variantes do EfficientNet (B0, B3 e B7) aplicadas especificamente à graduação ISUP no conjunto PANDA, combinando regressão ordinal e focal loss para modelar a natureza hierárquica e desbalanceada das classes. Também exploramos estratégias de ensemble otimizadas, que superam consistentemente modelos individuais, e incorporamos uma etapa de filtragem baseada na entropia de Shannon para mitigação de rótulos ruidosos, uma abordagem não explorada nos trabalhos apresentados nesta pesquisa.

3. Materials and Methods

A metodologia adotada neste estudo consiste em um pipeline estruturado para a classificação automática dos graus ISUP em imagens histopatológicas de próstata, conforme ilustrado na Figura 1. Inicialmente, o conjunto de dados PANDA é adquirido e submetido a etapas de pré-processamento, seguido pela divisão em treino e teste. Em seguida, aplica-se uma filtragem para redução de ruído, com o objetivo de remover imagens potencialmente inconclusivas que poderiam comprometer o processo de aprendizagem dos modelos. Após essa etapa, as lâminas completas são fragmentadas em patches, reduzindo a dimensionalidade espacial e tornando o treinamento computacionalmente mais eficiente. Na fase de modelagem, diferentes classificadores individuais são treinados empregando distintas estratégias de aprendizado. Por fim, utiliza-se uma abordagem de ensemble para combinar as predições desses modelos, resultando em uma solução mais robusta e estável.

**Figure 1**

3.1. Dataset Acquisition

Utilizamos o conjunto de dados do Prostate cANcer graDe Assessment (PANDA) [8], composto por 10.616 whole-slide images (WSIs) de biópsias de próstata digitalizadas em alta resolução (20×). Cada imagem foi anotada segundo o sistema de graduação ISUP (0–5), no qual o grau 0 indica ausência de malignidade, enquanto os graus 1 a 5 representam níveis crescentes de agressividade tumoral.

A Tabela 1 apresenta a distribuição das classes do conjunto de dados. Observa-se um desbalanceamento significativo entre os rótulos, com predominância da classe 0 (aproximadamente 27%). Em contraste, as classes associadas a graus clínicos mais avançados (ISUP 4 e 5) representam, cada uma, menos de 12% do total.

As imagens do PANDA são provenientes de dois centros médicos distintos: Radboud University Medical Center e Karolinska Institutet. Segundo os autores [8], as lâminas do Radboud foram anotadas por estudantes treinados, enquanto as do Karolinska foram rotuladas por patologistas experientes. Essa heterogeneidade introduz variabilidade interinstitucional nas anotações. Além disso, o conjunto público apresenta diferentes formas de ruído, incluindo anotações inclusivas e marcas de caneta próximas a regiões tumorais, o que pode afetar a qualidade do treinamento dos modelos.

Table 1. Characteristics of the PANDA dataset used in this study.

	Karolinska	Radboud	Total
ISUP Grade			
0	1,520 (27.9%)	1,372 (26.6%)	2,892 (27.24%)
1	1,404 (25.7%)	1,262 (24.4%)	2,666 (25.11%)
2	690 (12.6%)	653 (12.7%)	1,343 (12.65%)
3	635 (11.6%)	607 (11.8%)	1,242 (11.70%)
4	641 (11.7%)	608 (11.8%)	1,249 (11.77%)
5	566 (10.3%)	658 (12.7%)	1,224 (11.53%)
Total	5,456 (51.3%)	5,160 (48.7%)	10,616 (100%)

3.2. Preprocessing

O pipeline de pré-processamento foi estruturado sequencialmente para garantir a integridade da avaliação e a qualidade das amostras. O processo inicia-se com o particionamento estratificado dos dados, seguido por uma etapa de filtragem baseada em incerteza (entropia) para a remoção de instâncias ruidosas. Por fim, para lidar com a alta dimensionalidade das lâminas e ampliar a variabilidade do conjunto de treino, aplicam-se a extração de patches e técnicas de aumento de dados.

3.2.1. Data Partitioning and Noise Filtering

Inicialmente, realizou-se uma divisão estratificada do conjunto de dados, de modo a preservar a distribuição original das classes. Do total de imagens, 15% foram reservadas para o conjunto de teste final, enquanto os 85% restantes compuseram o conjunto de desenvolvimento.

Considerando a presença de rótulos ruidosos, como ilustrado na Figura 2, que apresenta uma imagem com marcas visíveis de caneta, e a elevada complexidade na discriminação de determinadas amostras (Seção 3.1), foi implementado um mecanismo de filtragem baseado na *Entropia de Shannon*. Essa métrica, amplamente utilizada na Teoria da Informação e em aplicações de Inteligência Artificial, permite quantificar o grau de incerteza associado às predições do modelo [15].



Figure 2. Exemplo de imagem contendo ruído.

Para cada instância, o modelo gera uma distribuição de probabilidades sobre as K classes, representada por $p = [p_1, \dots, p_K]$. A entropia é então definida por:

$$H(p) = - \sum_{i=1}^K p_i \log(p_i), \quad (1)$$

na qual valores baixos indicam maior confiança do modelo, pois a distribuição de probabilidades se encontra concentrada em poucas classes. Em contrapartida, valores mais elevados estão associados a distribuições mais uniformes, refletindo maior incerteza nas predições e sugerindo que a amostra pode ser ambígua, ruidosa ou de baixa qualidade. Dessa forma, a entropia foi adotada como um indicador sistemático da dificuldade das amostras, sendo aplicada exclusivamente ao conjunto de desenvolvimento.

O processo de filtragem foi conduzido em três etapas. Inicialmente, foi utilizado um modelo EfficientNet-B0 pré-treinado no ImageNet [16] para estimar a distribuição de probabilidades de todas as amostras do conjunto de desenvolvimento, a partir das quais se calculou a entropia. Em seguida, avaliou-se o impacto da remoção das instâncias com maiores valores de entropia, testando-se limiares correspondentes à exclusão dos 10%, 5%

e 2% dos exemplos mais incertos. Por fim, o limiar de 2% foi selecionado por apresentar o melhor equilíbrio entre a redução de ruído e a preservação do volume de dados disponível.

Após a remoção das amostras ruidosas, o conjunto de desenvolvimento foi subdividido estratificadamente em 80% para treinamento e 20% para validação. A Tabela 2 apresenta a distribuição dos dados antes e depois da filtragem.

Table 2. Dataset distribution after noise filtering (2% threshold)

Subset	% of Total	No. of Images
Test	15%	1,590
<i>Development Set (Pre-Filtering)</i>		9,024
<i>Development Set (Post-Filtering)</i>		8,844
Training	≈68%	7,075
Validation	≈17%	1,769
Total Used	100%	10,434

3.2.2. Patch extraction

Considerando o tamanho das WSIs e a presença de áreas não informativas, foi aplicado um pré-processamento para otimizar o uso computacional e preservar regiões relevantes para o diagnóstico. Inicialmente, foram extraídos patches fixos de 256×256 pixels, selecionados com base em critérios empíricos de intensidade média e saturação nos canais RGB, a fim de eliminar regiões de fundo, artefatos e áreas sem coloração diagnóstica. A Figura 3 ilustra a imagem histopatológica original utilizada como base para a extração dos patches e a imagem composta resultante após a extração e o rearranjo dos patches, permitindo uma compreensão visual do processo.




Figure 3. Original histopathological image (a) and composite image after patch extraction and rearrangement (b).

Para cada lâmina, foram extraídos 36 patches, número definido por meio de experimentos preliminares que avaliaram o impacto da quantidade de regiões na representatividade morfológica e na viabilidade computacional. Para estabelecer essa escolha, três configurações foram comparadas: 25, 36 e 49 patches por lâmina, conforme ilustrado na Figura 4.

A extração com 25 patches produziu uma composição compacta, consequentemente gerando menos dados a serem analisados, o que pode reduzir a demanda por recursos computacionais durante o treinamento e a validação do modelo. Entretanto, essa configuração




Figure 4. Representation of patch extraction with different quantities. The image shows three examples: (a) with 25 patches, (b) with 36 patches, and (c) with 49 patches, displayed from left to right.

limita a cobertura da lâmina, resultando em perda significativa de padrões morfológicos relevantes para a classificação. Por outro lado, a extração com 49 patches ampliou a área analisada, mas aumentou os custos computacionais e de armazenamento, além de incluir muitas regiões vazias ou redundantes que podem afetar a eficiência do processamento. Adicionalmente, a inclusão de áreas periféricas com baixo conteúdo discriminativo pode comprometer a qualidade da representação ao diluir ou saturar características importantes.

Assim, a configuração intermediária com 36 patches equilibra adequadamente a cobertura da diversidade morfológica e a eficiência computacional, abrangendo a maior parte das informações relevantes sem sobrecarregar a imagem com regiões irrelevantes. Por essa razão, essa configuração foi adotada como padrão neste trabalho. Após a extração, os patches foram reorganizados e concatenados em uma única imagem composta. Diferentemente de abordagens que preservam a distribuição espacial original, neste estudo os patches foram ordenados com base na quantidade de informação morfológica contida em cada um, estimada a partir de medidas de intensidade e saturação nos canais RGB.

3.3. Single Classifiers

Na fase inicial dos experimentos, adotamos o modelo EfficientNet-B0 como referência para a otimização dos hiperparâmetros. Inicialmente, estabeleceu-se um baseline utilizando a função de perda Binary Cross-Entropy (BCE). Esta escolha baseou-se na natureza do problema, considerando que, embora uma lâmina possa apresentar múltiplos graus de lesão, a graduação final da biópsia é determinada pelo padrão de Gleason primário (mais frequente) e secundário, conforme estabelecido pelo sistema ISUP [2].

Durante o treinamento deste baseline, foram avaliadas diversas estratégias, incluindo Stochastic Weight Averaging (SWA), Test Time Augmentation (TTA), além de variações na taxa de aprendizado, número de épocas, otimizadores e espaços de cores. Em todos os experimentos, o modelo apresentou convergência prematura (entre as épocas 7 e 10), seguida de overfitting, conforme ilustrado na Figura 5.




Figure 5. Curva de evolução do treinamento do modelo baseline.

A hipótese principal para esse comportamento reside no fato de a BCE Loss tratar as classes como entidades nominais independentes. Consequentemente, o modelo é penalizado de forma idêntica ao confundir ISUP 0 com ISUP 1 (erro clínico menor) e ao confundir ISUP 0 com ISUP 5 (erro clínico grave). Essa limitação motivou a adoção de uma abordagem baseada em Regressão Ordinal.

A arquitetura proposta utiliza a Regressão Ordinal para modelar a natureza contínua e hierárquica do sistema de graduação ISUP. O problema de K classes é transformado em $K - 1$ tarefas de classificação binária, onde a k -ésima saída representa a probabilidade condicional $P(y > k)$. Os rótulos de destino (y) são mapeados para vetores ordinais $V = [v_0, \dots, v_{K-2}]$, definidos formalmente como:

$$v_k = \begin{cases} 1, & \text{se } y > k \\ 0, & \text{caso contrário} \end{cases}$$

Desta forma, um grau ISUP 3 é codificado como $[1, 1, 1, 0, 0]$.

Esta estrutura impõe uma restrição de monotonicidade aos rótulos, impedindo configurações logicamente inconsistentes e permitindo que o modelo apreenda as relações hierárquicas entre os graus de severidade do câncer. A implementação da Ordinal Loss elevou o desempenho do modelo, superando o resultado anterior de 0.838 para 0.851 de Kappa. Subsequentemente, integrou-se a técnica de Focal Loss [17] à abordagem ordinal.

Projetada para mitigar o desbalanceamento de classes, a Focal Loss remodela a entropia cruzada padrão adicionando um fator de modulação $(1 - p_t)^\gamma$ que reduz o peso relativo de exemplos fáceis (bem classificados), forçando o modelo a focar o treinamento em exemplos difíceis e mal classificados. Com essa integração, obtivemos um coeficiente Kappa de 0.857, caracterizando essa configuração como a melhor combinação de hiperparâmetros para a arquitetura EfficientNet-B0. Na Figura 6, observamos que a perda no conjunto de validação manteve-se estável ao longo do treinamento, enquanto o valor do Kappa apresentou uma evolução contínua e consistente, atingindo aproximadamente 0.860 em seu ponto máximo. Esse comportamento indica que o modelo conseguiu melhorar sua capacidade discriminativa sem incorrer em sobreajuste significativo. Finalmente, esta mesma estrutura de pipeline (taxa de aprendizado, épocas, otimizador e função de perda) foi aplicada a modelos de maior profundidade (EfficientNet-B3 e B7). Os resultados obtidos foram de 0.848 e 0.844, respectivamente, indicando que o aumento da complexidade do modelo sem ajustes adicionais não resultou em ganho de desempenho neste cenário.




Figure 6. Loss e Kappa para o melhor modelo individual de classificação.

3.4. Ensemble

Visando maximizar o desempenho preditivo, implementou-se um ensemble dos modelos EfficientNet-B0, B3 e B7. A literatura respalda essa abordagem pela sua superioridade em robustez e generalização frente a modelos isolados[18]. Entre as estratégias de combinação avaliadas (média simples, ponderada, máximo e voto majoritário), a média simples obteve o melhor desempenho, com $k = 0,879$ (IC 95%: 0,8581–0,8983). Este resultado superou os modelos individuais B0 $k = 0,856$, B3 $k = 0,848$ e B7 $k = 0,844$.

3.4.1. Evaluation Metrics

A avaliação dos modelos utilizou a acurácia para mensurar o desempenho global e o coeficiente Kappa de Cohen com ponderação quadrática [10]. A adoção do Kappa visa considerar a natureza ordinal da graduação de Gleason, penalizando erros maiores de forma mais severa.

4. Results

Nesta seção apresentamos a avaliação quantitativa dos modelos individuais e das abordagens de ensemble, seguindo o protocolo descrito na Seção 3.

A Tabela 3 resume o desempenho em termos de Kappa Quadrático Ponderado (QWK) e acurácia, acompanhados de desvio padrão e intervalos de confiança de 95%. Entre os modelos individuais, o EfficientNet-B0 com regressão ordinal, perda focal e filtragem por entropia apresentou o melhor desempenho (QWK = 0,856). Versões mais profundas (B3 e B7) não resultaram em melhorias, sugerindo que o aumento da capacidade do modelo não trouxe benefícios sob o pipeline adotado.

Em contraste, as estratégias de ensemble superaram consistentemente os modelos isolados. O melhor desempenho foi obtido pelo ensemble baseado em média simples, alcançando QWK = 0,879, superando tanto os modelos individuais quanto outras estratégias de agregação, como média ponderada, voto majoritário e máximo. Observa-se também melhora na acurácia, indicando maior estabilidade nas predições interclasses.

Esses resultados demonstram que a combinação de múltiplos modelos por média simples não apenas suaviza variações indesejadas, mas também captura diferentes aspectos aprendidos por cada arquitetura, resultando em uma solução mais robusta para a classificação ISUP.

Table 3. Comparação de desempenho: Kappa e Acurácia (com Desvio Padrão e Intervalo de Confiança).

Model	Kappa			Acurácia		
	Resultado	Std	IC 95%	Resultado	Std	IC 95%
Ensemble-Mean	0,879	0,010	[0,858; 0,898]	0,698	0,011	[0,676; 0,721]
Ensemble-Weighted	0,878	0,009	[0,858; 0,895]	0,692	0,011	[0,669; 0,714]
Ensemble-Vote	0,859	0,011	[0,835; 0,882]	0,692	0,011	[0,668; 0,715]
B0-Entropy-Ordinal-Focal	0,856	0,011	[0,833; 0,876]	0,660	0,012	[0,635; 0,683]
B0-Entropy-Ordinal-Focal SWA	0,852	0,011	[0,830; 0,873]	0,653	0,012	[0,629; 0,676]
B3-Entropy-Ordinal-Focal	0,848	0,012	[0,824; 0,870]	0,660	0,011	[0,638; 0,683]
B7-Entropy-Ordinal-Focal	0,844	0,011	[0,821; 0,865]	0,602	0,012	[0,578; 0,628]
Ensemble-Max	0,839	0,011	[0,815; 0,859]	0,582	0,012	[0,559; 0,605]
B0-Baseline	0,826	0,012	[0,806; 0,846]	0,592	0,012	[0,572; 0,612]

As matrizes de confusão da Figura 7 mostram que o modelo B0-Baseline apresenta maior dispersão dos erros, com confusões frequentes entre classes não adjacentes, especialmente nos graus intermediários (ISUP 2–4). Isso indica que, sem a perda ordinal com focal loss, o modelo não consegue capturar adequadamente a natureza ordinal do problema. Por outro lado, o modelo B0-Entropy-Ordinal-Focal gera uma matriz de confusão

278 muito mais concentrada na diagonal, reduzindo erros distantes e limitando as confusões
279 principalmente a classes vizinhas, um comportamento alinhado ao esperado clinicamente.
280 Embora tenha sido superado apenas na categoria ISUP 0, sua maior precisão nos graus
281 mais agressivos reforça sua relevância clínica, já que esses casos demandam diagnósticos
282 mais consistentes e confiáveis.




Figure 7. Comparação entre o baseline e o melhor modelo individual

283 A análise da matriz de confusão do modelo Ensemble (Figura 8) evidencia um de-
284 sempenho robusto, caracterizado pela concentração de predições na diagonal principal. O
285 modelo demonstra alta eficácia nos casos de baixo risco (ISUP 0 e ISUP 1) e mantém con-
286 sistência nos graus intermediários (ISUP 2 e 3), onde os erros se restringem majoritariamente
287 às classes adjacentes. Nos estágios mais agressivos, a análise revela um comportamento
288 distinto: embora a acurácia em ISUP 4 apresente uma leve retração quando comparada ao
289 modelo B0-Entropy-Ordinal-Focal, o Ensemble compensa com uma performance superior
290 na detecção do ISUP 5. Este resultado é particularmente relevante, pois assegura maior
291 sensibilidade justamente no grau histológico de maior agressividade e pior prognóstico.




Figure 8. Matriz de confusão do ensemble

A Tabela 4 apresenta a comparação entre os resultados obtidos neste trabalho e estudos anteriores. Dada a diversidade de técnicas e bases utilizadas na literatura, destacam-se três eixos de análise: complexidade dos dados, Kappa (QWK) e consistência clínica.

- **Complexidade dos dados** - Este trabalho utiliza o dataset PANDA, reconhecidamente ruidoso e com alta variabilidade institucional, um cenário que torna a tarefa mais desafiadora. Em contraste, trabalhos como os de Lucas et al. e Hammouda et al. reportam acurácias elevadas, porém com bases privadas pequenas, o que tende a inflar métricas e reduzir a capacidade de generalização.
- **QWK (Quadratic Weighted Kappa)** - O modelo proposto apresenta desempenho competitivo, superando estudos como Lucas et al. e Nagpal et al. Embora Singhal et al. obtenham valores superiores, esses autores utilizam arquiteturas mais pesadas e estratégias adicionais, como active learning. Neste trabalho, optou-se pela família EfficientNet, buscando um melhor equilíbrio entre desempenho e custo computacional.
- **Consistência clínica** - Apesar de alguns trabalhos apresentarem maior acurácia, a matriz de confusão deste estudo evidencia que o modelo preserva de forma robusta a estrutura ordinal do problema. A maioria dos erros ocorre entre classes adjacentes, alinhando-se ao comportamento clínico esperado, aspecto que métricas agregadas, como a acurácia, não capturam adequadamente.

Table 4. Comparação dos resultados obtidos pelo método proposto com trabalhos relacionados do estado da arte.

Trabalho	Metodologia	Dataset	Desempenho	Observações
Proposto	Ensemble Efficient-Net (B0-B3-B7) + Ordinal Focal	PANDA (10.616 WSIs)	QWK: 0,879 Acc: 69,8%	Foco em redução de ruído (Entropia) e consistência ordinal.
Bulten et al. [3]	U-Net Estendida	Radboud (5.759 biópsias)	QWK: 0,918 (Int.) QWK: 0,700 (Ext.)	Superou a performance de 10 entre 15 patologistas.
Singhal et al. [14]	U-Net + ResNeXt50	Multicêntrico (6.670 WSIs)	QWK: 0,93 Acc: 83,1%	Utilizou <i>Active Learning</i> e adaptação de domínio.
Nagpal et al. [5]	InceptionV3 + k-NN	TCGA + Outros (1.226 lâminas)	Acc: 0,70	Superou significativamente a média de patologistas (0,61).
Lucas et al. [12]	InceptionV3	Privado (96 seções)	QWK: 0,70	Dataset limitado; alta acurácia apenas para classes binárias.
Kott et al. [11]	ResNet-18	Privado (85 WSIs)	Acc: 85,4%	Estudo piloto com foco em graduação multi-classe.
Hammouda et al. [13]	CNN Piramidal	Radboud (608 imagens)	Acc: 94%	Dataset pequeno e balanceado artificialmente.

5. Conclusion

Neste estudo, propusemos um pipeline eficiente para a classificação dos graus ISUP em imagens histopatológicas de próstata, combinando regressão ordinal, focal loss e filtragem baseada em entropia com variantes da arquitetura EfficientNet. Os resultados demonstram que o ensemble desenvolvido supera de forma consistente todos os modelos individuais, oferecendo previsões mais alinhadas à progressão clínica, menor ocorrência de erros graves e maior estabilidade entre as classes. Embora o modelo B0-Entropy-Ordinal-Focal já represente um avanço substancial em relação ao baseline, o ensemble integra de maneira eficaz os pontos fortes de cada arquitetura, resultando no padrão de confusão mais coerente e confiável observado.

Como limitação, destaca-se a utilização de apenas um dataset. Apesar de o PANDA ser multicêntrico e apresentar considerável diversidade, a validação em bases externas permanece essencial para fortalecer a generalização do método. Os achados também sugerem que modelos especializados para as classes intermediárias podem levar a melhorias adicionais, dada a maior heterogeneidade morfológica desses grupos.

Por fim, perspectivas futuras incluem a avaliação de arquiteturas mais recentes, como Vision Transformers (ViT), e o emprego de mecanismos baseados em self-attention ou estratégias específicas de curadoria ativa, que podem ampliar ainda mais a capacidade discriminativa do modelo. Tais avanços representam caminhos promissores para o desenvolvimento de sistemas mais precisos, robustos e clinicamente relevantes na graduação automatizada do câncer de próstata.

References

1. Siegel, R. L.; Giaquinto, A. N.; Jemal, A. Cancer statistics, 2024. *CA: A Cancer Journal for Clinicians* **2024**, *74*, 12–49.
2. Epstein, J. I.; Egevad, L.; Amin, M. B.; Delahunt, B.; Srigley, J. R.; Humphrey, P. A. The 2014 International Society of Urological Pathology (ISUP) Consensus Conference on Gleason Grading of Prostatic Carcinoma: Definition of Grading Patterns and Proposal for a New Grading System. *The American Journal of Surgical Pathology* **2016**, *40*, 244–252.
3. Bulten, W.; Pinckaers, H.; van Boven, H.; Vink, R.; de Bel, T.; van Ginneken, B.; van der Laak, J.; Hulsbergen-van de Kaa, C.; Litjens, G. Automated deep-learning system for Gleason grading of prostate cancer using biopsies: a diagnostic study. *The Lancet Oncology* **2020**, *21*, 233–241.
4. Campanella, G.; Hanna, M. G.; Geneslaw, L.; Miraflor, A.; Werneck Krauss Silva, V.; Busam, K. J.; Brogi, E.; Reuter, V. E.; Klimstra, D. S.; Fuchs, T. J. Clinical-grade computational pathology using weakly supervised deep learning on whole slide images. *Nature Medicine* **2019**, *25*, 1301–1309.
5. Nagpal, K.; Foote, D.; Liu, Y.; Chen, P. H. C.; Wulczyn, E.; Tan, F.; Olson, N.; Smith, J. L.; Mohtashamian, A.; Wren, J. H.; Corrado, G. S.; MacDonald, L.; Peng, L. H.; Amin, M. B.; Evans, A. J.; Sangoi, A. R.; Mermel, C. H.; Hipp, J. D.; Stumpe, M. C. Development and validation of a deep learning algorithm for improving Gleason scoring of prostate cancer. *npj Digital Medicine* **2019**, *2*, 48.
6. Tan, M.; Le, Q. V. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. In Proceedings of the 36th International Conference on Machine Learning, Long Beach, CA, USA, 9–15 June 2019; pp. 6105–6114.
7. Hu, J.; Shen, L.; Sun, G. Squeeze-and-Excitation Networks. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Salt Lake City, UT, USA, 18–23 June 2018; pp. 7132–7141.
8. PANDA Challenge. Prostate cANcer graDe Assessment Challenge. Kaggle, 2020. Available online: <https://www.kaggle.com/c/prostate-cancer-grade-assessment> (accessed on 1 January 2024).
9. Izmailov, P.; Podoprikin, D.; Garipov, T.; Vetrov, D.; Wilson, A. G. Averaging Weights Leads to Wider Optima and Better Generalization. In Proceedings of the 34th Conference on Uncertainty in Artificial Intelligence, Monterey, CA, USA, 6–10 August 2018; pp. 876–885.
10. Cohen, J. Weighted kappa: Nominal scale agreement with provision for scaled disagreement or partial credit. *Psychological Bulletin* **1968**, *70*, 213–220.
11. Kott, O.; Linsley, D.; Amin, A.; Karagounis, A.; Jeffers, C.; Golijanin, D.; Serre, T.; Gershman, B. Development of a Deep Learning Algorithm for the Histopathologic Diagnosis and Gleason Grading of Prostate Cancer Biopsies: A Pilot Study. *European Urology Focus* **2019**, *5*, 79–83.
12. Lucas, M.; Jansen, I.; Savci-Heijink, C. D.; Meijer, S. L.; de Boer, O. J.; van Leeuwen, T. G.; de Bruin, D. M.; Marquering, H. A. Deep learning for automatic Gleason pattern classification for grade group determination of prostate biopsies. *Virchows Archiv* **2019**, *475*, 77–83.
13. Hammouda, K.; Khalifa, F.; El-Melegy, M.; Ghazal, M.; Darwish, H. E.; Abou El-Ghar, M.; El-Baz, A. A Deep Learning Pipeline for Grade Groups Classification Using Digitized Prostate Biopsy Specimens. *Sensors* **2021**, *21*, 6708.
14. Singhal, N.; Soni, S.; Bonthu, S.; Chattopadhyay, N.; Samanta, P.; Joshi, U.; Jojera, A.; Chharchhodawala, T.; Agarwal, A.; Desai, M.; Ganpule, A. A deep learning system for prostate cancer diagnosis and grading in whole slide images of core needle biopsies. *Scientific Reports* **2022**, *12*, 3383.
15. Ali, I.; Khan, A.; Khan, M.; Ahmad, R.; Ullah, I. Shannon Entropy in Artificial Intelligence and Its Applications Based on Information Theory. *Entropy*, *25*(2): 364, 2023.
16. O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, M. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein *et al.*, “ImageNet Large Scale Visual Recognition Challenge”, *International Journal of Computer Vision*, vol. 115, no. 3, pp. 211–252, 2015.
17. T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, “Focal loss for dense object detection,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 2980–2988.

18. Mian, Q.; Yang, X.; Zhang, H.; Su, H.; Yang, G.; Bianchi, F.; Bølviken, A.; Riegler, M.; Halvorsen, P. *Ensemble learning: A systematic review and meta-analysis*. *Engineering Applications of Artificial Intelligence*, v. 132, p. 107812, 2024. 373
374

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual 375
author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to 376
people or property resulting from any ideas, methods, instructions or products referred to in the content. 377