



UNIVERSIDADE FEDERAL DO MARANHÃO
UNIVERSIDADE FEDERAL DO PIAUÍ
Doutorado em Ciência da Computação Associação
UFMA/UFPI

Woshington Valdeci de Sousa Rodrigues

**Uma Abordagem com Filtragem Baseada em Entropia,
Perda Focal Ordinal e Ensemble de EfficientNet para
Classificação do Grau ISUP em Histopatologia da Próstata**

Orientador: Prof. Dr. Antonio Oseas de Carvalho Filho

Picos - PI
Abril, 2026

Woshington Valdeci de Sousa Rodrigues

**Uma Abordagem com Filtragem Baseada em Entropia,
Perda Focal Ordinal e Ensemble de EfficientNet para
Classificação do Grau ISUP em Histopatologia da Próstata**

PROPOSTA DE TESE DE DOUTORADO

Proposta de tese ao Programa de Pós-Graduação em Ciência da Computação - Associação UFMA/UFPI como parte dos requisitos necessários para a obtenção do grau de Doutor em Ciência da Computação.

Orientador: Prof. Dr. Antonio Oseas de Carvalho Filho
Co-orientador:

Picos - PI
Abril, 2026

Woshington Valdeci de Sousa Rodrigues

Uma Abordagem com Filtragem Baseada em Entropia, Perda Focal Ordinal e Ensemble de EfficientNet para Classificação do Grau ISUP em Histopatologia da Próstata

A presente Proposta de Tese de Doutorado foi avaliada e aprovada por banca examinadora composta pelos seguintes membros:

Prof. Dr. Antonio Oseas de Carvalho Filho

Orientador

Universidade Federal do Piauí

Prof. Dra. Regina Célia Coelho

Examinador Externo

Universidade Federal de São Paulo

Prof. Dr. Otilio Paulo da Silva Neto

Examinador Externo

Instituto Federal do Piauí

Prof. Dr. João Otávio Bandeira Diniz

Examinador Externo

Instituto Federal do Maranhão

Prof. Dr. Flávio Henrique Duarte Araújo

Examinador Interno

Universidade Federal do Piauí

Certificamos que este documento corresponde à versão original e final da Proposta de Tese de Doutorado, a qual foi julgada adequada como parte dos requisitos para obtenção do título de Doutor em Ciência da Computação.

Prof. Dr. Antonio Oseas de Carvalho Filho

Orientador

Prof. Dr. Anselmo Cardoso de Paiva

Coordenador

Picos - PI, 10 de Abril de 2026

*À minha filha e à minha esposa, aos meus amigos e familiares, que acreditaram em mim
e me apoiaram ao longo desta jornada.*

Agradecimentos

Agradeço, primeiramente, a Deus, pela vida, pela força e por me guiar ao longo de toda esta jornada.

Ao meu orientador, Prof. Dr. Antonio Oseas de Carvalho Filho, pela orientação, dedicação, paciência e valiosas contribuições para o desenvolvimento deste trabalho.

À minha filha e à minha esposa, pelo amor, apoio incondicional e compreensão nos momentos de ausência.

Aos meus familiares e amigos, pelo incentivo, confiança e por sempre acreditarem em mim.

Por fim, agradeço a todos que, de alguma forma, contribuíram para a realização deste trabalho e para a minha formação acadêmica.

"A persistência é o caminho do êxito."
Charles Chaplin

Resumo

O câncer de próstata é uma das neoplasias malignas mais comuns em homens e representa um desafio significativo para a saúde pública. A avaliação histopatológica tradicional de imagens de lâminas inteiras depende da análise manual realizada por patologistas, sendo um processo sujeito à variabilidade inter e intraobservador, além de demandar tempo e elevada especialização. Neste trabalho, propõe-se uma abordagem para a classificação automatizada dos graus ISUP em imagens histopatológicas de biópsias de próstata, utilizando variantes da arquitetura EfficientNet (B0, B3 e B7) no conjunto de dados PANDA. O método integra três estratégias complementares: filtragem de amostras ruidosas baseada na entropia de Shannon; uma função de perda híbrida denominada Ordinal Focal Regression Loss, que combina regressão ordinal e Focal Loss para capturar a hierarquia entre os graus tumorais e mitigar o desbalanceamento entre classes; e um ensemble de modelos para aumentar a robustez e a estabilidade das previsões. Os experimentos demonstraram ganhos progressivos com a adição de cada componente proposto. O modelo baseline com EfficientNet-B0 e função de perda BCE alcançou $kappa = 0,826$ e acurácia de 0,592. A aplicação da filtragem de ruído, da perda ordinal focal e do ensemble baseado na média das probabilidades elevou o desempenho para $kappa = 0,880$ e acurácia de 0,698, superando o *baseline* em 5,4 e 10,6 pontos percentuais, respectivamente. Os erros de classificação concentraram-se predominantemente em classes adjacentes, reforçando o alinhamento clínico do método com a progressão ordinal dos graus ISUP.

Palavras-chave: Câncer de próstata, Classificação ISUP, Histopatologia digital, Redes neurais convolucionais, EfficientNet, Aprendizado profundo, Ensemble learning, Perda focal ordinal.

Abstract

Prostate cancer is one of the most common malignant neoplasms in men and represents a significant public health challenge. Traditional histopathological evaluation of whole-slide images relies on manual analysis by pathologists, a process that is subject to inter- and intra-observer variability and requires considerable time and high levels of expertise. In this work, we propose an approach for the automated classification of ISUP grades in histopathological images of prostate biopsies, using variants of the EfficientNet architecture (B0, B3, and B7) on the PANDA dataset. The method integrates three complementary strategies: filtering noisy samples based on Shannon entropy; a hybrid loss function, Ordinal Focal Regression Loss, that combines ordinal regression and Focal Loss to capture the hierarchical relationship between tumor grades and mitigate class imbalance; and a model ensemble to improve robustness and stability of predictions. The experiments demonstrated progressive gains with the addition of each proposed component. The baseline model, using EfficientNet-B0 and BCE loss, achieved a quadratic kappa of $\kappa = 0.826$ and an accuracy of 0.592. The application of noise filtering, ordinal focal loss, and an ensemble based on the mean of probabilities improved performance to $\kappa = 0.880$ and accuracy 0.698, surpassing the baseline by 5.4 and 10.6 percentage points, respectively. Classification errors were predominantly concentrated in adjacent classes, reinforcing the clinical alignment of the method with the ordinal progression of ISUP grades.

Keywords: Prostate cancer, ISUP Classification, Digital Histopathology, Convolutional neural networks, EfficientNet, Deep learning, Ensemble learning, Ordinal focal loss.

Lista de ilustrações

Figura 1 – Glândula Prostática	23
Figura 2 – Ilustração de biópsia com auxílio de TRUS. Fonte: [Neumaier 2023].	25
Figura 3 – Representação esquemática dos padrões arquiteturais do sistema de Gleason e sua correspondência aos grupos prognósticos (Grade Groups). Adaptado de [Hossain et al. 2025].	27
Figura 4 – Ilustração da forma de uma imagem digital.	28
Figura 5 – Representação matemática do modelo de um neurônio artificial. . .	29
Figura 6 – Representação da arquitetura do Multilayer Perceptron (MLP). . . .	30
Figura 7 – Representação de uma Rede Neural Convolucional (CNN).	34
Figura 8 – Comparação entre diferentes métodos de escalonamento. Adaptado de [Tan e Le 2019].	35
Figura 9 – Etapas do Método Proposto	41
Figura 10 – Exemplo de um artefato visual presente em uma WSI do conjunto de dados PANDA. À esquerda, apresenta-se a lâmina completa, com a região de interesse destacada em vermelho. À direita, uma visão ampliada da região selecionada revela uma marca de caneta sobre o tecido prostático. Fonte: Elaborado pelo autor.	43
Figura 11 – Distribuição de amostras no conjunto de dados PANDA	43
Figura 12 – Imagem de exemplo do conjunto de dados PANDA evidenciando a vasta área sem tecido.	45
Figura 13 – Ilustração da extração de <i>patches</i> em diferentes tamanhos: 5×5 (à esquerda), 6×6 (no centro) e 7×7 (à direita).	46
Figura 14 – Desempenho com diferentes limiares de remoção de ruído sobre os <i>hard samples</i>	51
Figura 15 – Imagem identificada como ruído pelo método de filtragem	52
Figura 16 – Matrizes de confusão normalizadas obtidas para o modelo treinado com a função de perda BCE (à esquerda) e com a função de perda ordinal (à direita).	53
Figura 17 – Matrizes de confusão normalizadas para modelos treinados com perda ordinal e perda focal ordinal.	54
Figura 18 – Exemplo de WSI classificada incorretamente.	59
Figura 19 – Exemplo de WSI com erro adjacente (ISUP 5 classificada como ISUP 4). .	60
Figura 20 – Exemplo de WSI com predição correta e unânime pelo <i>ensemble</i> . . .	60
Figura 21 – Exemplo de WSI com discordância (ISUP 5 Real vs Predições 0, 3 e 5). .	61

Lista de tabelas

Tabela 1 – Principais fatores de risco associados ao câncer de próstata	24
Tabela 2 – Resultados de desempenho do EfficientNet no ImageNet. Todos os modelos EfficientNet são derivados do EfficientNet-B0 utilizando escalonamento composto. Adaptado de [Tan e Le 2019].	36
Tabela 3 – Hiperparâmetros avaliados e configuração selecionada para os experimentos.	50
Tabela 4 – Impacto incremental das estratégias propostas no desempenho da EfficientNet-B0.	53
Tabela 5 – Comparação de desempenho entre as arquiteturas da família EfficientNet, utilizando a configuração experimental proposta.	55
Tabela 6 – Desempenho das diferentes estratégias de ensemble avaliadas no conjunto de teste.	55
Tabela 7 – Comparação do método proposto com trabalhos recentes.	56
Tabela 8 – Cronograma das atividades	64

Lista de abreviaturas e siglas

AUC-ROC	<i>Area Under the Receiver Operating Characteristic Curve</i>
BCE	<i>Binary Cross-Entropy</i>
CNN	<i>Convolutional Neural Network</i>
EOCC	<i>Ensembles of One-Class Classifiers</i>
FN	<i>False Negatives</i>
FP	<i>False Positives</i>
GCN	<i>Graph Convolutional Network</i>
HPB	Hiperplasia Prostática Benigna
IA	Inteligência Artificial
IARC	<i>International Agency for Research on Cancer</i>
ISUP	<i>International Society of Urological Pathology</i>
MIL	<i>Multiple Instance Learning</i>
MLP	<i>Multilayer Perceptron</i>
NAS	<i>Neural Architecture Search</i>
OMS	Organização Mundial de Saúde
PANDA	<i>Prostate Cancer Grade Assessment</i>
PDI	Processamento Digital de Imagens
PSA	<i>Prostate Specific Antigen</i>
ReLU	<i>Rectified Linear Units</i>
RF	<i>Random Forest</i>
RNA	Redes Neurais Artificiais
Self-ONN	<i>Self-Organizing Operational Neural Networks</i>
TC	Tomografia Computadorizada

TN	<i>True Negatives</i>
TP	<i>True Positives</i>
TRUS	<i>Transrectal Ultrasound</i>
TSOR	<i>Task-Specific Ordinal Regression</i>
ViT	<i>Vision Transformers</i>
WSI	<i>Whole-Slide Image</i>
XAI	<i>Explainable Artificial Intelligence</i>

Sumário

1	INTRODUÇÃO	14
1.1	Objetivo Geral	15
1.2	Objetivos Específicos	15
1.3	Organização do Trabalho	16
2	TRABALHOS RELACIONADOS	17
2.1	Abordagens Baseadas em WSI	17
2.2	Abordagens Baseadas em Patches	19
2.3	Limitações da Literatura e Lacunas de Pesquisa	20
3	FUNDAMENTAÇÃO TEÓRICA	22
3.1	Câncer de Próstata	22
3.1.1	Biópsia da Próstata	24
3.2	Sistema de Graduação Gleason	25
3.3	Processamento Digital de Imagens	28
3.4	Redes Neurais Artificiais	29
3.4.1	Multilayer Perceptron (MLP) e Backpropagation	30
3.5	Aprendizagem Profunda	31
3.5.1	Loss Function	32
3.5.1.1	Focal Loss	32
3.5.1.2	Ordinal Loss	32
3.5.2	Redes Neurais Convolucionais	33
3.5.3	EfficientNet e o Escalonamento Composto	34
3.6	Ensemble Learning	36
3.7	Métricas de Desempenho	38
4	MÉTODO PROPOSTO	40
4.1	Materiais	41
4.2	Pré-processamento	43
4.2.1	Filtragem de Ruído Baseada em Entropia	44
4.2.2	Extração de Patches	45
4.3	Treinamento e Modelos	46
4.4	Avaliação do Ensemble	47
5	RESULTADOS	49
5.1	Ambiente Experimental	49

5.2	Configuração de Hiperparâmetros	49
5.3	Impacto da Filtragem de Ruído e Funções de Perda	50
5.4	Comparação entre Arquiteturas EfficientNet	54
5.5	Avaliação do <i>Ensemble</i>	55
5.6	Comparação com trabalhos relacionados	56
5.7	Discussão	57
5.8	Estudo de Caso 1 - Erro clinicamente grave	58
5.9	Estudo de Caso 2 - Erro adjacente	59
5.10	Estudo de Caso 3 - Concordância unânime em lesão homogênea	60
5.11	Estudo de Caso 4 - Discordância entre modelos	61
6	CONCLUSÃO	63
6.1	Contribuições	63
6.2	Próximas Atividades	64
	REFERÊNCIAS	65

1 Introdução

O câncer de próstata é uma das neoplasias malignas mais comuns em homens, representando um desafio significativo para a saúde pública [Siegel, Giaquinto e Jemal 2024]. Estatísticas coletadas pela *International Agency for Research on Cancer* (IARC) indicam que, em 2022, essa neoplasia foi a quarta mais comum no mundo, correspondendo a 7,3% de todos os casos de câncer [Bray et al. 2024]. A graduação tumoral desempenha papel central na definição do manejo clínico e do prognóstico. O sistema de *Gleason*, baseado na soma dos dois padrões histológicos predominantes, evoluiu para o sistema de graduação da *International Society of Urological Pathology* (ISUP), que propõe uma classificação em cinco grupos prognósticos (1-5), com o objetivo de padronizar a interpretação dos escores de Gleason e melhorar a estratificação clínica [Epstein et al. 2016].

A avaliação histopatológica tradicional de imagens de lâminas inteiras (*Whole-Slide Images* - WSIs) depende da análise manual realizada por patologistas, sendo um processo sujeito à variabilidade inter e intraobservador [Bulten et al. 2020], além de demandar tempo e elevada especialização. Essas limitações têm impulsionado o desenvolvimento de métodos automatizados baseados em inteligência artificial, particularmente em aprendizado profundo, para apoiar a análise diagnóstica.

Em [Albahri et al. 2022], os autores realizaram uma revisão sistemática da literatura, que demonstrou um crescimento expressivo no uso de inteligência artificial na análise do câncer de próstata, evidenciando que as imagens médicas constituem a principal fonte de dados explorada, presente em mais da metade dos estudos investigados. Entre as abordagens predominantes, destacam-se técnicas de aprendizado profundo, de aprendizado de máquina e de *Convolutional Networks* (CNNs), aplicadas principalmente a tarefas de diagnóstico e classificação, com menor exploração em aplicações terapêuticas. De forma geral, os resultados indicam que sistemas baseados em Inteligência Artificial (IA) contribuem para reduzir a subjetividade diagnóstica, lidar com grandes volumes de dados e auxiliar especialistas na interpretação de exames clínicos e histopatológicos, reforçando o potencial dessas técnicas como ferramentas de apoio à decisão clínica.

Nesse contexto, CNNs têm apresentado desempenho destacado na análise de imagens médicas [Campanella et al. 2019], incluindo a graduação automatizada de padrões de Gleason e de graus ISUP [Nagpal et al. 2019, Bulten et al. 2020]. Entre as arquiteturas modernas, a família EfficientNet [Tan e Le 2019] oferece um equilíbrio favorável entre acurácia e custo computacional por meio da estratégia de *compound scaling* e do uso de blocos MBConv com mecanismos de *squeeze-and-excitation* [Hu,

[Shen e Sun 2018](#)]. Tais características tornam essas arquiteturas particularmente adequadas para tarefas envolvendo imagens histopatológicas de alta resolução.

Neste trabalho, investigamos a classificação automatizada dos graus ISUP por meio da avaliação de variantes da EfficientNet (B0, B3 e B7) no conjunto de dados PANDA [[PANDA Challenge 2020](#)]. São empregadas técnicas de *transfer learning*, estratégias de *fine-tuning*, técnicas avançadas de treinamento e métodos de *ensemble* para aumentar a robustez, a estabilidade e o desempenho dos modelos propostos.

1.1 Objetivo Geral

Investigar e avaliar métodos de aprendizado profundo para a classificação automatizada dos graus ISUP em câncer de próstata, utilizando variantes da arquitetura EfficientNet, com foco no aprimoramento da robustez, da estabilidade e do desempenho dos modelos.

1.2 Objetivos Específicos

Para alcançar o objetivo geral deste trabalho, faz-se necessário atingir os seguintes objetivos específicos:

- Propor e implementar uma função de perda híbrida denominada *Ordinal Focal Regression Loss*, que combine regressão ordinal e *Focal Loss*, explorando explicitamente a natureza hierárquica dos graus ISUP e mitigando o desbalanceamento entre classes presente no conjunto de dados PANDA;
- Desenvolver um método de filtragem de amostras ruidosas baseado na entropia de Shannon, utilizando um *ensemble* de modelos EfficientNet para identificar e remover instâncias de alta incerteza preditiva do conjunto de treinamento, melhorando a estabilidade e a capacidade de generalização dos modelos;
- Realizar uma análise sistemática e comparativa do desempenho das variantes EfficientNet-B0, B3 e B7 na tarefa de classificação dos graus ISUP;
- Propor e avaliar estratégias de *ensemble* as variantes EfficientNet, investigando diferentes métodos de combinação;
- Avaliar o desempenho dos modelos propostos por meio do Coeficiente Kappa Quadrático Ponderado, em conjunto com a acurácia e intervalos de confiança estimados via *bootstrap* não paramétrico, garantindo a confiabilidade estatística dos resultados obtidos.

1.3 Organização do Trabalho

Os demais capítulos deste trabalho estão organizados da seguinte forma:

- O Capítulo 2 apresenta uma revisão dos principais trabalhos relacionados à classificação automatizada do câncer de próstata por meio de técnicas de aprendizagem profunda;
- O Capítulo 3 aborda os conceitos teóricos fundamentais que servem de base para o desenvolvimento desta pesquisa;
- O Capítulo 4 descreve os materiais utilizados e as etapas do método proposto;
- O Capítulo 5 apresenta os resultados experimentais obtidos;
- Por fim, o Capítulo 6 apresenta as conclusões do trabalho, destacando as principais contribuições e as diretrizes propostas para pesquisas futuras.

2 Trabalhos Relacionados

A aplicação de técnicas de aprendizado profundo à classificação automatizada do câncer de próstata tem sido amplamente investigada na literatura, com avanços expressivos, particularmente no uso de imagens de lâminas histopatológicas completas, estratégias baseadas na extração de *patches* e mecanismos de agregação em múltiplas escalas. Esta seção apresenta uma revisão dos principais trabalhos relacionados, organizados de acordo com suas abordagens metodológicas.

2.1 Abordagens Baseadas em WSI

[Xiang et al. 2023](#) propuseram o framework *GCN-MIL* para diagnóstico e graduação do câncer de próstata em WSIs, baseado em aprendizado fracamente supervisionado com rótulos ao nível da lâmina. O método é estruturado em três etapas principais: (i) extração de *patches* a partir das WSIs e obtenção de representações por meio de uma *ResNet50* pré-treinada via aprendizado auto-supervisionado; (ii) modelagem das relações espaciais entre *patches* utilizando uma Rede Neural de Grafos (GCN), na qual cada instância é representada como um nó conectado a seus vizinhos; e (iii) agregação global das representações por meio de um mecanismo de atenção no contexto de *Multiple Instance Learning* (MIL), permitindo a predição do grau ISUP ao nível da lâmina. Adicionalmente, os autores incorporam uma estratégia de *Robust Training*, que realiza a filtragem iterativa de amostras de alta incerteza para mitigar o impacto de rótulos ruidosos. O modelo foi treinado no conjunto de desafio PANDA, com mais de 10 mil lâminas, e avaliado em cenários internos e externos multicêntricos, alcançando desempenho competitivo, com coeficiente Kappa quadrático de até 0,931 no conjunto interno.

Apesar dos resultados expressivos, a abordagem apresenta limitações relevantes. O método possui elevada complexidade computacional, envolvendo etapas custosas, como a extração de milhares de *patches* por WSI, a construção de grafos baseados em relações espaciais e o processamento por GCN, o que implica alto consumo de memória e tempo de processamento, dificultando sua aplicação em ambientes com recursos limitados. Outro ponto crítico refere-se à ausência de uma discussão explícita sobre a preservação da natureza ordinal dos graus ISUP no processo de treinamento. Embora o problema seja tratado como uma tarefa de classificação multiclasse, o trabalho não deixa claro se adotam-se mecanismos específicos para incorporar a estrutura hierárquica inerente à progressão da doença, o que pode limitar a capacidade do modelo de diferenciar adequadamente erros entre classes adjacentes e distantes.

[Arvaniti et al. 2018](#) propuseram um sistema automatizado para graduação do

câncer de próstata em WSIs de biópsias utilizando uma arquitetura Pyramidal CNN composta por três redes convolucionais operando em diferentes escalas de *patch*, permitindo capturar características morfológicas em múltiplos níveis de contexto espacial. O pipeline de processamento incluiu equalização de histograma para normalização de intensidade, extração de patches a partir das WSIs e seleção com base na proporção mínima de tecido presente, seguida de classificação *patch-wise* dos padrões de Gleason (ISUP 1-ISPU 5) e agregação das probabilidades para inferência do *Gleason Score* e dos *Grade Groups*. O conjunto experimental foi composto por 896 lâminas inteiras de biópsias prostáticas (750 para treinamento, 96 para validação e 50 para teste), fornecidas pelo *Radboud University Medical Center* e analisadas no *University of Louisville Hospital*, com rotulagem semi-automática realizada por patologistas especialistas. Os experimentos geraram milhões de *patches* multiescala para treinamento das redes, e os resultados indicaram acurácia de aproximadamente 0,77 na classificação dos padrões, além de desempenho na identificação dos grupos prognósticos com recall entre 50% e 75% e precisão entre 50% e 69%, comparável ao desempenho humano em cenários similares. Contudo, o método apresenta limitações relacionadas ao uso de rotulação semiautomática, à ausência de validação externa independente, ao desempenho moderado em classes de maior complexidade e à dependência da estratégia de seleção de *patches*, fatores que restringem a avaliação de generalização clínica e de robustez em ambientes multi-institucionais.

[Bhattacharyya et al. 2024](#) propôs dois métodos complementares para a graduação ISUP de câncer de próstata a partir de WSIs. O primeiro consiste em um ensemble hierárquico de CNNs (*Multi-CNN Ensemble*), no qual um modelo global M_1 , treinado via MIL (*Multiple Instance Learning*) com regressão ordinal, realiza uma classificação inicial da WSI. A partir da análise dos pares de graus com o maior índice de confusão e os autores treinaram modelos especializados nos subconjuntos de graus confusos, com diferentes tamanhos de *patch* (192×192 , 224×224 e 256×256). A predição final é obtida por meio de uma estratégia de decisão em cascata entre os modelos globais e especializados. O segundo método (*Bag-of-CNN Features*) utiliza as representações extraídas por modelos CNN treinados para gerar, por meio de *k*-means, um descritor global para WSI, que alimenta classificadores baseados em árvores de decisão com *gradient boosting* (XGBoost e LGBM). Ambos os métodos adotam o EfficientNet-B1 como *backbone* e são avaliados no dataset PANDA, no qual o *Multi-CNN Ensemble* alcançou kappa de 0,881.

[Kabir et al. 2025](#) propuseram um framework de três estágios que integra classificação e segmentação em nível de patch para a predição do grau ISUP a partir de WSIs. Após uma etapa de limpeza de dados, patches de dois tamanhos distintos (500x500 e 1000x1000 *pixels*) foram extraídos para alimentar as redes de classificação e de segmentação. No primeiro estágio, modelos de classificação baseados em EfficientNet-b0,

DenseNet121, Inception-v3 e Vision Transformer foram treinados para classificar os *patches* em quatro classes: benigno, Gleason 3, Gleason 4 e Gleason 5. No segundo estágio, uma arquitetura de segmentação semântica DeepLabV3+, com codificador EfficientNet-B0 e camadas convolucionais substituídas por redes neurais operacionais auto-organizáveis (Self-ONN), foi proposta para a delimitação *pixel a pixel* de cada padrão histológico. No terceiro estágio, as proporções de cada padrão de Gleason nas WSIs foram concatenadas em vetores de características para o treinamento de classificadores de aprendizado de máquina. O classificador Random Forest, treinado com a combinação de características provenientes de ambas as abordagens e de ambos os tamanhos de patch, obteve o melhor kappa quadrático de 0,921 no *dataset* PANDA. Apesar dos resultados promissores, o estudo apresenta uma limitação metodológica importante ao descartar as imagens do Instituto *Karolinska*. A utilização exclusiva de dados de uma única instituição (*Radboud*) impede a validação externa do modelo, restringindo a sua capacidade de generalização para dados inéditos e, consequentemente, limitando a sua viabilidade para adoção na prática clínica.

Bhattacharyya, Pal e Mitra 2026 propuseram o TSOR (*Task-Specific Ordinal Regression*), um *framework* composto por três módulos integrados. No primeiro, um modelo híbrido de MIL gera pseudo-rótulos em nível de *patch*, produzindo um conjunto de dados relativamente balanceado entre os graus de Gleason no pré-treinamento. No segundo, esse conjunto é utilizado em um *framework* de aprendizado auto-supervisionado específico para a tarefa, com um termo de perda adicional baseado em augmentação de coloração, permitindo o aprendizado de características morfológicas invariantes à variação de *stain* entre os centros. No terceiro módulo, a rede pré-treinada é ajustada para a graduação ISUP por meio de regressão ordinal, na qual os rótulos são codificados de modo que a distância entre as classes reflita sua ordenação clínica. Avaliado nos conjuntos PANDA e SICAPv2, o método atingiu kappa de 0,884 e 0,874, respectivamente, superando abordagens SOTA baseadas em MIL e modelos de fundação histopatológicos.

2.2 Abordagens Baseadas em Patches

No trabalho de Kosoko et al. 2024, os autores avaliaram diferentes arquiteturas de redes neurais convolucionais, combinadas com técnicas de *Explainable Artificial Intelligence* (XAI), em especial *Grad-CAM*, para a interpretação das decisões do modelo. O conjunto de dados utilizado foi o SICAPv2. Entre as arquiteturas avaliadas, o modelo VGG19 apresentou o melhor desempenho, alcançando AUC-ROC de 0,85 e valores médios próximos de 0,75 para acurácia, precisão e *recall*, enquanto uma CNN simples apresentou desempenho significativamente inferior (acurácia $\approx 0,41$ e F1 $\approx 0,24$), evidenciando a vantagem de arquiteturas profundas pré-treinadas na captura de padrões morfológicos complexos associados aos graus de Gleason. O estudo apresenta limitações

relacionadas à ausência de validação clínica externa, à dependência de um único conjunto de dados e à exploração restrita de técnicas de XAI, o que limita a avaliação de generalização em cenários interinstitucionais.

[Alici-Karaca e Akay 2024](#) propuseram um modelo de aprendizado profundo para diagnóstico e graduação do câncer de próstata utilizando imagens histopatológicas do dataset público DiagSet. O processamento foi realizado em *patches* extraídos de lâminas digitalizadas coradas em H&E. A abordagem baseou-se na arquitetura EfficientNet-B4 e em uma variante denominada Eff4-Attn, que incorpora um mecanismo de atenção de canais para aprimorar a extração de características morfológicas. O modelo foi avaliado em diferentes níveis de granularidade: uma classificação em quatro classes (tecido normal, estroma, alterações benignas e câncer) e outra em oito classes (tecido normal, estroma, artefatos, inflamação, hiperplasia benigna, Gleason 3, Gleason 4 e Gleason 5). Os resultados alcançaram acurácia de 96,18% na tarefa binária, 94,86% na classificação em quatro classes e 93,32% na classificação em oito classes, demonstrando desempenho competitivo aliado à eficiência computacional. Contudo, o estudo apresenta limitações relacionadas ao uso exclusivo de *patches* em vez de inferência em nível de lâmina completa, à dependência de um único conjunto de dados público e ao desbalanceamento entre as classes, fatores que restringem a avaliação da generalização clínica e da robustez do método em cenários multi-institucionais.

No estudo de [Ikromjanov et al. 2021](#), a análise de imagens histopatológicas de próstata foi conduzida por meio de um modelo baseado em *Vision Transformers* (ViT), com o objetivo de classificar padrões teciduais associados ao sistema de graduação de Gleason a partir de WSI. O conjunto de dados utilizado deriva do desafio público PANDA, sendo empregado um subconjunto com mais de 5.000 imagens na experimentação. Após a detecção das regiões de interesse, as lâminas foram particionadas em aproximadamente 304 mil *patches* de dimensões 256×256 pixels, rotuladas em cinco classes (estroma, benigno, Gleason 3, Gleason 4 e Gleason 5), com cerca de 240 mil amostras destinadas ao treinamento, 60 mil à validação e 4 mil ao teste. O modelo ViT foi utilizado para classificação em nível de *patch* e para inferência em nível de lâmina, com predições agregadas. Os resultados experimentais demonstraram desempenho competitivo na identificação de padrões histológicos, alcançando acurácia superior a 85% na classificação dos *patches*, evidenciando a capacidade do mecanismo de atenção de capturar dependências contextuais globais nas imagens.

2.3 Limitações da Literatura e Lacunas de Pesquisa

Apesar dos avanços no uso de aprendizado profundo na análise de imagens histopatológicas de próstata, persistem limitações relevantes. Muitos trabalhos tratam o problema como uma classificação nominal, ignorando a natureza ordinal dos graus ISUP,

o que penaliza erros de forma uniforme e desalinha o modelo em relação à relevância clínica. Além disso, há forte dependência de arquiteturas convolucionais e de estratégias baseadas em *patches*, sem tratamento robusto de ruído e incerteza, o que é agravado por artefatos, inconsistências nas anotações e variabilidade entre instituições em *datasets* como o PANDA.

Outra limitação é o uso predominante de classificadores individuais, com pouca exploração de *ensembles*, além da dificuldade em capturar relações hierárquicas entre graus tumorais. Para enfrentar essas lacunas, este trabalho propõe um pipeline que combina a filtragem por entropia, a modelagem ordinal com *Focal Loss* e um *ensemble* de variantes do EfficientNet, visando maior robustez, estabilidade e coerência clínica nas predições.

3 Fundamentação Teórica

Este capítulo apresenta o embasamento teórico necessário à compreensão dos conceitos explorados neste trabalho. Inicialmente, abordam-se os aspectos clínicos e histopatológicos do câncer de próstata, com foco no sistema de graduação de Gleason. Em seguida, descreve-se a evolução da Inteligência Artificial (IA) e do *Deep Learning* no contexto da Patologia Digital, destacando como essas tecnologias transformaram a análise de lâminas histológicas. Adicionalmente, detalha-se a arquitetura *EfficientNet*, selecionada por sua eficácia no equilíbrio entre profundidade, largura e resolução na classificação de imagens médicas. Por fim, apresenta-se o conceito de Regressão Ordinal, uma abordagem estatística e computacional fundamental para problemas de classificação em que as categorias possuem uma ordem intrínseca de gravidade, como é o caso dos graus histopatológicos do câncer de próstata.

3.1 Câncer de Próstata

A próstata é um órgão do sistema reprodutor masculino, localizado inferiormente à bexiga e circundando a uretra proximal, conforme ilustrado na Figura 1. Anatomicamente, encontra-se próxima às vesículas seminais e aos ductos ejaculatórios. Sua principal função biológica consiste na produção e secreção de fluidos que compõem o sêmen, contribuindo para a nutrição, a proteção e a viabilidade dos espermatozoides [Rebello et al. 2021]. Alterações genéticas nas células epiteliais prostáticas podem levar à perda do controle do ciclo celular, resultando em proliferação celular desordenada e no desenvolvimento do câncer de próstata [Rebello et al. 2021].

Globalmente, o câncer de próstata permanece como a segunda neoplasia maligna mais diagnosticada entre homens e a quinta principal causa de morte por câncer no mundo, apresentando uma incidência que varia substancialmente entre diferentes regiões geográficas [Rawla 2019]. Essa variabilidade reflete uma complexa interação entre predisposição genética, fatores ambientais, estilo de vida e condições socioeconômicas [Bergengren et al. 2023].

Diversos fatores de risco têm sido associados ao desenvolvimento do câncer de próstata. Entre os mais bem estabelecidos, destacam-se a idade avançada, o histórico familiar positivo e os fatores genéticos. Além desses, outros fatores relacionados ao estilo de vida, como obesidade, padrões alimentares e níveis reduzidos de atividade física, também têm sido investigados como potenciais contribuintes para o desenvolvimento e progressão da doença [Bergengren et al. 2023, Perdana et al. 2016].

A Tabela 1 apresenta um resumo dos principais fatores de risco associados ao




Figura 1 – Localização da Glândula Prostática

Fonte: Adaptado de [National Cancer Institute 2024]

câncer de próstata descritos na literatura, incluindo fatores demográficos, genéticos, comportamentais e ambientais.

Do ponto de vista anatômico e clínico, a localização tumoral na próstata constitui um importante fator prognóstico. Aproximadamente 70-80% dos carcinomas prostáticos originam-se na zona periférica, região que pode ser acessada por meio do exame de toque retal, permitindo a identificação de alterações suspeitas durante a avaliação clínica. Em contraste, tumores originados na zona de transição ou na zona central são menos frequentes [Hammerich, Ayala e Wheeler 2009]. O adenocarcinoma acinar, principal subtipo histológico da doença, caracteriza-se por evolução lenta e frequentemente assintomática em estágios iniciais. Com a progressão tumoral e eventual comprometimento da uretra prostática ou do colo vesical, podem surgir sintomas urinários obstrutivos ou irritativos, que frequentemente se sobrepõem às manifestações clínicas da hiperplasia prostática benigna (HPB), dificultando a distinção clínica entre essas condições [Crawford 2003, Rawla 2019].

O diagnóstico do câncer de próstata baseia-se tradicionalmente na combinação entre a dosagem sérica do *Prostate Specific Antigen* (PSA), o exame de toque retal e a confirmação histopatológica por biópsia prostática.

Tabela 1 – Principais fatores de risco associados ao câncer de próstata

Fator de risco	Descrição
Idade	O risco aumenta significativamente após os 50 anos, sendo mais comum em homens acima de 65 anos.
Histórico familiar	Homens com parentes de primeiro grau com câncer de próstata apresentam maior risco de desenvolver a doença.
Fatores genéticos	Mutações em genes como <i>BRCA1</i> , <i>BRCA2</i> e <i>HOXB13</i> estão associadas ao aumento do risco.
Etnia	Homens afrodescendentes apresentam maior incidência e mortalidade pela doença.
Obesidade	Associada a formas mais agressivas do câncer de próstata e a pior prognóstico clínico.
Dieta	Dietas ricas em gordura animal e pobres em frutas, vegetais e fibras podem aumentar o risco.
Sedentarismo	A baixa prática de atividade física pode contribuir para alterações metabólicas associadas ao desenvolvimento da doença.
Exposição ocupacional	Exposição a pesticidas ou outras substâncias químicas podem aumentar o risco em determinadas populações.

3.1.1 Biópsia da Próstata

A biópsia prostática é o exame padrão para confirmar o câncer de próstata, pois permite a análise histopatológica do tecido suspeito. O procedimento é geralmente realizado com auxílio da ultrassonografia transretal (*Transrectal Ultrasound* - TRUS), que permite a visualização da próstata em tempo real e o direcionamento preciso da agulha de coleta [Matlaga, Eskew e McCullough 2003]. Na Figura 2 pode-se visualizar uma ilustração do procedimento.

A indicação da biópsia baseia-se principalmente em níveis elevados de PSA e em alterações detectadas no exame de toque retal. Embora valores de PSA acima de 4,0 ng/ml sejam tradicionalmente utilizados como referência para investigação, níveis entre 2,5 e 4,0 ng/ml também podem justificar a realização do procedimento em determinados pacientes [Matlaga, Eskew e McCullough 2003].

Durante o procedimento, são coletados pequenos fragmentos de tecido prostático, denominados *cores*. Inicialmente, utilizava-se o protocolo de sextante, que coletava seis fragmentos da glândula. Entretanto, devido à possibilidade de resultados falso-negativos, protocolos estendidos passaram a ser adotados, com a coleta sistemática de 10 a 12 fragmentos distribuídos nas regiões base, média e ápice da próstata [Matlaga, Eskew e McCullough 2003]. Esses fragmentos são posteriormente analisados por patologistas para identificar a presença de carcinoma.




Figura 2 – Ilustração de biópsia com auxílio de TRUS.
Fonte: [Neumaier 2023].

3.2 Sistema de Gradação Gleason

A avaliação histopatológica desempenha papel central no manejo clínico do câncer de próstata, uma vez que o grau de diferenciação tumoral está diretamente associado ao prognóstico da doença e à escolha da estratégia terapêutica. Nesse contexto, o sistema de gradação de Gleason é um dos métodos mais amplamente utilizados para caracterizar a agressividade do adenocarcinoma prostático [Epstein et al. 2016].

O sistema de Gleason foi originalmente desenvolvido nas décadas de 1960 e 1970 pelo patologista Dr. Donald Gleason, com base em um estudo prospectivo conduzido pela *Veterans Administration* nos Estados Unidos, envolvendo mais de 2.900 pacientes. O objetivo do estudo era investigar a relação entre os padrões arquiteturais de crescimento do adenocarcinoma prostático, o estágio clínico da doença e os desfechos prognósticos observados nos pacientes. Os resultados desse trabalho fundamentaram a criação do sistema de classificação que posteriormente foi incorporado às classificações oficiais da Organização Mundial da Saúde (OMS) [Chen e Zhou 2016].

O modelo clássico descreve cinco padrões histológicos arquiteturais distintos,

numerados de 1 a 5, que correspondem a diferentes níveis de diferenciação tumoral. O padrão 1 corresponde a tumores altamente diferenciados, geralmente associados a melhor prognóstico, enquanto o padrão 5 representa neoplasias pouco diferenciadas e de comportamento biológico mais agressivo. Como tumores prostáticos frequentemente apresentam heterogeneidade morfológica, foi introduzido o escore de Gleason, obtido pela soma dos dois padrões histológicos mais prevalentes observados na amostra tumoral (por exemplo, 3+4=7). Essa abordagem demonstrou maior correlação com o comportamento biológico do tumor e com os desfechos clínicos quando comparada à avaliação isolada de um único padrão histológico [Chen e Zhou 2016].

Na descrição original, o padrão 1 era caracterizado por glândulas pequenas, uniformes e bem delimitadas pelo estroma adjacente. Entretanto, estudos posteriores indicaram que tal morfologia é raramente observada em carcinomas prostáticos verdadeiros. O padrão 3, atualmente o mais frequentemente identificado em biópsias prostáticas, caracteriza-se por glândulas neoplásicas individualizadas infiltrando o estroma. Já o padrão 4 é definido pela presença de fusão glandular, estruturas cribriformes ou glândulas malformadas, enquanto o padrão 5 corresponde a tumores com crescimento sólido, necrose ou células isoladas, sem formação glandular definida [Chen e Zhou 2016].

Com o avanço do conhecimento em biologia tumoral e o aprimoramento das técnicas diagnósticas, revisões importantes foram realizadas no sistema de Gleason, especialmente após o consenso da ISUP em 2005. Entre as principais modificações destacam-se a virtual eliminação do padrão 1, a restrição do padrão 2, a reclassificação de determinadas arquiteturas cribriformes¹ como padrão 4 e o estabelecimento de critérios mais rigorosos para a identificação de necrose² do tipo comedo³ no padrão 5. Essas mudanças contribuíram significativamente para aumentar a reprodutibilidade diagnóstica e aprimorar a correlação prognóstica do sistema [Chen e Zhou 2016].

Posteriormente, em 2014, um novo consenso internacional introduziu um sistema prognóstico complementar baseado em grupos de grau, que atualmente está incorporado às classificações da Organização Mundial da Saúde. Esse sistema reorganiza os escores de Gleason em cinco categorias prognósticas, permitindo uma comunicação clínica mais clara e uma estratificação de risco mais precisa [Epstein et al. 2016]:

- Grupo 1: escore ≤ 6
- Grupo 2: escore 3+4=7

¹ Termo médico e anatômico utilizado para descrever uma estrutura que possui múltiplos pequenos orifícios ou perfurações, assemelhando-se a uma peneira ou crivo.

² Morte prematura e descontrolada de células ou tecidos vivos, provocada por agentes patológicos como isquemia (falta de sangue), infecções, traumas ou toxinas.

³ Forma específica de necrose caracterizada pela presença de material necrótico central dentro de estruturas glandulares ou ductais.

- Grupo 3: $\text{escore } 4+3=7$
- Grupo 4: $\text{escore } 8$
- Grupo 5: $\text{escores } \geq 9$

A Figura 3 apresenta uma representação esquemática da correspondência entre os padrões arquiteturais do sistema de Gleason e os respectivos grupos prognósticos. Observa-se um gradiente progressivo de desorganização tecidual à medida que o grau tumoral aumenta. Nos padrões de menor grau, as glândulas apresentam morfologia relativamente preservada e limites bem definidos em relação ao estroma adjacente. À medida que o padrão evolui, verifica-se uma crescente desorganização estrutural, caracterizada por margens infiltrativas, fusão glandular e formação de estruturas irregulares. No padrão 5, associado ao maior risco de progressão tumoral e de metástase, ocorre perda quase completa da arquitetura glandular original, o que reflete um carcinoma altamente agressivo e de rápida evolução.









Propriedades	Padrão de Gleason e Grupo de Grau	Imagens Histológicas	Fator de Risco
Glândulas pequenas e uniformes	 1		Baixo: câncer de crescimento lento; menos chance de disseminação
Mais estroma entre as glândulas	 2		Intermediário: maior chance de disseminação
Margens distintamente infiltrativas	 3		Intermediário: maior chance de disseminação
Massas irregulares de glândulas neoplásicas	 4		Alto: câncer de crescimento rápido; alta chance de disseminação
Glândulas mal formadas ou ocasionalmente formadas	 5		Mais alto: câncer de crescimento rápido; alta chance de disseminação

Figura 3 – Representação esquemática dos padrões arquiteturais do sistema de Gleason e sua correspondência aos grupos prognósticos (Grade Groups). Adaptado de [Hossain et al. 2025].

3.3 Processamento Digital de Imagens

Segundo [Gonzalez e Woods 2008], uma imagem pode ser definida como uma função bidimensional $f(x, y)$, em que x e y representam as coordenadas espaciais no plano da imagem e o valor de $f(x, y)$ corresponde à intensidade luminosa ou ao nível de cinza do pixel. Sendo assim, uma imagem é representada como uma matriz de *pixels*, onde cada *pixel* possui um valor numérico que representa sua intensidade ou cor, como pode ser observado através da Figura 4. Neste contexto, o Processamento Digital de Imagens (PDI) diz respeito ao conjunto de técnicas computacionais utilizadas para manipular, analisar e extrair informações de imagens digitais, atuando sobre seus valores para realizar transformações ou obter conhecimento a partir deles.




Figura 4 – Ilustração da forma de uma imagem digital.

As operações de PDI podem ser organizadas em diferentes níveis de abstração. Gonzalez e Woods [Gonzalez e Woods 2008] distinguem três níveis principais: o baixo nível, que envolve operações primitivas como redução de ruído, realce de contraste e nitidez, atuando diretamente sobre os valores dos *pixels*; o nível intermediário, que abrange tarefas como segmentação e extração de atributos; e o alto nível, voltado à interpretação semântica das informações extraídas, frequentemente associado à visão computacional. Essa hierarquia evidencia que o PDI não se limita à simples manipulação de imagens, mas constitui a base técnica sobre a qual sistemas de reconhecimento e análise automática são construídos.

Na área médica, o PDI desempenha papel fundamental ao viabilizar a análise automatizada de imagens clínicas e laboratoriais, como campos de lâminas histológicas [Gonzalez e Woods 2008]. Nesse contexto, técnicas de pré-processamento, segmentação e extração de características permitem identificar estruturas de interesse com precisão e reprodutibilidade superiores à análise manual, o que reduz a subjetividade do examinador e o tempo de diagnóstico. Em particular, a análise de imagens microscópicas representa um campo onde o PDI encontra aplicação direta, uma vez que a identificação de células, ou outras estruturas biológicas em lâminas demanda a detecção de padrões morfológicos sutis em meio a fundos complexos e variáveis. Assim, o PDI se torna uma ferramenta essencial na construção de sistemas automatizados de auxílio ao diagnóstico.

3.4 Redes Neurais Artificiais

As Redes Neurais Artificiais (RNA) são modelos matemáticos inspirados na estrutura biológica do cérebro humano e são compostos por unidades funcionais simples, interconectadas e que operam como processadores paralelos de informação [Sengupta et al. 2020]. Sua unidade fundamental de processamento é o neurônio artificial, que combina um conjunto de entradas para gerar uma saída única, cujo comportamento é descrito pela equação apresentada na Figura 5.




Figura 5 – Representação matemática do modelo de um neurônio artificial.

Na Figura 5, x_i representa a entrada i , w_i o peso associado, b é o termo de *bias* (viés) e f a função de ativação. As funções de ativação são responsáveis por introduzir não linearidade no modelo, sendo determinantes para sua capacidade de aprendizado. Embora funções como a sigmóide e a tangente hiperbólica tenham sido amplamente empregadas, as funções *Rectified Linear Units* (ReLU) e sua variante *Leaky ReLU* tornaram-se predominantes por proporcionarem maior velocidade de convergência durante o treinamento [Maas, Hannun e Ng 2013]. Essas funções são definidas pelas Equações 3.1 e 3.2, respectivamente:

$$\sigma(x) = \max(0, x) \quad (3.1)$$

$$\sigma(x) = \max(0.1, x) \quad (3.2)$$

3.4.1 Multilayer Perceptron (MLP) e Backpropagation

O *Multilayer Perceptron* (MLP) é uma arquitetura clássica de RNA formada por múltiplas camadas de neurônios totalmente conectadas. Uma representação dessa arquitetura pode ser observada na Figura 6. A rede é organizada em três componentes principais: uma camada de entrada, responsável por receber os dados brutos; uma ou mais camadas ocultas, que extraem representações intermediárias por meio de transformações não lineares sucessivas; e uma camada de saída, responsável por produzir a inferência final do modelo. Essa arquitetura em camadas permite que a rede aprenda relações complexas e não lineares entre as variáveis de entrada e saída [Goodfellow, Bengio e Courville 2016].




Figura 6 – Representação da arquitetura do Multilayer Perceptron (MLP).

O treinamento do MLP ocorre, na maioria dos casos, de forma supervisionada por meio do algoritmo de *backpropagation*. Nesse processo, os pesos da rede são ajustados iterativamente para reduzir o erro entre as saídas do modelo e os valores esperados. Para isso, o erro calculado na camada de saída é propagado de volta às camadas anteriores, permitindo que cada neurônio contribua para o ajuste dos parâmetros da rede [Rumelhart, Hinton e Williams 1986].

Durante o treinamento, os pesos w_{ij} são atualizados a cada iteração t de acordo com a equação 3.3:

$$w_{ij}(t+1) = w_{ij}(t) + \eta \delta_j x_i \quad (3.3)$$

Onde η representa a taxa de aprendizado, responsável por controlar o *score* de ajuste aplicado aos pesos; δ_j corresponde ao termo de erro do neurônio j ; e x_i representa a entrada do neurônio i .

No caso dos neurônios localizados na camada de saída, o termo de erro é calculado a partir da diferença entre a saída desejada d_j e a saída produzida pela rede y_j , conforme equação 3.4:

$$\delta_j = y_j(1 - y_j)(d_j - y_j) \quad (3.4)$$

Já nas camadas ocultas, o erro não é diretamente observado. Nesses casos, ele é obtido a partir da retropropagação dos erros provenientes das camadas subsequentes (k), de acordo com a equação 3.5:

$$\delta_j = x_j(1 - x_j) \sum_k \delta_k w_{jk} \quad (3.5)$$

A partir desse mecanismo de propagação do erro e ajuste iterativo dos pesos, a rede passa gradualmente a aprender representações internas dos dados, o que permite melhorar seu desempenho ao longo do processo de treinamento.

3.5 Aprendizagem Profunda

A Aprendizagem Profunda (*Deep Learning*) é um subcampo da aprendizagem de máquina que utiliza modelos computacionais compostos por múltiplas camadas de processamento para aprender representações hierárquicas dos dados, capturando diferentes níveis de abstração. Esses modelos, geralmente baseados em redes neurais artificiais profundas, têm apresentado desempenho significativo em diversas aplicações, como reconhecimento de fala, reconhecimento de objetos em imagens, processamento de linguagem natural e detecção de padrões complexos em grandes volumes de dados [LeCun, Bengio e Hinton 2015].

Nas abordagens tradicionais de aprendizagem de máquina, há uma forte dependência da etapa de engenharia de características (*feature engineering*), na qual especialistas do domínio precisam projetar manualmente as representações dos dados a serem utilizadas pelo modelo. Esse processo envolve a seleção, transformação e extração de atributos relevantes, o que pode demandar grande esforço e conhecimento específico sobre o problema analisado.

Em contraste, a aprendizagem profunda reduz essa dependência ao permitir que os próprios modelos aprendam automaticamente representações relevantes diretamente a partir dos dados brutos. Por meio de múltiplas camadas de transformação não linear, as

redes profundas conseguem extrair características de baixo, médio e alto nível, tornando o processo de aprendizado mais automatizado e, frequentemente, mais eficiente em tarefas complexas de visão computacional, reconhecimento de padrões e análise de grandes conjuntos de dados.

3.5.1 Loss Function

A função de perda (*loss function*) é um componente fundamental no treinamento de modelos de aprendizagem profunda, pois quantifica a discrepância entre as previsões do modelo e os rótulos reais. Essa medida de erro orienta o processo de otimização, permitindo ajustar os pesos da rede por meio do algoritmo de *backpropagation* para minimizar o custo global empírico. Embora a entropia cruzada (*cross-entropy*) seja a métrica padrão para classificação multiclasse, cenários do mundo real frequentemente apresentam distribuições de dados severamente desequilibradas ou categorias com ordem intrínseca, o que exige funções de perda especializadas para evitar um ajuste subótimo das fronteiras de decisão.

3.5.1.1 Focal Loss

A *Focal Loss* foi projetada especificamente para mitigar o viés decorrente do desequilíbrio extremo entre as classes, um desafio recorrente na classificação de dados raros e de anomalias [Al-Turaiqi et al. 2021]. Sua formulação matemática, para um problema de classificação binária, é definida como:

$$\mathcal{L}_{\text{focal}} = -\alpha_t(1 - p_t)^\gamma \log(p_t) \quad (3.6)$$

onde p_t representa a probabilidade predita para a classe verdadeira, $\alpha_t \in [0, 1]$ é um fator de balanceamento entre classes, e $\gamma \geq 0$ é o parâmetro de focalização que controla a atenuação das amostras fáceis. Para $\gamma = 0$, a função se reduz à entropia cruzada tradicional. À medida que γ aumenta, o termo $(1 - p_t)^\gamma$ reduz progressivamente a contribuição de exemplos bem classificados ($p_t \rightarrow 1$), concentrando o aprendizado em amostras difíceis e em classes minoritárias [Lin et al. 2022]. Dessa forma, a *Focal Loss* evita que o gradiente seja dominado por classes predominantes, favorecendo uma melhor generalização em cenários com distribuições desbalanceadas.

3.5.1.2 Ordinal Loss

Em muitos problemas de diagnóstico e análise, as classes não são mutuamente independentes, mas representam uma escala contínua de progressão (como estágios de uma anomalia ou graus de uma patologia), caracterizando um problema de regressão ordinal [Baccianella, Esuli e Sebastiani 2020]. Nesses contextos, tratar os rótulos como

categorias nominais isoladas descarta informações estruturais essenciais. Um erro de predição entre graus distantes na escala possui um impacto significativamente maior do que erros entre classes adjacentes. Para incorporar essa estrutura ordinal no processo de otimização, pode-se definir explicitamente uma função de perda sensível à distância entre classes.

Uma formulação prática da *Ordinal Loss* baseia-se na comparação entre a classe esperada predita pelo modelo e a classe alvo real. Seja $\mathbf{p} = (p_1, p_2, \dots, p_K)$ o vetor de probabilidades preditas após a função de ativação, e $\mathbf{y} = (y_1, y_2, \dots, y_K)$ a codificação ordinal do rótulo verdadeiro. A classe esperada predita pode ser definida como:

$$\hat{c} = \sum_{k=1}^K p_k \quad (3.7)$$

De forma análoga, a classe alvo é dada por:

$$c = \sum_{k=1}^K y_k \quad (3.8)$$

A *Ordinal Loss* é então definida como a diferença absoluta normalizada entre essas duas quantidades:

$$\mathcal{L}_{ordinal} = \frac{1}{K-1} |\hat{c} - c| \quad (3.9)$$

Para um conjunto de N amostras, a função de perda média é dada por:

$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^N \frac{|\hat{c}_i - c_i|}{K-1} \quad (3.10)$$

Essa formulação penaliza diretamente a distância entre a classe prevista e a classe real, garantindo que erros mais distantes na escala ordinal resultem em penalizações maiores. Dessa forma, o modelo é incentivado a aprender representações que respeitam a estrutura hierárquica dos rótulos, promovendo previsões mais coerentes do ponto de vista ordinal. Adicionalmente, abordagens como a *Ordinal Focal Loss* estendem essa ideia ao incorporar mecanismos de reponderação dinâmica inspirados na *Focal Loss*, permitindo lidar simultaneamente com a estrutura ordinal e o desbalanceamento de classes [Al-Turaiki et al. 2021].

3.5.2 Redes Neurais Convolucionais

As Redes Neurais Convolucionais (*Convolutional Neural Networks* — CNNs) constituem uma classe de modelos de aprendizado profundo projetadas especificamente

para o processamento de dados com estrutura espacial regular, como imagens digitais. A arquitetura típica de uma CNN intercala camadas convolucionais com camadas de subamostragem (*pooling*), responsáveis por reduzir a dimensionalidade espacial, e é finalizada por uma ou mais camadas totalmente conectadas destinadas à tarefa de classificação ou regressão. A Figura 7 apresenta a representação de uma CNN. A composição hierárquica das camadas convolucionais permite que o modelo aprenda representações progressivamente mais abstratas, sendo que, as camadas iniciais tendem a capturar características de baixo nível, como bordas e texturas, enquanto as camadas mais profundas codificam estruturas semânticas mais complexas [LeCun et al. 1998, Goodfellow, Bengio e Courville 2016].




Figura 7 – Representação de uma Rede Neural Convolucional (CNN).

No domínio da medicina, as CNNs têm se destacado como potenciais ferramentas para análises clínicas, promovendo avanços no que diz respeito a diagnósticos assistidos por computador. Sua capacidade de extrair características relevantes de forma automática, a partir de imagens complexas, as torna particularmente úteis para tarefas onde o processo de execução é laborioso e demanda tempo, foco e repetição. Estudos comparativos demonstraram que modelos baseados em CNNs alcançam desempenho equivalente ou superior ao de especialistas humanos em tarefas específicas de reconhecimento visual médico, como na classificação de lesões dermatológicas [Esteve et al. 2017]. Neste contexto, é possível afirmar que esses modelos podem ser utilizados para auxiliar na análise e classificação de lâminas histopatológicas de câncer de próstata, a fim de promover diagnósticos mais rápidos e precisos, o que influenciará positivamente no tratamento e manejo do paciente.

3.5.3 EfficientNet e o Escalonamento Composto

O *EfficientNet*, proposto por [Tan e Le 2019], introduz uma abordagem sistemática para o escalonamento de Redes Neurais Convolucionais profundas. Diferentemente de métodos tradicionais, que ampliam apenas uma dimensão da rede, como a profundidade ou a largura, o EfficientNet propõe um método de escalonamento composto (*compound*

scaling), no qual múltiplas dimensões da arquitetura são ampliadas de forma conjunta e balanceada.

Especificamente, o método considera três dimensões principais da rede: profundidade (d), largura (w) e resolução da imagem de entrada (r). O escalonamento é controlado por um coeficiente composto ϕ , que determina o nível global de ampliação do modelo. A partir desse coeficiente, as três dimensões são escaladas segundo as seguintes relações:

$$\begin{aligned} \text{profundidade: } d &= \alpha^\phi \\ \text{largura: } w &= \beta^\phi \\ \text{resolução: } r &= \gamma^\phi \end{aligned} \quad (3.11)$$

onde α , β e γ são constantes positivas determinadas empiricamente por meio de uma busca em um pequeno espaço de arquiteturas, sujeitas à restrição $\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$, garantindo que o custo computacional aumente de forma controlada a cada incremento de ϕ .

Como ilustrado na Figura 8, esse mecanismo de escalonamento composto ajusta a largura (número de canais), a profundidade (número de camadas) e a resolução (dimensão da entrada) de forma proporcional. Essa abordagem permite aumentar a capacidade representacional da rede de maneira significativamente mais eficiente, alcançando um melhor desempenho preditivo com um menor número de parâmetros e um custo computacional reduzido, quando comparada aos métodos tradicionais de escalonamento unidimensional.




Figura 8 – Comparação entre diferentes métodos de escalonamento.

Adaptado de [Tan e Le 2019].

A arquitetura base, denominada EfficientNet-B0, foi obtida por meio de *Neural Architecture Search* (NAS). A partir dessa arquitetura inicial, modelos maiores, EfficientNet-

B1 até EfficientNet-B7, são gerados aplicando-se progressivamente o coeficiente de escalonamento ϕ , resultando em redes com diferentes compromissos entre precisão e custo computacional. A Tabela 2 apresenta uma comparação entre as variantes do EfficientNet e arquiteturas clássicas, evidenciando a eficiência do método proposto em termos de acurácia e custo computacional.

Modelo	Top-1 (%)	Top-5 (%)	#Params (M)	FLOPs (B)
EfficientNet-B0	77.1	93.3	5.3	0.39
ResNet-50	76.0	93.0	26	4.1
DenseNet-169	76.2	93.2	14	3.5
EfficientNet-B1	79.1	94.4	7.8	0.70
ResNet-152	77.8	93.8	60	11.0
DenseNet-264	77.9	93.9	34	6.0
Inception-v3	78.8	94.4	24	5.7
Xception	79.0	94.5	23	8.4
EfficientNet-B2	80.1	94.9	9.2	1.0
Inception-v4	80.0	95.0	48	13
Inception-ResNet-v2	80.1	95.1	56	13
EfficientNet-B3	81.6	95.7	12	1.8
ResNeXt-101	80.9	95.6	84	32
PolyNet	81.3	95.8	92	35
EfficientNet-B4	82.9	96.4	19	4.2
SENet	82.7	96.2	146	42
NASNet-A	82.7	96.2	89	24
AmoebaNet-A	82.8	96.1	87	23
PNASNet	82.9	96.2	86	23
EfficientNet-B5	83.6	96.7	30	9.9
AmoebaNet-C	83.5	96.5	155	41
EfficientNet-B6	84.0	96.8	43	19
EfficientNet-B7	84.3	97.0	66	37
GPipe	84.3	97.0	557	-

Tabela 2 – Resultados de desempenho do EfficientNet no ImageNet. Todos os modelos EfficientNet são derivados do EfficientNet-B0 utilizando escalonamento composto.

Adaptado de [Tan e Le 2019].

3.6 Ensemble Learning

Ensemble learning consiste na combinação de múltiplos classificadores com o objetivo de melhorar a capacidade preditiva e a robustez do modelo final. Em vez de utilizar um único classificador monolítico treinado simultaneamente para todas as classes, essa abordagem integra as respostas de diversos modelos, explorando sua

diversidade para reduzir erros, equilibrar viés e variância e aumentar a capacidade de generalização [Novotny et al. 2025].

Uma estratégia amplamente empregada nesse contexto é o treinamento de especialistas, no qual modelos individuais são treinados para distinguir uma classe ou um subconjunto de classes específicas. Dessa forma, o problema de classificação é decomposto em subproblemas menores, e a decisão final é obtida a partir da combinação das saídas desses modelos especializados. Essa decomposição permite capturar diferentes perspectivas sobre o espaço de características e explorar as complementaridades entre os classificadores.

Uma extensão desse paradigma é o uso de conjuntos baseados em classificadores *One-Class Classifiers*, formando os chamados *Ensembles of One-Class Classifiers* (EOCC). Nesse cenário, cada classificador é treinado exclusivamente com dados de uma única classe, aprendendo suas características intrínsecas sem depender de informações interclasse. Durante a inferência, cada modelo produz um escore de confiança ou probabilidade associado à classe modelada, e a decisão final depende da estratégia utilizada para combinar essas saídas [Novotny et al. 2025].

Outra abordagem amplamente explorada na literatura consiste no treinamento de múltiplos classificadores, seguida da aplicação de regras formais de combinação para determinar a classe final da predição. Nesse contexto, a decisão global pode ser obtida por meio de estratégias como a votação majoritária (*majority voting*), a média ou a soma ponderada de probabilidades (*soft voting*), o produto de probabilidades, regras baseadas em ranking ou ainda por meio de um meta-aprendiz, caracterizando o método conhecido como *stacking*. Diferentemente das abordagens baseadas apenas na especialização por classe, esses métodos buscam explorar explicitamente a diversidade estatística entre os modelos — seja ela decorrente de diferentes arquiteturas, subconjuntos de dados, inicializações ou estratégias de treinamento — a fim de reduzir o erro generalizado do sistema.

Do ponto de vista teórico, a eficácia desses métodos está associada à redução da variância (como em *bagging*), à redução do viés (como em *boosting*) ou ao equilíbrio entre ambos, dependendo da estratégia adotada. Trabalhos clássicos demonstram que, sob hipóteses de independência parcial entre os classificadores, a combinação tende a produzir desempenho superior ao de modelos individuais [Dietterich 2000, Kuncheva 2004]. Além disso, métodos como o *stacked generalization* formalizam o aprendizado da regra de combinação por meio de um segundo nível de modelagem, permitindo que o próprio sistema aprenda a ponderar as contribuições de cada classificador base [Wolpert 1992].

3.7 Métricas de Desempenho

Foram utilizados, como métricas de avaliação, a acurácia e o Kappa Quadrático Ponderado. A acurácia mede a capacidade de um modelo de classificar corretamente as instâncias, distinguindo adequadamente entre classes positivas e negativas, como, por exemplo, pacientes com a doença e indivíduos saudáveis [Baratloo et al. 2015].

Essa métrica é calculada como a proporção de classificações corretas em relação ao número total de instâncias avaliadas, considerando tanto os *verdadeiros positivos* (*True Positives* - TP) quanto os *verdadeiros negativos* (*True Negatives* - TN) [Baratloo et al. 2015]. Assim, a acurácia pode ser definida matematicamente pela seguinte expressão:

$$\text{Acurácia} = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.12)$$

Onde TP representa os verdadeiros positivos, TN os verdadeiros negativos, FP os falsos positivos (*False Positives*) e FN os falsos negativos (*False Negatives*).

O coeficiente Kappa Quadrático Ponderado mede o grau de concordância entre as classes preditas e as reais, considerando a concordância esperada ao acaso [Cohen 1968]. Essa métrica pode ser expressa matematicamente como:

$$\kappa = 1 - \frac{\sum_{i=1}^N \sum_{j=1}^N w_{ij} O_{ij}}{\sum_{i=1}^N \sum_{j=1}^N w_{ij} E_{ij}} \quad (3.13)$$

Onde O_{ij} representa a matriz de confusão observada, E_{ij} corresponde à matriz de concordância esperada ao acaso, N é o número de categorias e w_{ij} é o peso atribuído à discordância entre as classes i e j . No caso do Kappa Quadrático Ponderado, os pesos são definidos como:

$$w_{ij} = \frac{(i - j)^2}{(N - 1)^2} \quad (3.14)$$

Essa ponderação penaliza de forma mais severa erros entre classes mais distantes, tornando a métrica especialmente adequada para problemas de classificação ordinal.


A variabilidade das métricas de desempenho e os respectivos intervalos de confiança foram estimados por meio de *bootstrap* não paramétrico [Efron 1979]. Com base nas predições do conjunto de teste, foram geradas 1.000 reamostragens com reposição, preservando-se o tamanho do conjunto original. Em cada reamostragem, os indicadores de desempenho foram recalculados, o que permitiu estimar a distribuição empírica das métricas. A média, o desvio padrão e o intervalo de confiança de 90% foram

obtidos pelo método dos percentis, utilizando os quantis de 5% e 95%. Essa abordagem permite quantificar a incerteza das estimativas sem assumir pressupostos paramétricos sobre a distribuição dos dados.

4 Método Proposto

Este capítulo descreve a metodologia desenvolvida para a classificação automática dos graus ISUP em imagens histológicas de biópsias de próstata. A Figura 9 apresenta uma visão do fluxo de trabalho implementado, que é subdividido em quatro etapas fundamentais, a serem exploradas sequencialmente neste capítulo. Inicialmente, a Seção 4.1 descreve os materiais utilizados, com foco nas características do *dataset* PANDA. Em seguida, a Seção 4.2 detalha o pré-processamento, abordando as estratégias de divisão de dados, a análise de entropia para filtragem de amostras ruidosas e a extração de *patches*. A terceira etapa, descrita na Seção 4.3, engloba o Treinamento e Modelos, nos quais são discutidos a otimização de hiperparâmetros e o treinamento dos modelos EfficientNet (B0, B3 e B7) sob diferentes configurações de funções de perda ordinais. Por fim, a Seção 4.4 apresenta a Avaliação do *Ensemble*, elucidando as estratégias de fusão de modelos (Média, Máximo e Voto) adotadas para consolidar a predição final do grau ISUP.

Figura 9 – Etapas do Método Proposto



4.1 Materiais

Neste trabalho, utilizou-se o conjunto de dados PANDA (*Prostate Cancer Grade Assessment*), composto por aproximadamente 10.616 imagens histopatológicas

completas de biópsias de próstata [[PANDA Challenge 2020](#)]. Este conjunto de dados foi disponibilizado como parte do desafio PANDA na plataforma Kaggle e tem sido amplamente utilizado em pesquisas sobre a classificação automática do câncer de próstata. As imagens no conjunto de dados são anotadas com o escore e o grau de Gleason, fornecendo rótulos clínicos utilizados na graduação da doença. Neste estudo, apenas a versão pública do conjunto de dados foi utilizada, sem acesso ao conjunto de teste privado disponibilizado no desafio. Os dados foram coletados em dois centros médicos, *Radboud University Medical Center* e *Karolinska Institute*, o que introduz variabilidade institucional nas imagens.

Essa variabilidade está associada a diferenças nos protocolos de preparação de lâminas, nos procedimentos de escaneamento e nos critérios de anotação, o que aproxima o cenário experimental da prática clínica. Além disso, o conjunto de dados apresenta ruídos inerentes tanto ao processo de aquisição quanto ao de anotação das lâminas. Entre os artefatos visuais, destacam-se marcas de caneta realizadas por patologistas durante a análise, como ilustrado na Figura 10, que podem interferir na extração de características relevantes pelos modelos. Adicionalmente, há fontes de ruído associadas à rotulagem, incluindo a variabilidade interobservador na atribuição dos graus histopatológicos, o que introduz incerteza nos rótulos de treinamento. Nesse contexto, [[Kabir et al. 2025](#)] relatam inconsistências entre diferentes níveis de anotação, evidenciando casos em que as máscaras de segmentação não estavam alinhadas aos rótulos globais das respectivas imagens. Tais discrepâncias comprometem a qualidade supervisionada dos dados e podem prejudicar o processo de aprendizado, especialmente em tarefas que dependem da coerência entre anotações locais e globais.

Esses fatores aumentam a complexidade da tarefa de classificação automática e refletem desafios presentes na prática da patologia digital.




Figura 10 – Exemplo de um artefato visual presente em uma WSI do conjunto de dados PANDA. À esquerda, apresenta-se a lâmina completa, com a região de interesse destacada em vermelho. À direita, uma visão ampliada da região selecionada revela uma marca de caneta sobre o tecido prostático.
Fonte: Elaborado pelo autor.

Outro aspecto relevante do conjunto de dados é a distribuição desigual das amostras entre as seis classes de graduação (ISUP 0 a ISUP 5). Esse desbalanceamento torna-se evidente na Figura 11, que apresenta a distribuição das amostras por classe. Observa-se que a maior parte dos exemplos está concentrada nas classes ISUP 0 e ISUP 1.




Figura 11 – Distribuição de amostras no conjunto de dados PANDA

4.2 Pré-processamento

O fluxo de pré-processamento foi estruturado em duas etapas sequenciais: a filtragem de ruído nos rótulos e a extração de *patches*. Inicialmente, o conjunto de dados foi dividido em treinamento (85%) e teste (15%), garantindo independência entre o

processo de ajuste e a avaliação final dos modelos. Após essa divisão, o conjunto de treinamento passou a conter 9.024 instâncias, enquanto o conjunto de teste, utilizado na avaliação de todos os modelos deste trabalho, ficou composto por 1.592 instâncias.

4.2.1 Filtragem de Ruído Baseada em Entropia

Conforme relatado na Seção 4.1, o conjunto PANDA apresenta ruídos nos rótulos, decorrentes de anotações manuais e de laudos patológicos inconclusivos. Para mitigar o impacto dessas inconsistências no aprendizado, foi aplicada uma estratégia de filtragem baseada na estimativa de incerteza preditiva.

Inicialmente, considerou-se o conjunto de treinamento correspondente a 85% das amostras do *dataset* completo. Esse conjunto foi subdividido em duas partes: 80% das amostras foram utilizadas para treinamento efetivo dos modelos, enquanto os 20% restantes foram reservados para validação interna. Em seguida, quatro variantes de menor complexidade da família EfficientNet (B0, B1, B2 e B3) foram treinadas de forma independente utilizando essa divisão. Cada modelo foi treinado por 20 épocas, com taxa de aprendizado inicial de 3×10^{-4} , critério de parada antecipada (*early stopping*) com paciência de 7 épocas, e função de perda baseada em *Binary Cross-Entropy* (BCE).

Após o treinamento, cada modelo foi utilizado para gerar probabilidades preditas para todas as amostras dos conjuntos de treinamento e validação. Essas previsões foram posteriormente empregadas para estimar a incerteza e identificar amostras potencialmente ruidosas. A incerteza de cada decisão foi quantificada usando a entropia de Shannon [Ali et al. 2023], definida para a classe c como:

$$H = \frac{1}{C} \sum_{c=1}^C -[p_c \log(p_c) + (1 - p_c) \log(1 - p_c)], \quad (4.1)$$

Onde p_c é a probabilidade predita para a classe positiva e C é o número de classes. Valores de p_c próximos de 0 ou 1 indicam baixa entropia (alta confiança), enquanto valores próximos de 0.5 refletem alta incerteza.

A entropia foi calculada para cada amostra em cada modelo e, em seguida, foi obtida a média das previsões das quatro redes. Com base nessa estimativa, foram selecionadas as 10% amostras com maior entropia média, calculadas exclusivamente sobre o conjunto de treinamento, ou seja, correspondentes a 10% das amostras pertencentes a esse conjunto (85% do dataset total), formando um subconjunto denominado *hard samples*.

A partir desse conjunto, avaliou-se o impacto da remoção dessas amostras apenas no conjunto de treinamento, considerando quatro cenários experimentais:

- (i) utilização de todo o conjunto de dados (sem remoção de *hard samples*);
- (ii) remoção de 100% das *hard samples*;
- (iii) remoção de 50% das *hard samples*;
- (iv) remoção de 20% das *hard samples*.

4.2.2 Extração de Patches

Após a definição das amostras de treinamento por meio da filtragem de entropia, a etapa final do pré-processamento consistiu na geração das imagens de entrada para o modelo final. Como o tecido histológico ocupa apenas uma fração da WSI, como observamos na Figura 12, processar a lâmina completa exigiria um custo computacional elevado e seria desnecessário para tratar extensas áreas de fundo.




Figura 12 – Imagem de exemplo do conjunto de dados PANDA evidenciando a vasta área sem tecido.

Para extrair regiões informativas das imagens, adotou-se uma abordagem baseada na geração de recortes (*patches*) da imagem original. Inicialmente, definiu-se um tamanho fixo de 256×256 *pixels* para cada *patch*. Para garantir a padronização, aplicou-se preenchimento com *pixels* brancos nas bordas das WSIs, de modo que suas dimensões se tornassem compatíveis com a extração de *patches* de tamanho fixo. Em seguida, cada imagem foi particionada em *patches*, e a presença de tecido em cada fragmento foi estimada pela soma dos valores RGB; como o fundo tende ao branco, menores somas indicam maior densidade de tecido. Os *patches* foram então ordenados de forma crescente segundo essa métrica. Por fim, quando a WSI não possuía quantidade suficiente de regiões com tecido para atingir o número pré-definido de *patches*, as posições remanescentes foram preenchidas com *patches* brancos, assegurando um número fixo de entradas por amostra.

Por fim, avaliou-se a reorganização espacial dos fragmentos nas configurações 5×5 , 6×6 e 7×7 (Figura 13). A configuração 5×5 omitia padrões lesionais sutis, enquanto a 7×7 gerava imagens de alta dimensionalidade (1792×1792) com excesso de fundo. Adotou-se a configuração intermediária de 6×6 (36 *patches*, gerando imagens de 1536×1536 *pixels*), equilibrando a preservação da informação tecidual, a cobertura espacial e a eficiência computacional.




Figura 13 – Ilustração da extração de *patches* em diferentes tamanhos: 5×5 (à esquerda), 6×6 (no centro) e 7×7 (à direita).

4.3 Treinamento e Modelos

Esta seção descreve a estratégia de treinamento dos classificadores, etapa subsequente ao pré-processamento das imagens. Inicialmente, adotou-se a arquitetura EfficientNet-B0 como modelo *baseline* para o ajuste de hiperparâmetros, devido ao equilíbrio entre capacidade representacional e eficiência computacional. Uma vez definida a configuração ideal, os experimentos foram ampliados para as arquiteturas EfficientNet-B3 e EfficientNet-B7. Essa progressão metodológica permitiu avaliar o impacto do aumento da complexidade estrutural dos modelos sobre o desempenho e a capacidade de generalização da rede.

Na etapa de avaliação de hiperparâmetros e construção do modelo *baseline*, utilizou-se a função de perda BCE como referência inicial. Foram investigadas diferentes combinações de taxa de aprendizado, dropout e proporção de camadas descongeladas no processo de *fine-tuning*, por meio de um grid search com a arquitetura EfficientNet-B0. Mesmo após essa otimização, observou-se que a formulação do problema como uma classificação multiclasse convencional limitava o desempenho do modelo. Considerando que os graus ISUP representam uma progressão ordinal da severidade tumoral, o problema foi reformulado como uma regressão ordinal para capturar a hierarquia entre as classes.

Nesta abordagem, a predição do grau ISUP não é tratada como um problema multiclasse com categorias independentes, mas como uma sequência de classificações binárias cumulativas. Para um grau ISUP $k \in \{0, \dots, 5\}$, o rótulo é codificado como um vetor binário cumulativo, em que os k primeiros elementos assumem valor 1 e os restantes, 0. Por exemplo, o grau 3 é representado por $[1, 1, 1, 0, 0]$. Essa codificação permite que o modelo aprenda limiares progressivos associados ao aumento da gravidade da doença.

Para explorar explicitamente a natureza ordinal do problema de graduação prostática, adotou-se uma função de perda composta que integra dois componentes complementares: um termo de classificação nos limiares cumulativos e um termo de penalização ordinal.

O componente de classificação é baseado na *Binary Cross-Entropy* com *logits* aplicada ao vetor de limiares, permitindo que o modelo aprenda, de forma independente, a probabilidade de uma amostra pertencer a uma classe maior ou igual a cada nível ordinal. Para lidar com o desbalanceamento presente no conjunto de dados PANDA, esse termo é reformulado utilizando a *Focal Loss*, que reduz a contribuição de exemplos fáceis e enfatiza amostras difíceis.

Complementarmente, incorpora-se um termo de regressão ordinal que penaliza a discrepância entre a classe esperada predita e o rótulo verdadeiro, conforme formalizado na Equação 3.10.

A função de perda final, denominada *Ordinal Focal Regression Loss*, é definida como:

$$\mathcal{L} = \alpha \cdot \mathcal{L}_{focal} + \beta \cdot \mathcal{L}_{ord} \quad (4.2)$$

onde $\mathcal{L}_{focal}$ representa o termo de classificação baseado em *Focal Loss*, enquanto α e β controlam a contribuição relativa de cada componente.

Essa formulação integra de forma unificada a modelagem ordinal das classes e o tratamento do desbalanceamento, incentivando o modelo a produzir previsões consistentes com a hierarquia dos rótulos e robustas frente à distribuição desigual dos dados.

Após a definição do pipeline metodológico, que engloba a extração de *patches*, a otimização de hiperparâmetros e a adequação da função de perda, o desempenho das arquiteturas EfficientNet (B0, B3 e B7) foi avaliado em dados não vistos no treinamento.

4.4 Avaliação do Ensemble

Para melhorar a robustez e a capacidade de generalização na classificação do grau ISUP, as previsões de múltiplos modelos foram combinadas por meio de técnicas de *ensemble*. No contexto deste trabalho, cada modelo gera um conjunto de *logits*, que são convertidos em probabilidades ordinais pela função sigmoide. A classe final é tipicamente decodificada por meio da contagem de limiares ordinais com probabilidade superior a 0,5.

Para agregar as respostas dos diferentes modelos, avaliamos três abordagens distintas:

- Média Simples: Uma abordagem de *soft voting* em que a probabilidade combinada para cada limiar ordinal é a média aritmética das probabilidades obtidas por todos os modelos.
- Máximo: Semelhante à média, mas a probabilidade adotada para cada limiar é o valor máximo dentre as probabilidades previstas pelos modelos individuais antes da etapa de decodificação.
- Voto Majoritário: Diferente das anteriores, esta é uma estratégia de *hard voting*, em que as probabilidades não são combinadas. Cada modelo realiza sua predição isolada de classe, e a decisão final do *ensemble* é dada pela classe mais votada (moda).

As técnicas foram aplicadas a um conjunto de arquiteturas EfficientNet (variantes B0, B3 e B7), previamente treinadas com funções de perda focais adaptadas à regressão ordinal.

5 Resultados

Esta seção apresenta os resultados experimentais obtidos com a aplicação da metodologia descrita na Seção 4. O objetivo é validar as abordagens propostas e analisar o comportamento do modelo sob diferentes condições. Inicialmente, detalham-se o ambiente computacional utilizado e a seleção dos hiperparâmetros para o treinamento do modelo *baseline*. Na sequência, investiga-se o impacto da etapa de remoção de ruído e das diferentes formulações da função de perda no desempenho preditivo. Por fim, conduz-se um estudo comparativo abrangente entre diferentes arquiteturas da família EfficientNet, avaliando o compromisso entre custo computacional e eficácia.

5.1 Ambiente Experimental

Os experimentos foram conduzidos em uma estação de trabalho Linux equipada com um processador AMD Ryzen 5 5600X, 32 GB de memória RAM DDR4 (3200 MHz) e uma GPU NVIDIA GeForce RTX 3060 (12 GB de VRAM), dedicada à aceleração do treinamento de modelos de aprendizado profundo.

O desenvolvimento foi realizado em Python, utilizando o *framework* PyTorch integrado ao CUDA 12.8. Para o processamento das imagens histopatológicas, empregou-se a biblioteca OpenSlide para a leitura e a extração de patches. O cálculo das métricas de avaliação foi realizado com o scikit-learn, enquanto as análises visuais foram geradas com a biblioteca Matplotlib.

5.2 Configuração de Hiperparâmetros

A etapa inicial da experimentação consistiu em uma *grid search* para identificar a configuração de hiperparâmetros que maximizasse a convergência e a capacidade de generalização do modelo *baseline*, mitigando o risco de *overfitting*. Os valores explorados e a configuração final selecionada estão consolidados na Tabela 3. Essa configuração ótima foi estabelecida como padrão e mantida constante nos experimentos subsequentes, a fim de garantir a comparabilidade dos resultados.

A taxa de aprendizado inicial fixada em 3×10^{-4} , operando em conjunto com o otimizador Adam, proporcionou a melhor estabilidade durante a minimização da função de perda (BCE). No processo de *fine-tuning*, adotou-se a estratégia de descongelamento dos últimos 150 parâmetros/camadas treináveis do modelo, o que apresentou o melhor equilíbrio. Aliada a isso, uma camada de *dropout* com probabilidade de retenção de 0,4 demonstrou ser a regularização mais eficaz.

O tamanho do batch foi limitado a duas amostras devido às limitações de memória da GPU. Para mitigar as flutuações na atualização dos gradientes decorrentes do lote reduzido, configurou-se o treinamento para até 50 épocas, adotando-se um critério de *early stopping* com tolerância de 7 épocas sem melhoria na métrica de validação.

Parâmetro	Valores avaliados	Valor selecionado
Taxa de aprendizado	3×10^{-4} , 3×10^{-3} , 1×10^{-4}	3×10^{-4}
Número de épocas	50	50
Camadas descongeladas (<i>fine-tuning</i>)	100, 150	150
<i>Dropout</i>	0.4, 0.5, 0.6	0.4
Tamanho do lote (<i>batch size</i>)	2	2
Função de perda	BCE	BCE
Otimizador	Adam	Adam

Tabela 3 – Hiperparâmetros avaliados e configuração selecionada para os experimentos.

5.3 Impacto da Filtragem de Ruído e Funções de Perda

Com o conjunto ideal de hiperparâmetros definido, procedeu-se ao treinamento do modelo *baseline* com a arquitetura EfficientNet-B0 e a função de perda BCE. Este modelo alcançou uma acurácia de 0,592 e um coeficiente Kappa de 0.826. No contexto da classificação de graus ISUP em biópsias de próstata, este valor de Kappa é considerado altamente satisfatório e competitivo. A literatura médica aponta uma expressiva variabilidade interobservador na graduação histopatológica [Ozkan et al. 2016, Cinar e Cinar 2025]. Enquanto uropatologistas experientes frequentemente alcançam valores de Kappa entre 0.43 e 0.68 [Ozkan et al. 2016], avaliações recentes focadas especificamente nos graus ISUP relatam níveis de concordância mínimos entre patologistas, com Kappa na faixa de 0.31 [Cinar e Cinar 2025]. Dessa forma, o baseline obtido demonstra um nível de concordância que supera consideravelmente a variabilidade humana relatada. Ademais, os resultados indicam que, mesmo com uma acurácia moderada (59,2%), os erros de predição do modelo concentram-se em graus ISUP adjacentes, minimizando penalidades clínicas graves.

A etapa de filtragem baseada em entropia permitiu identificar um subconjunto de 903 amostras, correspondentes aos 10% com maior incerteza entre as predições dos modelos EfficientNet-B0, B1, B2 e B3. A análise desse subconjunto revelou características que demonstram grande dificuldade para os modelos, incluindo alta entropia média (0.3851 ± 0.0638), grande variabilidade nas predições (1.1188 ± 0.8943) e baixa concordância entre as arquiteturas avaliadas. Observou-se que apenas 6,2% das amostras apresentaram consenso entre os quatro modelos. Além disso, em 58% das instâncias classificadas como *hard samples*, nenhum dos modelos foi capaz de realizar a predição correta, esses dados sustentam a hipótese de que a entropia pode atuar como um indicador eficaz para a identificação de exemplos difíceis ou inconsistentes.

Ademais, a análise da distribuição dessas *hard samples* revelou que a incerteza das redes não é homogênea entre as classes, mas fortemente associada à severidade da lesão. Aproximadamente 81,7% das imagens de alta entropia concentram-se nos graus ISUP 3, 4 e 5. Esse comportamento reflete a complexidade morfológica e a maior heterogeneidade visual inerentes aos tumores mais agressivos, o que naturalmente impõe um desafio maior para a extração de características convolucionais.

A partir desse subconjunto de *hard samples*, foram investigados diferentes cenários de remoção de dados potencialmente ruidosos durante o treinamento. Os resultados indicaram que a remoção parcial dessas amostras contribuiu para a melhoria do desempenho do modelo. Na Figura 14, observa-se que a exclusão de aproximadamente 20% das *hard samples* proporcionou o melhor equilíbrio entre a redução do ruído e a preservação da diversidade do conjunto de treinamento, sugerindo que uma filtragem moderada pode favorecer a capacidade de generalização do modelo.




Figura 14 – Desempenho com diferentes limiares de remoção de ruído sobre os *hard samples*

A Figura 15 apresenta um exemplo de imagem identificada pelo método como uma amostra com elevado grau de incerteza na predição. Ao analisar os resultados obtidos pelos modelos, observa-se que o rótulo verdadeiro da imagem corresponde à classe ISUP 2. Entretanto, durante o processo de inferência, o modelo EfficientNet-B0 a classificou como ISUP 3, enquanto os modelos EfficientNet-B1, B2 e B3 a classificaram como ISUP 1. Embora essas discrepâncias não representem erros clinicamente graves, a análise realizada nesta etapa prioriza o nível de incerteza associado às decisões dos modelos. Para essa imagem específica, o valor médio de entropia calculado foi de 0,59, considerado alto. Esse exemplo ilustra como o método é capaz de identificar casos potencialmente ruidosos; nessa imagem em específico, ficam evidentes as anotações de caneta. A eficácia dessa estratégia de filtragem torna-se mais evidente ao analisar os resultados apresentados na Tabela 4. Observa-se que a aplicação da remoção de ruído

elevou o κ_{quad} do valor de 0.826 no modelo *baseline* para 0.833. O impacto na acurácia foi ainda mais significativo, passando de 0.592 para 0.638, o que representa um ganho absoluto de aproximadamente 4,6 pontos percentuais. Esses resultados indicam que a remoção de uma parcela das amostras altamente incertas melhora a capacidade de generalização do modelo.




Figura 15 – Imagem identificada como ruído pelo método de filtragem

A substituição da função de perda BCE pela formulação ordinal elevou o desempenho global do modelo para 0.851, embora tenha ocorrido uma leve redução na acurácia. Esse resultado sugere que a inclusão do fator ordinal promove uma redistribuição das predições incorretas, reduzindo os erros entre classes distantes e concentrando as confusões entre classes adjacentes. Em problemas de classificação ordinal, como no sistema de graduação ISUP, esse comportamento é desejável, pois discrepâncias entre classes vizinhas têm menor impacto clínico do que erros entre graus mais distantes. Esse comportamento pode ser observado na Figura 16, que apresenta as matrizes de confusão normalizadas dos modelos treinados com BCE e com a função de perda ordinal. Nota-se que o modelo com perda ordinal concentra os erros principalmente entre classes adjacentes, enquanto o modelo treinado com BCE apresenta maior dispersão entre classes mais distantes.

Ao analisar a diagonal principal das matrizes, observa-se melhora nas classes ISUP 1, ISUP 2 e ISUP 4, enquanto houve redução na acurácia das classes ISUP 0, ISUP 3 e ISUP 5. Além disso, a perda ordinal praticamente elimina erros entre classes distantes; amostras ISUP 0 deixam de ser classificadas como ISUP 3, 4 ou 5 e passam a apresentar confusão predominantemente com a classe adjacente ISUP 1. Em contrapartida, observa-se maior dispersão nas classes intermediárias, especialmente nas classes ISUP 2 e ISUP 3, o que reflete a dificuldade intrínseca de distinção entre graus histopatológicos adjacentes. Em síntese, os resultados indicam que a utilização da perda ordinal promove um comportamento de classificação mais alinhado à natureza hierárquica do problema, reduzindo discrepâncias severas entre classes e favorecendo confusões entre graus histopatológicos adjacentes.

Após a introdução da perda ordinal, observou-se que o desbalanceamento do conjunto de dados, descrito na Seção 4.1, poderia estar limitando o desempenho do modelo. Diante disso, foi proposta uma função de perda híbrida que combina penalização

		Matriz de Confusão (Sem Perda Ordinal)						Matriz de Confusão (Com Perda Ordinal)					
Classe Verdadeira	ISUP 0	0.882	0.069	0.016	0.019	0.009	0.005	0.711	0.257	0.028	0.005	0.000	0.000
	ISUP 1	0.150	0.605	0.190	0.045	0.010	0.000	0.065	0.785	0.128	0.022	0.000	0.000
	ISUP 2	0.020	0.192	0.448	0.210	0.090	0.040	0.005	0.354	0.461	0.139	0.036	0.005
	ISUP 3	0.028	0.037	0.146	0.381	0.263	0.146	0.016	0.071	0.303	0.365	0.212	0.033
	ISUP 4	0.059	0.032	0.048	0.109	0.495	0.257	0.022	0.054	0.102	0.187	0.498	0.138
	ISUP 5	0.044	0.006	0.005	0.059	0.217	0.669	0.005	0.038	0.038	0.082	0.342	0.494
		Classe Predita						Classe Predita					
		ISUP 0	ISUP 1	ISUP 2	ISUP 3	ISUP 4	ISUP 5	ISUP 0	ISUP 1	ISUP 2	ISUP 3	ISUP 4	ISUP 5

Figura 16 – Matrizes de confusão normalizadas obtidas para o modelo treinado com a função de perda BCE (à esquerda) e com a função de perda ordinal (à direita).

ordinal com o mecanismo focal, com o objetivo de enfatizar as amostras mais difíceis e mitigar os efeitos do desbalanceamento entre as classes.

Essa estratégia resultou no melhor desempenho entre as configurações avaliadas, atingindo $kappa = 0.856$ e acurácia de 0.669. Em comparação com o modelo *baseline*, essa abordagem proporcionou um ganho absoluto de aproximadamente 3% em kappa e mais de 6 pontos percentuais em acurácia.

Configuração	Kappa Quadrático			Acurácia (%)		
	Resultado	Des. Pad.	IC 95%	Resultado	Des. Pad.	IC 95%
BCE (baseline)	0.826	0.012	[0.806; 0.846]	0.592	0.012	[0.572; 0.612]
BCE + Remoção de Ruído	0.833	0.013	[0.812; 0.853]	0.638	0.116	[0.619; 0.657]
Perda Ordinal	0.851	0.009	[0.833; 0.869]	0.608	0.126	[0.587; 0.628]
Ordinal + Focal (Híbrida)	0.856	0.011	[0.833; 0.876]	0.669	0.011	[0.635; 0.683]

Tabela 4 – Impacto incremental das estratégias propostas no desempenho da EfficientNet-B0.

A análise das matrizes de confusão apresentadas na Figura 17 evidencia melhorias consistentes ao utilizar a perda focal ordinal. O modelo treinado apenas com perda ordinal apresenta maior dispersão nas classes intermediárias, particularmente na classe ISUP 3, cuja taxa de acerto foi de 0.365, com uma parcela significativa das amostras confundida com ISUP 2 (0.303) e ISUP 4 (0.212). Em contraste, o modelo híbrido apresentou maior concentração das predições na diagonal principal, indicando maior capacidade discriminativa. Observam-se melhorias relevantes em diversas classes, incluindo ISUP 0 (0.857 vs. 0.711), ISUP 3 (0.492 vs. 0.365) e ISUP 4 (0.652 vs. 0.498). Além disso, nota-se uma redução das confusões entre classes intermediárias, especialmente entre ISUP 2 e ISUP 3, o que sugere maior separabilidade entre esses

graus histopatológicos.

Outro aspecto importante é a melhora na distinção entre classes de alto grau. No modelo ordinal, uma proporção significativa de amostras classificadas como ISUP 5 foi classificada como ISUP 4 (0.342). Embora essa confusão ainda esteja presente no modelo híbrido (0.380), observa-se um aumento na taxa de acerto para ISUP 4 (0.652 vs. 0.498), indicando maior discriminação entre os graus superiores.




Figura 17 – Matrizes de confusão normalizadas para modelos treinados com perda ordinal e perda focal ordinal.

5.4 Comparação entre Arquiteturas EfficientNet

A configuração experimental definida para a EfficientNet-B0 também foi aplicada às arquiteturas EfficientNet-B3 e EfficientNet-B7, inclusive à função de perda híbrida. O objetivo foi avaliar se arquiteturas mais profundas poderiam gerar ganhos adicionais de desempenho.

Os resultados, apresentados na Tabela 5, indicam que a EfficientNet-B0 apresentou o melhor desempenho tanto no kappa quadrático quanto na acurácia. As arquiteturas mais profundas não apresentaram melhorias significativas e, em alguns casos, exibiram uma leve redução nas métricas avaliadas.

Esse comportamento sugere que modelos mais complexos podem ser mais suscetíveis ao *overfitting* neste conjunto de dados. Assim, a EfficientNet-B0 demonstrou o melhor equilíbrio entre desempenho preditivo, estabilidade estatística e custo computacional.

Arquitetura	Kappa Quadrático			Acurácia (%)		
	Resultado	Des. Pad.	IC 95%	Resultado	Des. Pad.	IC 95%
EfficientNet-B0	0.856	0.011	[0.833; 0.876]	0.669	0.011	[0.635; 0.683]
EfficientNet-B3	0.849	0.013	[0.824; 0.870]	0.661	0.014	[0.634; 0.685]
EfficientNet-B7	0.842	0.015	[0.815; 0.866]	0.654	0.016	[0.628; 0.678]

Tabela 5 – Comparação de desempenho entre as arquiteturas da família EfficientNet, utilizando a configuração experimental proposta.

5.5 Avaliação do *Ensemble*

Embora os modelos individuais apresentem desempenho competitivo, abordagens baseadas em *ensemble* são amplamente utilizadas para melhorar a robustez e a capacidade de generalização de modelos de aprendizado profundo. A combinação de múltiplos classificadores permite reduzir a variância das previsões e explorar complementaridades entre diferentes arquiteturas e estratégias de treinamento.

Com esse objetivo, foi construído um *ensemble* composto pelos três modelos EfficientNet (B0, B3 e B7), descritos na Seção 5.4. A combinação das previsões foi investigada por meio de diferentes estratégias de agregação: média, máxima e votação majoritária. Os resultados obtidos são apresentados na Tabela 6.

Estratégia de Ensemble	Kappa Quadrático			Acurácia (%)		
	Resultado	Des. Pad.	IC 95%	Resultado	Des. Pad.	IC 95%
Média	0.880	0.010	[0.861; 0.898]	0.698	0.012	[0.674; 0.721]
Máxima	0.840	0.014	[0.812; 0.864]	0.583	0.015	[0.556; 0.610]
Votação	0.860	0.012	[0.835; 0.881]	0.692	0.013	[0.667; 0.715]

Tabela 6 – Desempenho das diferentes estratégias de ensemble avaliadas no conjunto de teste.

Observa-se que as estratégias de ensemble baseadas em média e votação majoritária apresentaram desempenho superior ao dos modelos individuais, enquanto a estratégia baseada no operador máximo apresentou desempenho inferior. A estratégia de média simples obteve o melhor resultado global, com kappa de 0.880 e acurácia de 0.698. Em comparação com o melhor modelo individual (EfficientNet-B0 com perda ordinal focal), essa abordagem proporcionou um ganho absoluto de aproximadamente 2,3 pontos percentuais em kappa e de cerca de 3,8 pontos percentuais em acurácia.

Esse resultado sugere que as arquiteturas EfficientNet-B0, B3 e B7 capturam padrões complementares no conjunto de dados, permitindo que o *ensemble* reduza erros individuais e produza previsões mais estáveis. Em contraste, a estratégia baseada na seleção da probabilidade máxima apresentou desempenho inferior, indicando que a simples escolha da previsão mais confiante não explora adequadamente a complementaridade entre os modelos. De forma geral, os resultados demonstram que o

uso de *ensemble* contribui para melhorar a capacidade preditiva do sistema, fornecendo estimativas mais robustas e reduzindo a variabilidade associada às decisões de modelos individuais.

5.6 Comparação com trabalhos relacionados

Nesta seção, apresenta-se uma análise comparativa entre o método proposto e os trabalhos relacionados discutidos no Capítulo 2. A Tabela 7 sintetiza essas abordagens, reunindo informações sobre o *dataset* utilizado, o modelo principal, o nível de análise (em nível de *patch* ou WSI), a tarefa considerada (incluindo número de classes e tipo de graduação, como Gleason ou ISUP), bem como as métricas de desempenho reportadas, especificamente acurácia e coeficiente kappa.

Trab.	Dados	Modelo	Nível	Tarefa	Acc.	kappa
[Arvaniti et al. 2018]	Radboud	Pyramidal CNN	Patch → WSI	Gleason / GG	0,773	-
[Ikromjanov et al. 2021]	PANDA	ViT	Patch	Gleason	0,800	-
[Xiang et al. 2023]	PANDA	ResNet50 + GCN	WSI	ISUP	-	0,931 / 0,801
[Alici-Karaca e Akay 2024]	DiagSet	EffNet-B4 + ECA	Patch	Bin./4 cls	0,961 / 0,948	-
[Kosoko et al. 2024]	SICAPv2	VGG19	Patch	Gleason	0,780	-
[Bhattacharyya et al. 2024]	PANDA	EffNet-B1 + MIL + Ensemble	WSI	ISUP	-	0,881
[Kabir et al. 2025]	PANDA	EffNet-B0 + DeepLabV3 + RF	WSI + Seg	ISUP	-	0,921
[Bhattacharyya, Pal e Mitra 2026]	PANDA / SICAPv2	SSL (TSOR) + Ord. Reg.	WSI	ISUP	-	0,884
Proposto (Base)	PANDA	EffNet-B0 + Ord. Focal	WSI	ISUP	0,669	0,856
Proposto (Ensemble)	PANDA	EffNet-B0/B3/B7 + Ensemble	WSI	ISUP	0,698	0,880

Tabela 7 – Comparação do método proposto com trabalhos recentes.

Embora diferentes trabalhos reportem resultados competitivos na classificação do padrão de Gleason, diversas limitações metodológicas reduzem sua aplicabilidade clínica e comprometem a generalização dos modelos.

No caso de [Arvaniti et al. 2018], a abordagem baseada em uma arquitetura piramidal acarreta alto custo computacional, exigindo o treinamento de múltiplas CNNs e o processamento de mais de 10 milhões de *patches*. Além disso, o uso de subamostragem severa para o balanceamento resulta no descarte de um grande volume de informação clínica relevante. De forma semelhante, [Ikromjanov et al. 2021], [Alici-Karaca e Akay 2024] e [Kosoko et al. 2024] restringem a tarefa à classificação de *patches*, o que simplifica o problema e dificulta comparações diretas com abordagens em nível de WSI. No caso específico de [Ikromjanov et al. 2021], há ainda a exclusão da coorte do *Karolinska* e dependência de máscaras de segmentação, reduzindo a variabilidade dos dados e favorecendo resultados potencialmente superestimados.

Outros trabalhos também apresentam fragilidades relacionadas à curadoria de dados e à robustez. [Xiang et al. 2023] reporta um *kappa* alto (0,931), porém obtido em um conjunto interno sem artefatos reais (como marcas de caneta), com queda significativa na validação externa (0,801), o que evidencia limitações de generalização. De forma análoga, [Kabir et al. 2025] depende de anotações em nível de pixel, o que restringe drasticamente o volume de dados utilizado e cria um cenário pouco

representativo da prática clínica. Limitações semelhantes na amostragem são observadas em [Bhattacharyya, Pal e Mitra 2026] e [Bhattacharyya et al. 2024], que utilizam apenas frações do dataset PANDA. Especificamente em [Bhattacharyya et al. 2024], embora o método baseado em *ensemble* reporte um *kappa* competitivo de 0,881, os autores aplicam um balanceamento manual forçado em todo o conjunto de dados, selecionando o mesmo número de imagens para cada grau ISUP, antes mesmo de separar os conjuntos de validação e teste. Essa abordagem mascara a distribuição real e severamente desbalanceada da doença na prática clínica, o que introduz um viés de avaliação e compromete a generalização do modelo para cenários do mundo real.

Em contraste, o método proposto elimina a dependência de anotações em nível de pixel por meio de uma filtragem automatizada baseada na entropia, permitindo o uso mais amplo e realista dos dados disponíveis. A abordagem opera diretamente no nível de WSI, evitando simplificações inerentes à análise por *patches* e preservando a distribuição original das classes, sem descartar amostras arbitrariamente. Adicionalmente, o uso de regressão ordinal incorpora a estrutura hierárquica dos graus de Gleason, o que resulta em predições mais consistentes do ponto de vista clínico. Em conjunto, essas características conferem maior robustez, eficiência computacional e capacidade de generalização ao método proposto.

5.7 Discussão

Os resultados obtidos evidenciam que a avaliação de modelos de classificação de câncer de próstata não deve se restringir à acurácia global, especialmente em problemas de estrutura ordinal e de impacto clínico direto. Abordagens que simplificam a tarefa, como classificações binárias ou nominais, tendem a apresentar melhor desempenho em métricas tradicionais, porém não modelam explicitamente a relação ordinal entre as classes, o que limita a interpretação clínica das predições.

O método proposto se diferencia ao incorporar explicitamente a natureza ordinal dos graus ISUP, o que resulta em um aumento consistente do coeficiente *kappa* quadrático. Essa métrica é mais adequada ao problema, pois penaliza de forma mais severa erros entre classes distantes, refletindo melhor o impacto clínico das predições. A utilização da perda ordinal, especialmente quando combinada ao mecanismo de *focal loss*, altera o padrão de erros do modelo. Observa-se maior concentração de confusões entre classes adjacentes, o que indica que o modelo captura a progressão gradual da doença, em vez de tratá-las como categorias independentes.

O uso de estratégias de *ensemble* mostrou-se fundamental não apenas para aumentar a estabilidade do modelo, mas também para recuperar casos de alta complexidade diagnóstica. A análise evidenciou que, em 70 instâncias, apenas um dos modelos individuais foi capaz de realizar a classificação correta — sendo 30 acertos

do B0, 25 do B3 e 15 do B7. Nessas situações, o *ensemble* foi capaz de consolidar corretamente o diagnóstico ao integrar as diferentes previsões, mesmo quando a maioria dos modelos falhava. Esse resultado é clinicamente relevante, pois demonstra que a diversidade arquitetural funciona como uma espécie de mecanismo de compensação: erros específicos de um modelo são corrigidos pelos acertos de outro. Na prática, isso implica que, caso apenas um único modelo fosse utilizado, essas 70 amostras apresentariam um alto risco de classificação incorreta, com uma taxa de erro potencial de pelo menos 57%. Assim, o *ensemble* não apenas melhora o desempenho médio, mas atua diretamente na redução de erros críticos, especialmente em casos mais desafiadores.

Além disso, observou-se um efeito complementar em 9 casos, nos quais todos os modelos individuais falharam isoladamente, mas a agregação por meio do *ensemble mean* resultou na classificação correta. Esse achado indica que a combinação das probabilidades permite que a classe correta seja identificada a partir da distribuição conjunta das previsões, mesmo quando ela não apresenta a maior probabilidade em nenhum modelo individual. Por fim, a robustez da abordagem é reforçada pelo fato de que o *ensemble* não introduziu erros em situações em que houve consenso correto entre os três modelos, preservando o desempenho nos casos já bem resolvidos.

A filtragem de amostras com base na entropia também contribuiu para a remoção de instâncias ruidosas ou ambíguas, melhorando a capacidade de generalização. Esse resultado evidencia a importância da qualidade dos dados em aplicações de aprendizado profundo, especialmente em contextos com alta variabilidade interobservador. A combinação das estratégias propostas, modelagem ordinal, *focal loss*, *ensemble* e filtragem por entropia, resultou em ganhos progressivos de desempenho, culminando em um sistema mais robusto e clinicamente coerente.

Como limitação, destaca-se a utilização de um único conjunto de dados, o que pode comprometer a generalização dos resultados. Trabalhos futuros devem considerar validações externas, bem como a exploração de técnicas adicionais, como otimização bayesiana de hiperparâmetros e métodos mais avançados de fusão de modelos, visando aprimorar ainda mais a robustez e o desempenho do sistema em biópsias fragmentadas.

5.8 Estudo de Caso 1 - Erro clinicamente grave

A análise dos resultados do *ensemble* revelou que 271 instâncias (17%) do conjunto de teste não foram corretamente classificadas por nenhum dos modelos avaliados. Dentre elas, há casos clinicamente críticos. Por exemplo, o primeiro estudo de caso refere-se a uma WSI rotulada como ISUP 5, que foi consistentemente classificada como ISUP 0 por todos os três modelos e pelas estratégias de *ensemble*.




Figura 18 – Exemplo de WSI classificada incorretamente.

A Figura 18 evidencia a causa da classificação incorreta. Observa-se que grande parte do tecido corresponde a regiões benignas, enquanto apenas uma porção menor apresenta padrão de Gleason 5. Esse desbalanceamento pode levar os modelos a aprender representações dominadas por tecido benigno, enviesando a predição para classes de menor grau.

Entretanto, do ponto de vista clínico, o sistema de graduação ISUP considera exclusivamente as regiões cancerígenas na definição do grupo final, desconsiderando o tecido benigno. Assim, apesar da predominância de áreas benignas, a classificação correta dessa WSI é ISUP 5, devido à presença de regiões tumorais de alto grau. Essa discrepância evidencia uma limitação das abordagens baseadas em *patches*, nas quais a contribuição das diferentes regiões não reflete sua relevância clínica, podendo levar à subvalorização de padrões mais agressivos.

5.9 Estudo de Caso 2 - Erro adjacente

Em contraste com o erro grave discutido anteriormente, este estudo de caso aborda um erro adjacente, no qual os modelos identificam corretamente a presença de malignidade e o padrão predominante, mas falham em capturar o padrão secundário de maior agressividade. Neste cenário, analisamos uma WSI com rótulo ISUP 5 (Gleason 4+5=9), que foi consistentemente classificada pelo como ISUP 4 (Gleason 4+4=8), tanto pelos modelos individuais quanto pelas estratégias de *ensemble*.




Figura 19 – Exemplo de WSI com erro adjacente (ISUP 5 classificada como ISUP 4).

A Figura 19 mostra a predominância de tecido tumoral na amostra, majoritariamente composto pelo padrão de Gleason 4. Entretanto, há focos minoritários de padrão 5, que são determinantes para a classificação correta como ISUP 5. Do ponto de vista computacional, a predominância de *patches* representando o padrão 4 reduz o impacto dos poucos *patches* com padrão 5 na representação final, levando ao subestadiamento. Esse comportamento evidencia a dificuldade dos modelos em capturar padrões raros, mas clinicamente decisivos, especialmente quando há forte desbalanceamento entre os padrões e diferenças morfológicas sutis entre eles.

5.10 Estudo de Caso 3 - Concordância unânime em lesão homogênea

Diferentemente dos casos anteriores, este exemplo apresenta um cenário de alta concordância, no qual todos os modelos individuais e estratégias de *ensemble* classificaram corretamente a WSI como ISUP 1.




Figura 20 – Exemplo de WSI com predição correta e unânime pelo *ensemble*.

A Figura 20 evidencia uma extensa e homogênea área tumoral composta predominantemente pelo padrão de Gleason 3. A ausência de padrões concorrentes e a ampla representatividade desse padrão favorecem a extração de características consistentes.

Do ponto de vista computacional, a predominância de *patches* representativos da classe correta reduz ambiguidades na representação global, resultando em previsões

estáveis e consistentes entre os modelos. Esse cenário evidencia a robustez das abordagens propostas na identificação de padrões homogêneos e amplamente distribuídos na amostra.

5.11 Estudo de Caso 4 - Discordância entre modelos

O quarto estudo de caso ilustra o cenário de maior incerteza diagnóstica: discordância total entre as previsões dos modelos do *ensemble*. A WSI analisada possui rótulo verdadeiro ISUP 5 (Gleason ≥ 9), caracterizando tumor de alto risco. No entanto, as previsões divergiram: B0 indicou ISUP 0 (benigno), B3 acertou ISUP 5 e B7 subestadiou para ISUP 3 (Gleason 4+3=7).




Figura 21 – Exemplo de WSI com discordância (ISUP 5 Real vs Previsões 0, 3 e 5).

A Figura 21 mostra o *overlay* da máscara de anotação. Trata-se de uma biópsia longa e fragmentada, com predominância de estroma (cinza) e epitélio benigno (azul), mas contendo áreas malignas significativas: Gleason 4 (laranja) no fragmento superior direito e focos esparsos de Gleason 5 (vermelho) na extremidade inferior direita.

Do ponto de vista computacional, o modelo B0 apresentou falha na classificação, sugerindo uma limitação na extração de características malignas imersas em tecido estromal denso. O modelo B7, por sua vez, detectou o padrão predominante de Gleason 4, porém não foi capaz de identificar os focos de Gleason 5, culminando em um

subestadiamento da amostra para o grau ISUP 3. Em contraste, o B3 foi o único modelo cuja predição refletiu corretamente a conduta de gradação clínica, evidenciando uma maior sensibilidade na detecção de focos esparsos de alta agressividade. Adicionalmente, no que tange às estratégias de ensemble, apenas a regra de agregação pelo valor máximo (*max rule*) foi capaz de consolidar uma predição final correta para este caso.

Este caso evidencia que, em biópsias complexas e fragmentadas, a simples agregação de predições por voto majoritário pode diluir diagnósticos críticos, potencialmente levando a decisões clínicas subótimas. Ressalta-se a importância de estratégias de fusão de modelos mais inteligentes, capazes de ponderar regiões de alto risco e lidar com a heterogeneidade morfológica, além de indicar que a diversidade arquitetural do *ensemble* pode ser explorada para aumentar a robustez diagnóstica.

6 Conclusão

Este trabalho apresentou uma metodologia robusta para a classificação automática dos graus ISUP em imagens histopatológicas de próstata, abordando desafios críticos como o desbalanceamento de classes, o ruído nos rótulos e a natureza ordinal intrínseca à progressão tumoral. A adoção de uma função de perda híbrida, combinando regressão ordinal e Focal Loss, elevou o índice kappa de 0,826 para 0,856 e a acurácia de 59,2% para 66,0%, evidenciando que a modelagem explícita da hierarquia entre os graus aprimora significativamente a coerência das predições. A filtragem de amostras de alta entropia proporcionou maior estabilidade ao treinamento, e o melhor desempenho foi obtido por meio de um ensemble baseado na média das probabilidades dos modelos EfficientNet-B0, B3 e B7, alcançando um kappa de 0,880 e uma acurácia de 69,8%, superando o baseline em 5,3 e 10,6 pontos percentuais, respectivamente. Observou-se, ainda, que os erros de classificação concentraram-se predominantemente em classes adjacentes, reforçando a capacidade do método de capturar a progressão ordinal dos graus ISUP. Apesar dos excelentes resultados, a principal limitação do estudo reside no uso de um único dataset, ainda que multicêntrico e heterogêneo, o que indica a necessidade de validações futuras em bases de dados externas para comprovar a robustez e a generalização do método.

6.1 Contribuições

Finalmente, as principais contribuições do método proposto desenvolvido nesta tese são descritas a seguir:

1. Proposta de uma função de perda híbrida denominada *Ordinal Focal Regression Loss*, que combina regressão ordinal e *focal loss*, explorando explicitamente a natureza hierárquica dos graus ISUP e mitigando o desbalanceamento entre classes no conjunto de dados PANDA;
2. Desenvolvimento de um método de filtragem de amostras ruidosas baseado na entropia de Shannon, utilizando um *ensemble* de modelos EfficientNet para identificar e remover instâncias de alta incerteza preditiva do conjunto de treinamento, melhorando a estabilidade e a capacidade de generalização dos modelos;
3. Avaliação sistemática das variantes EfficientNet-B0, B3 e B7 na tarefa de classificação dos graus ISUP, demonstrando que arquiteturas mais compactas podem superar modelos de maior profundidade quando aplicadas a conjuntos de dados histopatológicos com ruído e desbalanceamento;

- 4. Proposta e análise de um *ensemble* de variantes do EfficientNet, com avaliação de três estratégias de combinação (média, máximo e votação majoritária).

6.2 Próximas Atividades

Como próximas atividades para o desenvolvimento da tese, sugere-se algumas atividades:

- Atividade 1: Empregar *frameworks* de otimização bayesiana (*Optuna*, *Ray Tune*) para calibração do fator de ponderação λ na função de perda ordinal;
- Atividade 2: Investigar classificadores especialistas para classes intermediárias, visando reduzir erros de confusão;
- Atividade 3: Explorar estratégias de *ensemble*, incluindo métodos baseados em *Oracle*, meta-aprendizado e agregação guiada por incerteza;
- Atividade 4: Avaliar diferentes arquiteturas de *backbone*, como *ConvNeXt* e *EfficientNetV2*;
- Atividade 5: Produzir e submeter artigos científicos relacionados ao método proposto;
- Atividade 6: Realizar a redação e defesa da tese.

A Tabela 8 apresenta o cronograma previsto para as atividades. Para facilitar a visualização, o período de abril de 2026 a janeiro de 2027 foi agrupado em trimestres.

Tabela 8 – Cronograma das atividades

Atividade	T1	T2	T3
Atividade 1	X		
Atividade 2	X	X	
Atividade 3	X	X	
Atividade 4	X	X	
Atividade 5	X	X	X
Atividade 6			X

Referências

AL-TURAIKI, I. et al. A deep learning approach for intrusion detection in internet of things using focal loss function. **Internet of Things**, Elsevier, 2021. Citado 2 vezes nas páginas 32 e 33.

ALBAHRI, O. S.; ALBAHRI, A. S.; MOHAMMED, K. I.; ZAIDAN, A.; ZAIDAN, B. B.; HASHIM, M.; SALMAN, O. H.; ALAA, M.; ALSALEM, M. A. Expert system research for prostate cancer: A literature review. **Computers in Biology and Medicine**, Elsevier, v. 145, p. 105487, 2022. Citado na página 14.

ALI, I.; KHAN, A.; KHAN, M.; AHMAD, R.; ULLAH, I. Shannon entropy in artificial intelligence and its applications based on information theory. **Entropy**, v. 25, n. 2, p. 364, 2023. Citado na página 44.

ALICI-KARACA, D.; AKAY, B. An efficient deep learning model for prostate cancer diagnosis. **IEEE Access**, IEEE, v. 12, p. 150776–150790, 2024. Citado 2 vezes nas páginas 20 e 56.

ARVANITI, E.; FRICKER, K. S.; MORET, M.; RUPP, N.; HERMANN, T.; FANKHAUSER, C.; WEY, N.; WILD, P. J.; RÜSCHOFF, J.; CLAASSEN, M. A pyramidal cnn-based gleason grading system using digitized prostate biopsy specimens. **IEEE Transactions on Medical Imaging**, IEEE, v. 37, n. 3, p. xxx–xxx, 2018. Citado 2 vezes nas páginas 17 e 56.

BACCIANELLA, S.; ESULI, A.; SEBASTIANI, F. Neural network for ordinal classification of imbalanced data. **Pattern Recognition Letters**, Elsevier, 2020. Citado na página 32.

BARATLOO, A.; HOSSEINI, M.; NEGIDA, A.; ASHAL, G. E. Part 1: Simple definition and calculation of accuracy, sensitivity and specificity. **Emergency**, Shahid Beheshti University of Medical Sciences, v. 3, n. 2, p. 48–49, 2015. Citado na página 38.

BERGENGREN, O. et al. 2022 update on prostate cancer epidemiology and risk factors—a systematic review. **European Urology**, v. 84, n. 2, p. 191–206, 2023. Citado na página 22.

BHATTACHARYYA, R.; PAL, S.; MITRA, S. Efficient self-supervised grading of prostate cancer pathology. **IEEE Transactions on Systems, Man, and Cybernetics: Systems**, 2026. Citado 3 vezes nas páginas 19, 56 e 57.

BHATTACHARYYA, R.; ROY, P.; BANERJI, S.; MITRA, S. Efficient grading of prostate cancer wsi with deep learning. In: SPIE. **Medical Imaging 2024: Digital and Computational Pathology**. [S.l.], 2024. v. 12933, p. 1293305. Citado na página 18.

BHATTACHARYYA, R.; ROY, P.; BANERJI, S.; MITRA, S. Efficient grading of prostate cancer wsi with deep learning. In: SPIE. **Medical Imaging 2024: Digital and Computational Pathology**. [S.l.], 2024. Citado 2 vezes nas páginas 56 e 57.

BRAY, F.; LAVERSANNE, M.; SUNG, H.; FERLAY, J.; SIEGEL, R. L.; SOERJOMATARAM, I.; JEMAL, A. Global cancer statistics 2022: Globocan estimates of incidence and mortality worldwide for 36 cancers in 185 countries. **CA: A Cancer Journal for Clinicians**, v. 74, n. 3, p. 229–263, 2024. Citado na página 14.

BULTEN, W.; PINCKAERS, H.; BOVEN, H. van; VINK, R.; BEL, T. de; GINNEKEN, B. van; LAAK, J. van der; KAA, C. Hulsbergen-van de; LITJENS, G. Automated deep-learning system for Gleason grading of prostate cancer using biopsies: a diagnostic study. **The Lancet Oncology**, v. 21, n. 2, p. 233–241, 2020. Citado na página 14.

CAMPANELLA, G.; HANNA, M. G.; GENESLAW, L.; MIRAFLORES, A.; SILVA, V. W. K.; BUSAM, K. J.; BROGI, E.; REUTER, V. E.; KLIMSTRA, D. S.; FUCHS, T. J. Clinical-grade computational pathology using weakly supervised deep learning on whole slide images. **Nature Medicine**, v. 25, n. 9, p. 1301–1309, 2019. Citado na página 14.

CHEN, N.; ZHOU, Q. The evolving gleason grading system. **Chinese Journal of Cancer Research**, v. 28, n. 1, p. 58–64, 2016. Citado 2 vezes nas páginas 25 e 26.

CINAR, I.; CINAR, E. Assessment of interobserver variability in gleason grading for prostate carcinoma. **North Clin Istanbul**, v. 12, n. 3, p. 337–343, 2025. Citado na página 50.

COHEN, J. Weighted kappa: Nominal scale agreement with provision for scaled disagreement or partial credit. **Psychological Bulletin**, v. 70, n. 4, p. 213–220, 1968. Citado na página 38.

CRAWFORD, E. D. Epidemiology of prostate cancer. **Urology**, v. 62, n. 6, p. 3–12, 2003. Citado na página 23.

DIETTERICH, T. G. Ensemble methods in machine learning. **International Workshop on Multiple Classifier Systems**, Springer, p. 1–15, 2000. Citado na página 37.

EFRON, B. Bootstrap methods: Another look at the jackknife. **The Annals of Statistics**, Institute of Mathematical Statistics, v. 7, n. 1, p. 1–26, 1979. Citado na página 38.

EPSTEIN, J. I.; EGEVAD, L.; AMIN, M. B.; DELAHUNT, B.; SRIGLEY, J. R.; HUMPHREY, P. A. The 2014 International Society of Urological Pathology (ISUP) consensus conference on gleason grading of prostatic carcinoma: Definition of grading patterns and proposal for a new grading system. **The American Journal of Surgical Pathology**, v. 40, n. 2, p. 244–252, 2016. Citado 3 vezes nas páginas 14, 25 e 26.

ESTEVA, A.; KUPREL, B.; NOVOA, R. A.; KO, J.; SWETTER, S. M.; BLAU, H. M.; THRUN, S. Dermatologist-level classification of skin cancer with deep neural networks. **nature**, Nature Publishing Group UK London, v. 542, n. 7639, p. 115–118, 2017. Citado na página 34.

GONZALEZ, R.; WOODS, R. **Digital image processing**. [S.l.]: Pearson, Prentice Hall, 2008. 954 p. Citado 2 vezes nas páginas 28 e 29.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep learning**. [S.l.]: MIT press, 2016. 800 p. Citado 2 vezes nas páginas 30 e 34.

HAMMERICH, K. H.; AYALA, G. E.; WHEELER, T. M. Anatomy of the prostate gland and surgical pathology of prostate cancer. In: HRICAK, H.; SCARDINO, P. T. (Ed.). **Prostate Cancer**. [S.l.]: Cambridge University Press, 2009. Citado na página 23.

HAN, S. et al. Ordinal convolutional neural networks for predicting rdcc positive valence psychiatric symptom severity scores. **Psychiatry Research: Neuroimaging**, Elsevier, 2021. Nenhuma citação no texto.

- HOSSAIN, M. S.; RAHMAN, M. S.; AHMED, M.; HUSSEN, A.; ULLAH, Z.; JAMJOOM, M. Automated gleason grading of prostate cancer from low-resolution histopathology images using an ensemble network of cnn and transformer models. **Computers, Materials & Continua**, v. 84, n. 2, p. 3194–3215, 2025. Citado 2 vezes nas páginas 8 e 27.
- HU, J.; SHEN, L.; SUN, G. Squeeze-and-excitation networks. In: **Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)**. Salt Lake City, UT, USA: [s.n.], 2018. p. 7132–7141. Citado na página 14.
- IKROMJANOV, K.; SUMON, R. I.; BHATTACHARJEE, S.; KIM, H.-C.; HWANG, Y.-B.; CHOI, H.-K. Whole slide image analysis and detection of prostate cancer using vision transformers. In: **Proceedings of the International Conference/Publication on Medical Imaging and AI**. [S.l.: s.n.], 2021. Citado 2 vezes nas páginas 20 e 56.
- KABIR, S.; SARMUN, R.; SAADY, R. M. A.; VRANIC, S.; MURUGAPPAN, M.; CHOWDHURY, M. E. H. Automating prostate cancer grading: A novel deep learning framework for automatic prostate cancer grade assessment using classification and segmentation. **Journal of Imaging Informatics in Medicine**, v. 38, p. 3992–4014, 2025. Citado 3 vezes nas páginas 18, 42 e 56.
- KOSOKO, I.; GARG, A.; JAIN, S.; HEWAGE, P. Leveraging deep learning and explainable ai for diagnosis of prostate cancer. In: **Proceedings of the International Conference on Applied Artificial Intelligence in Medical Imaging**. Bolton, United Kingdom: [s.n.], 2024. Citado 2 vezes nas páginas 19 e 56.
- KUNCHEVA, L. I. **Combining Pattern Classifiers: Methods and Algorithms**. [S.l.]: Wiley-Interscience, 2004. Citado na página 37.
- LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, Nature Publishing Group, v. 521, n. 7553, p. 436–444, 2015. Citado na página 31.
- LECUN, Y.; BOTTOU, L.; BENGIO, Y.; HAFFNER, P. Gradient-based learning applied to document recognition. **Proceedings of the IEEE**, v. 86, n. 11, p. 2278–2324, 1998. Citado na página 34.
- LIN, J. et al. A focal loss and sequential analytics approach for liver disease classification. **Healthcare Analytics**, 2022. Citado na página 32.
- MAAS, A. L.; HANNUN, A. Y.; NG, A. Y. Rectifier nonlinearities improve neural network acoustic models. In: **Proc. ICML**. [S.l.: s.n.], 2013. v. 30, n. 1, p. 3. Citado na página 29.
- MATLAGA, B. R.; ESKEW, L. A.; MCCULLOUGH, D. L. Prostate biopsy: indications and technique. **The Journal of Urology**, Elsevier, v. 169, n. 1, p. 12–19, 2003. Citado na página 24.
- NAGPAL, K.; FOOTE, D.; LIU, Y.; CHEN, P. H. C.; WULCZYN, E.; TAN, F.; OLSON, N.; SMITH, J. L.; MOHTASHAMIAN, A.; WREN, J. H.; CORRADO, G. S.; MACDONALD, L.; PENG, L. H.; AMIN, M. B.; EVANS, A. J.; SANGOI, A. R.; MERMEL, C. H.; HIPPE, J. D.; STUMPE, M. C. Development and validation of a deep learning algorithm for improving Gleason scoring of prostate cancer. **npj Digital Medicine**, v. 2, p. 48, 2019. Citado na página 14.

- National Cancer Institute. **Prostate Cancer Prevention (PDQ®)–Patient Version**. National Institutes of Health, 2024. Acesso em: 08 mar. 2025. Disponível em: <<https://www.cancer.gov/types/prostate/patient/prostate-prevention-pdq>>. Citado na página 23.
- NEUMAIER, M. **Biópsia da Próstata - Entenda**. Curitiba, PR, Brasil, 2023. Acesso em: 8 mar. 2026. Disponível em: <<https://urologia.curitiba.br/biopsia-de-prostata/>>. Citado 2 vezes nas páginas 8 e 25.
- NOVOTNY, A.; BEBIS, G.; TAVAKKOLI, A.; NICOLESCU, M. Ensembles of deep one-class classifiers for multi-class image classification. **Machine Learning with Applications**, Elsevier, v. 19, p. 100621, 2025. Citado na página 37.
- OZKAN, T. A.; ERUYAR, A. T.; CEBECI, O. O.; MEMIK, O.; OZCAN, L.; KUSKONMAZ, I. Interobserver variability in gleason histological grading of prostate cancer. **Scandinavian Journal of Urology**, v. 50, n. 6, p. 420–424, 2016. Epub 2016 Jul 14. Disponível em: <<https://doi.org/10.1080/21681805.2016.1206619>>. Citado na página 50.
- PANDA Challenge. **Prostate cANcer graDe Assessment Challenge**. [S.l.]: Kaggle, 2020. <<https://www.kaggle.com/c/prostate-cancer-grade-assessment>>. Accessed: 2024-01-01. Citado 2 vezes nas páginas 15 e 42.
- PERDANA, N.; MOCHTAR, C.; UMBAS, R.; HAMID, A. The risk factors of prostate cancer and its prevention: a literature review. **Acta Medica Indonesiana**, v. 48, n. 3, p. 228–238, 2016. Citado na página 22.
- PLACEHOLDER, A. Ordinal loss methodology and applications. **Journal Placeholder**, 2023. Nenhuma citação no texto.
- RAWLA, P. Epidemiology of prostate cancer. **World Journal of Oncology**, v. 10, n. 2, p. 63–89, 2019. Citado 2 vezes nas páginas 22 e 23.
- REBELLO, R. J. et al. Prostate cancer. **Nature Reviews Disease Primers**, v. 7, n. 1, p. 9, 2021. Citado na página 22.
- RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. **Nature**, v. 323, p. 533–536, 1986. Citado na página 30.
- SENGUPTA, S.; BASAK, S.; SAIKIA, P.; PAUL, S.; TSALAVOUTIS, V.; ATIAH, F.; RAVI, V.; PETERS, A. A review of deep learning with special emphasis on architectures, applications and recent trends. **Knowledge-Based Systems**, p. 105596, 2020. ISSN 0950-7051. Citado na página 29.
- SIEGEL, R. L.; GIAQUINTO, A. N.; JEMAL, A. Cancer statistics, 2024. **CA: A Cancer Journal for Clinicians**, v. 74, n. 1, p. 12–49, 2024. Citado na página 14.
- TAN, M.; LE, Q. V. EfficientNet: Rethinking model scaling for convolutional neural networks. In: **Proceedings of the 36th International Conference on Machine Learning**. Long Beach, CA, USA: [s.n.], 2019. p. 6105–6114. Citado 6 vezes nas páginas 8, 9, 14, 34, 35 e 36.
- WOLPERT, D. H. Stacked generalization. **Neural Networks**, Elsevier, v. 5, n. 2, p. 241–259, 1992. Citado na página 37.

XIANG, J.; WANG, X.; WANG, X.; ZHANG, J.; YANG, S.; YANG, W.; HAN, X.; LIU, Y. Automatic diagnosis and grading of prostate cancer with weakly supervised learning on whole slide images. **Computers in Biology and Medicine**, Elsevier, v. 152, p. 106340, 2023. ISSN 0010-4825. Citado 2 vezes nas páginas [17](#) e [56](#).