

Classificação de Graus ISUP em Imagens Histopatológicas de Próstata utilizando EfficientNet e Aprendizado com Perda Ordinal Focal

1

Abstract. *The manual histopathological evaluation of prostate cancer in WSIs is subject to interobserver and intraobserver variability. To mitigate this issue, this work proposes the automatic classification of ISUP grade groups using Convolutional Neural Networks. The methodology employed the PANDA dataset, applying entropy-based noise reduction and patch extraction. EfficientNet models (B0, B3, and B7) were trained using the Ordinal Focal Loss function to preserve the ordinal progression of the disease and mitigate class imbalance. The best-performing model was EfficientNet-B0, which achieved a quadratic kappa of 0.856 and an accuracy of 66.9%. The approach preserved the ordinal integrity of the grades, making extreme errors infrequent and demonstrating its potential clinical viability.*

Resumo. *A avaliação histopatológica manual do câncer de próstata em WSIs está sujeita a variabilidades interobservador e intraobservador. Para mitigar esse problema, este trabalho propõe a classificação automática dos grupos de graus ISUP utilizando Redes Neurais Convolucionais. A metodologia utilizou o dataset PANDA, aplicando a redução de ruído por entropia e a extração de patches. Os modelos EfficientNet (B0, B3 e B7) foram treinados com a função Ordinal Focal Loss para preservar a progressão da doença e mitigar o desbalanceamento das classes. O melhor modelo foi EfficientNet-B0 que alcançou kappa quadrático de 0,856 e acurácia de 66,9%. A abordagem preservou a integridade ordinal dos graus, tornando pouco frequentes os erros extremos e demonstrando sua viabilidade clínica.*

1. Introdução

O câncer de próstata é uma das neoplasias malignas mais comuns em homens, representando um desafio significativo para a saúde pública [Siegel et al. 2024]. Estatísticas coletadas pela *International Agency for Research on Cancer* indicam que, em 2022, essa neoplasia foi a quarta mais comum no mundo, correspondendo a 7,3% de todos os casos de câncer [Bray et al. 2024]. Neste contexto, a gradação tumoral desempenha papel central na definição do manejo clínico e do prognóstico. O sistema de *Gleason*, baseado na soma dos dois padrões histológicos predominantes, evoluiu para o sistema de gradação proposto pela *International Society of Urological Pathology* (ISUP), organizado em cinco grupos que variam de 1 a 5. Este sistema fornece uma estratificação prognóstica aprimorada e é amplamente utilizado na prática clínica [Epstein et al. 2016].

A avaliação histopatológica tradicional de imagens de lâminas inteiras (*Whole-Slide Images* – WSIs) depende da análise manual realizada por patologistas. Neste sentido, tendo em vista a quantidade de campos a serem observados em uma única lâmina,

o processo de análise do exame torna-se uma tarefa repetitiva e exige jornadas de trabalho prolongadas, foco contínuo e especialização do profissional. Nesse sentido, a fadiga decorrente da análise contínua durante esse processo pode introduzir variabilidades inter e intraobservador nos resultados, o que influencia diretamente o manejo clínico do paciente [Bulten et al. 2020]. Com isso, nos últimos anos, tem sido observado um crescimento significativo no uso de técnicas de Inteligência Artificial (IA) para automatizar a análise de exames histopatológicos e auxiliar no diagnóstico do câncer de próstata, com o intuito de mitigar os problemas citados anteriormente [Albahri et al. 2022].

Neste contexto, as Redes Neurais Convolucionais (RNCs) têm representado o *estado-da-arte* na análise de imagens médicas [Campanella et al. 2019], sendo capazes de extrair características relevantes e combinar padrões visuais complexos para identificar determinadas condições patológicas [Araújo et al. 2021]. Tal capacidade torna essa abordagem particularmente promissora para a análise automatizada dos padrões de Gleason e dos grupos de grau ISUP. Com isso, a abordagem contribui para a padronização do diagnóstico do câncer de próstata e para a redução das variabilidades intra e interobservador, inerentes à avaliação histopatológica convencional. Assim, além de reduzir o tempo de diagnóstico, a abordagem viabilizaria um manejo clínico mais preciso e reprodutível.

Este trabalho propõe um pipeline estruturado para a classificação automática dos grupos de grau ISUP em imagens histopatológicas de próstata. As principais contribuições são: (i) uma função de perda híbrida que combina penalização ordinal e perda focal, considerando a natureza hierárquica do problema e o desbalanceamento da base de dados; (ii) um método automatizado de remoção de ruído baseado na incerteza estimada pela média das previsões dos modelos EfficientNet (B0, B1, B2 e B3); e (iii) a avaliação comparativa das arquiteturas EfficientNet B0, B3 e B7.

2. Trabalhos Relacionados

Nesta seção, é realizada uma revisão dos principais trabalhos da literatura que investigam a aplicação de métodos computacionais na análise de imagens histopatológicas para o diagnóstico do câncer de próstata, evidenciando as abordagens adotadas, os conjuntos de dados utilizados, os resultados obtidos e as lacunas identificadas.

No trabalho de [Xiang et al. 2023], os autores propuseram a ferramenta GCN-MIL, que utiliza uma Rede Neural de Grafos para agregar características espaciais de *patches* em lâminas de WSI. O modelo incorpora a estratégia de *Robust Training*, que filtra iterativamente amostras de alta incerteza para mitigar o impacto de rótulos ruidosos e inconsistentes, alcançando um Kappa quadrático de 93,10% no conjunto interno do desafio PANDA. Entretanto, a abordagem apresenta limitações metodológicas relevantes. O emprego da função de perda *Cross-Entropy* tradicional, que trata as graduações ISUP como classes nominais independentes, ignora a hierarquia biológica inerente à progressão do câncer de próstata, o que pode comprometer a coerência ordinal das previsões. Ademais, o uso da ResNet50 como extrator de características, uma arquitetura clássica de RNC, pode restringir tanto a capacidade de representação morfológica quanto a eficiência computacional em comparação com modelos mais modernos.

Em [Kosoko et al. 2024], os autores avaliaram diferentes arquiteturas de RNCs, combinadas à técnica de *Grad-CAM*, para a interpretação das decisões do modelo. O conjunto de dados utilizado foi o SICAPv2, composto por *patches* extraídos de WSIs

coradas em H&E, com anotação em nível de pixel, totalizando 4417 amostras não cancerosas: 1635 do grupo GG3, 3622 do GG4 e 665 do GG5. Entre as arquiteturas avaliadas, o modelo VGG19 apresentou o melhor desempenho, alcançando AUC-ROC de 85,0% e métricas médias de acurácia, precisão e *recall* em torno de 75,0%. Entretanto, o estudo apresenta lacunas significativas. A ausência de validação clínica externa compromete a avaliação da capacidade de generalização do modelo em cenários interinstitucionais. Ademais, o emprego exclusivo de arquiteturas clássicas de RNCs restringe a capacidade de representação morfológica e o desempenho em conjuntos de dados mais heterogêneos.

No estudo de [Afifi et al. 2024], a detecção de câncer de próstata foi formulada como um problema de classificação binária, no qual foram avaliadas as arquiteturas InceptionV3, ResNet50 e InceptionResNetV2 em conjunto com as técnicas de *Transfer Learning* e *Fine-Tuning*, sobre imagens WSI provenientes do *Radboud University Medical Center* e do *Karolinska Institute*. O modelo InceptionResNetV2 apresentou o melhor desempenho, atingindo acurácia de 91,80%. Entretanto, a formulação binária ignora a graduação histológica da doença, o que limita a utilidade clínica do modelo, uma vez que a distinção entre graus de malignidade é determinante para o planejamento terapêutico. Ademais, o uso exclusivo da acurácia é insuficiente para uma avaliação robusta, especialmente em contextos de desequilíbrio entre as classes.

Em [Alici-Karaca and Akay 2024], os autores incorporaram mecanismos de atenção à arquitetura EfficientNet-B4 para o diagnóstico e a graduação do câncer de próstata, utilizando o conjunto de dados público DiagSet. A abordagem contempla três níveis de classificação: binária (presença ou ausência de câncer), quatro classes (tecido normal, estroma, alterações benignas e câncer) e oito classes (tecido normal, estroma, artefatos, inflamação, hiperplasia benigna, Gleason 3, 4 e 5). Os resultados apresentam acurácias de 96,18%, 94,86%, 93,32%, respectivamente. Entretanto, o uso exclusivo de fragmentos de WSI limita a representatividade do cenário clínico real, e o reporte restrito à acurácia é insuficiente para uma avaliação robusta diante do desequilíbrio entre as classes. Ademais, a aplicação da classificação binária limita a utilidade clínica do modelo.

De maneira geral, os trabalhos revisados apresentam algumas limitações em comum. No que diz respeito à avaliação de desempenho, os estudos de [Afifi et al. 2024, Alici-Karaca and Akay 2024] reportam apenas a acurácia, uma métrica insuficiente para uma avaliação robusta em cenários de desbalanceamento entre as classes. O emprego de RNCs clássicas, como ResNet50 e VGG19, como extratores de características [Xiang et al. 2023, Kosoko et al. 2024] pode restringir a capacidade de representação morfológica em comparação com arquiteturas recentes. Ademais, estudos que adotam classificação binária [Afifi et al. 2024, Alici-Karaca and Akay 2024] ignoram a graduação histológica da doença, o que limita a utilidade clínica dos modelos, já que a distinção entre graus de malignidade é determinante para o planejamento terapêutico.

Com o intuito de superar as limitações identificadas, o presente trabalho propõe uma metodologia estruturada que contempla o tratamento de rótulos ruidosos, a utilização de arquiteturas de *Deep Learning* e de estratégias de *Ensemble* para potencializar a robustez das inferências. Além disso, a natureza ordinal da progressão biológica da doença é incorporada à modelagem por meio de uma função de perda sensível à hierarquia entre os grupos de grau ISUP, o que promove maior coerência e utilidade clínica das predições. Por fim, os modelos são avaliados por meio de um conjunto de métricas capaz de refletir,

de forma mais robusta, seu desempenho.

3. Materiais e Método

Esta seção apresenta os procedimentos metodológicos adotados para o desenvolvimento e a avaliação da abordagem proposta. O método, ilustrado na Figura 1, foi estruturado em três etapas principais: (i) materiais, (ii) pré-processamento e (iii) extração de características e treinamento dos modelos. Cada etapa é descrita detalhadamente nas seções subsequentes.




Figura 1. Método Proposto

3.1. Materiais

Neste trabalho foi utilizada a base de dados PANDA (*Prostate Cancer Grade Assessment*), composta por aproximadamente 10.616 imagens histopatológicas completas (*Whole Slide Images* – WSIs) de biópsias prostáticas [PANDA Challenge 2020]. Esse conjunto de dados foi disponibilizado no contexto do desafio PANDA, promovido na plataforma Kaggle, e tem sido amplamente utilizado em pesquisas voltadas à classificação automática do câncer de próstata. As imagens presentes no banco de dados são anotadas com o score e o grau de Gleason, fornecendo rótulos clínicos utilizados na graduação da doença. Neste estudo, foi utilizada exclusivamente a versão pública da base de dados, sem acesso ao conjunto privado disponibilizado durante o desafio.

Os dados foram coletados em dois centros médicos distintos, *Radboud University Medical Center* e *Karolinska Institute*, o que introduz variabilidade institucional nas imagens. Essa variabilidade está associada a diferenças nos protocolos de preparação das lâminas, digitalização e critérios de anotação, tornando o cenário experimental mais próximo da prática clínica real.

Além disso, o conjunto de dados apresenta ruídos inerentes ao processo de aquisição e anotação das lâminas. Entre eles, destacam-se artefatos visuais, como marcas de caneta realizadas por patologistas durante a análise das lâminas, conforme ilustrado na

Figura 2. Também há ruídos relacionados à rotulação das imagens, como a discordância entre anotadores na atribuição dos graus histopatológicos. Esses fatores aumentam a complexidade da tarefa de classificação automática e refletem desafios presentes na prática da patologia digital.




Figura 2. Exemplo de artefato visual presente em uma WSI da base PANDA. À esquerda, apresenta-se a lâmina completa com a região de interesse destacada em vermelho. À direita, observa-se uma ampliação da região selecionada, evidenciando uma marca de caneta sobre o tecido prostático.

Outro aspecto relevante da base de dados é a distribuição desigual das amostras entre as seis classes de graduação ISUP (ISUP 0 a ISUP 5). Destaca-se que o grau ISUP 0 indica ausência de lesão maligna. Observa-se maior concentração de amostras nas classes ISUP 0 e ISUP 1, enquanto as demais apresentam menor representatividade. A distribuição completa das amostras é apresentada na Figura 3.




Figura 3. Distribuição das amostras da base PANDA

3.2. Pré-processamento

Na fase de pré-processamento, os dados foram inicialmente divididos em conjuntos de treinamento e teste, garantindo a separação adequada entre as etapas de ajuste e de

avaliação do modelo. Em seguida, aplicou-se uma técnica de redução de ruído baseada em entropia e, por fim, realizou-se a extração de *patches* a partir da densidade de informação de cada lâmina.

Para a etapa de redução de ruído, utilizaram-se quatro arquiteturas baseadas no *backbone* EfficientNet (B0, B1, B2 e B3) para calcular a entropia de Shannon, a fim de quantificar a incerteza das predições [Ali et al. 2023]. A entropia média dos quatro modelos foi calculada para cada amostra do conjunto de treinamento, e o percentil superior de 10% foi selecionado, formando um banco de dados de amostras potencialmente ruidosas. A partir desse conjunto, avaliaram-se quatro cenários: manutenção integral dos dados e remoção de 100%, 50% e 20% das imagens identificadas como ruidosas. O melhor desempenho foi obtido com a remoção de 20% dessas imagens (180 amostras), indicando que muitas amostras, apesar de apresentarem alta incerteza, contribuem com informações relevantes para o problema no contexto do banco de dados.

Na etapa final do pré-processamento, a partir das WSIs do PANDA, foram geradas novas imagens por meio da extração de *patches*, selecionando-se regiões de tecido relevante. Essa abordagem foi necessária porque o material histológico ocupa apenas parte da lâmina; sem a extração, o processamento direto das WSIs originais envolveria alto custo computacional e análise de grandes áreas sem tecido, como ilustrado na Figura 4.




Figura 4. Exemplo de imagem do banco de dados PANDA

Para definir a melhor estratégia de extração, avaliou-se a reorganização das imagens em *patches* nas configurações 5×5 (25 *patches*), 6×6 (36 *patches*) e 7×7 (49 *patches*). Conforme ilustrado na Figura 5, a configuração 5×5 apresenta maior densidade de tecido e menor proporção de áreas vazias, mas o número reduzido de fragmentos pode levar à perda de regiões potencialmente relevantes, prejudicando a representação de padrões lesionais mais sutis. Por outro lado, a configuração 7×7 preserva maior cobertura espacial da lâmina, porém inclui muitas regiões sem tecido e gera imagens de alta dimensionalidade (1792×1792), o que aumenta a demanda por memória e tempo de processamento. Diante disso, optou-se pela configuração intermediária de 36 *patches*, que preserva a maior parte da informação tecidual, mantendo a dimensionalidade relativamente reduzida (1536×1536), equilibrando qualidade, cobertura e eficiência computacional.




Figura 5. Ilustração da extração de *patches* em diferentes tamanhos: 5x5 (à esquerda), 6x6 (no centro) e 7x7 (à direita).

3.3. Extração de características e treinamento dos modelos

Nesta seção, apresenta-se a abordagem proposta para o treinamento dos classificadores individuais, incluindo a definição dos hiperparâmetros, das estratégias de regularização e da função de perda. Após o pré-processamento, iniciaram-se o treinamento e a avaliação dos classificadores. A EfficientNet-B0 foi utilizada como modelo-base para ajustar os hiperparâmetros. Com a configuração definida, os experimentos foram estendidos às EfficientNet-B3 e B7, permitindo comparar diferentes níveis de complexidade da mesma família e analisar o impacto da maior capacidade representacional no desempenho e na generalização.

Inicialmente, adotou-se a *Binary Cross-Entropy* (BCE) como função de perda *baseline*, em virtude de sua ampla utilização em cenários de classificação multirrotulo. A partir dessa configuração inicial, foram conduzidos experimentos exploratórios com o objetivo de analisar a estabilidade do treinamento e o impacto dos hiperparâmetros na capacidade de generalização do modelo. Foram avaliadas variações na taxa de aprendizado, no número de camadas descongeladas durante o *fine-tuning* e nas estratégias de regularização por meio de *Dropout*. Para a seleção da melhor combinação de hiperparâmetros, empregou-se uma busca sistemática em grade, aplicada ao modelo EfficientNet-B0. Essa busca foi realizada utilizando um subconjunto correspondente a 20% do conjunto de treinamento, reservado para validação interna, permitindo a identificação da configuração com melhor desempenho antes do treinamento final.

Apesar da avaliação dessas configurações no treinamento, observou-se um desempenho estagnado que poderia estar associado não apenas à escolha dos hiperparâmetros, mas também à formulação da própria função de perda. Considerando que a graduação do câncer de próstata possui natureza ordinal, em que os erros entre classes adjacentes são menos severos do que entre classes mais distantes, o problema foi reformulado como uma regressão ordinal.

Nessa formulação, a predição do grau ISUP não é tratada como um problema multiclasse com categorias independentes, e sim como uma sequência de classificações binárias cumulativas. Para um grau ISUP $k \in \{0, \dots, 5\}$, o rótulo é codificado como um vetor binário cumulativo, no qual os k primeiros elementos assumem valor 1 e os demais, 0; por exemplo, o grau 3 é representado por $[1, 1, 1, 0, 0]$. A perda ordinal é então aplicada

de forma independente a cada limiar do vetor, o que faz com que o erro total corresponda à soma das discrepâncias cumuladas. Essa modelagem impõe uma penalização proporcional à distância entre classes, de modo que erros mais distantes acarretam maior custo, preservando a estrutura hierárquica do problema.

Para mitigar o desbalanceamento dos dados (Seção 3.1), a perda ordinal foi combinada à *Focal Loss* [Lin et al. 2017, Dina et al. 2023, Chen 2026]. Esta função modula a entropia cruzada para reduzir a influência de instâncias classificadas com alta confiança, priorizando amostras de maior incerteza diagnóstica. No presente estudo, configurou-se o fator de foco $\gamma = 2,0$ para atenuar a contribuição de exemplos fáceis e o peso $\alpha = 0,25$ para equilibrar a importância relativa entre as classes. Essa estratégia direciona a otimização para os casos mais complexos e sub-representados, fundamentais para a distinção precisa entre os graus ISUP.

3.4. Métricas de avaliação

Foram utilizadas as métricas de **acurácia** e de κ_{quad} (Kappa Quadrático Ponderado). A acurácia mensura a proporção de predições corretas em relação ao total de instâncias avaliadas [Baldi et al. 2000]. Já o κ_{quad} quantifica o grau de concordância entre as classes preditas e as reais, incorporando penalizações proporcionais à magnitude do erro, sendo especialmente adequado para problemas de natureza ordinal [Cohen 1968].

A variabilidade das métricas e os respectivos intervalos de confiança foram estimados por meio de bootstrap não paramétrico [Efron 1979]. A partir das predições do conjunto de teste, geraram-se 1.000 reamostragens com reposição, preservando-se a dimensão do conjunto original. Para cada iteração, recalcularam-se os indicadores de desempenho, permitindo derivar a média, o desvio padrão e o intervalo de confiança (IC) de 90% através dos percentis 5% e 95%. Esta abordagem garante uma estimativa de incerteza robusta, prescindindo de pressupostos paramétricos sobre a distribuição dos dados.

4. Resultados

Esta seção apresenta o ambiente de implementação, a seleção do melhor pipeline de configurações e o impacto da função de perda híbrida Ordinal-Focal.

4.1. Ambiente de Implementação

Os experimentos foram conduzidos em uma estação Linux com GPU RTX 3060, CPU AMD Ryzen 5 5600X e 32 GB de RAM DDR4. Além disso, utilizou-se PyTorch, CUDA e OpenSlide para a leitura de WSIs e a extração de *patches*.

4.2. Etapa inicial - Configurando hiperparâmetros

A etapa inicial de treinamento, conduzida conforme descrito na Seção 3, permitiu definir a melhor configuração de hiperparâmetros do modelo. Os valores avaliados e a configuração selecionada são apresentados na Tabela 1.

4.3. Impacto da Remoção de Ruído e Formulações de Perda

A Tabela 2 apresenta a evolução incremental do desempenho da *EfficientNet-B0*. As estratégias foram aplicadas cumulativamente, de modo que cada configuração incorpora as melhorias da etapa anterior.

Parâmetro	Valores avaliados	Valor selecionado
Taxa de aprendizado	3×10^{-4} , 3×10^{-3} , 1×10^{-4}	3×10^{-4}
Número de épocas	50	50
Camadas descongeladas (fine-tuning)	100, 150	150
<i>Dropout</i>	0.4, 0.5, 0.6	0.4
Tamanho do <i>batch</i>	2	2
Função de perda	BCE	BCE
Otimizador	Adam	Adam

Tabela 1. Hiperparâmetros avaliados e configuração selecionada após a busca em grade.

Inicialmente, a remoção de ruído foi aplicada ao modelo *baseline*, elevando o κ_{quad} de 0,826 para 0,833. Esse resultado indica que a correção de inconsistências no conjunto de dados contribuiu para maior estabilidade no treinamento. Na sequência, mantendo a remoção de ruído, a substituição da BCE pela perda ordinal promoveu um salto para 0,851. Esse avanço demonstra que a modelagem explícita da relação de ordem entre as classes melhora a qualidade das predições. Essa configuração também apresentou o menor desvio padrão (0,009), indicando maior estabilidade. Por fim, a estratégia híbrida foi aplicada à formulação ordinal, resultando no melhor desempenho observado ($\kappa_{\text{quad}} = 0,856$). A combinação permitiu tratar simultaneamente a estrutura ordinal das classes e o desbalanceamento do conjunto de dados. No total, a sequência de refinamentos resultou em um ganho absoluto de 3% em relação ao modelo *baseline*.

Configuração	Kappa Quadrático			Acurácia (%)		
	Resultado	Std	CI 95%	Resultado	Std	CI 95%
BCE (<i>baseline</i>)	0,826	0,012	[0,806; 0,846]	0,592	0,012	[0,572; 0,612]
BCE + Remoção de Ruído	0,833	0,013	[0,812; 0,853]	0,638	0,116	[0,619; 0,657]
Perda Ordinal	0,851	0,009	[0,833; 0,869]	0,608	0,126	[0,587; 0,628]
Ordinal + Focal (Híbrida)	0,856	0,011	[0,833; 0,876]	0,669	0,011	[0,635; 0,683]

Tabela 2. Impacto da formulação da função de perda no desempenho da EfficientNet-B0

4.4. Comparação entre Arquiteturas EfficientNet

Após a definição da melhor combinação de hiperparâmetros e da função de perda utilizando a EfficientNet-B0, a mesma configuração experimental foi aplicada às variantes EfficientNet-B3 e EfficientNet-B7, que representam modelos de complexidade intermediária e elevada, respectivamente. O objetivo foi avaliar se o refinamento metodológico desenvolvido para o modelo base produziria ganhos adicionais quando empregado em arquiteturas com maior capacidade representacional dentro da mesma família.

Os resultados estão apresentados na Tabela 3. Observa-se que a EfficientNet-B0 apresentou o melhor desempenho tanto no kappa quadrático quanto na acurácia. As arquiteturas mais profundas (B3 e B7) não apresentaram ganho estatisticamente relevante, havendo, inclusive, leve degradação nos valores médios das métricas avaliadas. Tal comportamento pode estar associado ao tamanho da base de dados ou à maior propensão ao

sobreajuste em modelos com maior número de parâmetros. Assim, a EfficientNet-B0 demonstrou ter o melhor equilíbrio entre desempenho preditivo, estabilidade estatística e custo computacional.

Arquitetura	Kappa Quadrático			Acurácia (%)		
	Resultado	Std	CI 95%	Resultado	Std	CI 95%
EfficientNet-B0	0,856	0,011	[0,833; 0,876]	0,669	0,119	[0,635; 0,683]
EfficientNet-B3	0,846	0,010	[0,829; 0,861]	0,659	0,125	[0,554; 0,594]
EfficientNet-B7	0,844	0,011	[0,821; 0,865]	0,602	0,112	[0,578; 0,628]

Tabela 3. Comparação de desempenho entre as variantes da EfficientNet.

No contexto clínico, os modelos demonstraram desempenho globalmente satisfatório, com predominância de erros entre classes adjacentes, comportamento esperado em problemas de classificação ordinal, como o sistema ISUP. Observa-se que as maiores taxas de confusão concentram-se nas classes intermediárias (ISUP 2, ISUP 3 e ISUP 4), conforme evidenciado na Tabela 4, sugerindo que os modelos conseguem, em grande parte, preservar a proximidade semântica entre os graus de agressividade tumoral.

Modelo	Classe Real	Prev. ISUP 0	Prev. ISUP 1	Prev. ISUP 2	Prev. ISUP 3	Prev. ISUP 4	Prev. ISUP 5
B0	ISUP 0	0,857	0,088	0,014	0,021	0,021	0,000
	ISUP 1	0,095	0,693	0,188	0,022	0,003	0,000
	ISUP 2	0,015	0,230	0,485	0,230	0,040	0,000
	ISUP 3	0,027	0,032	0,146	0,492	0,270	0,032
	ISUP 4	0,037	0,016	0,048	0,134	0,652	0,112
	ISUP 5	0,033	0,011	0,016	0,065	0,380	0,495
B3	ISUP 0	0,818	0,152	0,009	0,012	0,007	0,002
	ISUP 1	0,075	0,708	0,200	0,010	0,007	0,000
	ISUP 2	0,015	0,195	0,530	0,210	0,050	0,000
	ISUP 3	0,038	0,043	0,205	0,432	0,216	0,065
	ISUP 4	0,037	0,053	0,059	0,134	0,572	0,144
	ISUP 5	0,049	0,005	0,027	0,076	0,201	0,641
B7	ISUP 0	0,788	0,173	0,023	0,007	0,007	0,002
	ISUP 1	0,140	0,640	0,203	0,018	0,000	0,000
	ISUP 2	0,015	0,215	0,525	0,195	0,050	0,000
	ISUP 3	0,022	0,059	0,178	0,357	0,297	0,086
	ISUP 4	0,043	0,053	0,059	0,241	0,433	0,171
	ISUP 5	0,033	0,022	0,011	0,082	0,266	0,587

Tabela 4. Previsões por Modelo e Classe Real (ISUP)

4.5. Discussão

Com base nos experimentos realizados, a função de perda híbrida demonstrou impacto direto na robustez do treinamento, elevando a acurácia do *baseline* de 0,592 para 0,669 (+7 p.p.) e o κ_{quad} de 0,826 para 0,856 (+3 p.p.), conforme apresentado na Tabela 2.

A análise comparativa com trabalhos anteriores (Tabela 5) evidencia que, embora alguns estudos reportem métricas absolutas elevadas, frequentemente o fazem em cenários simplificados, com validações menos desafiadoras ou com métricas isoladas. Por exemplo, [Xiang et al. 2023] obteve $\kappa = 0,931$ em validação interna, porém 0,801 em validação externa; em contraste, nosso modelo alcança $\kappa = 0,856$ diretamente nos

dados públicos ruidosos do PANDA, indicando maior robustez prática. De forma semelhante, [Afifi et al. 2024] reportou acurácia de 91,80%, mas $\kappa = 0,608$, o que sugere discrepâncias ordinais relevantes.

Diferentemente dessas abordagens, o modelo proposto realiza a graduação completa dos seis níveis ISUP (0–5), incorpora explicitamente a natureza ordinal da doença por meio de uma função de perda sensível à hierarquia e reduz erros extremos, entregando um equilíbrio superior entre desempenho estatístico, coerência clínica e capacidade de generalização.

Trabalho	Banco de Dados	Abordagem / Modelo	Tarefa	Acurácia	Kappa
[Xiang et al. 2023]	PANDA	ResNet50 + GCN	ISUP (6 níveis)	-	0.931 (Int.) / 0.801 (Ext.)
[Alici-Karaca and Akay 2024]	DiagSet	EfficientNet-B4 + ECA	Binária / 4 classes	0,961% / 0,948%	-
[Kosoko et al. 2024]	SICAPv2	VGG19	Score de Gleason	0,780%	-
[Afifi et al. 2024]	PANDA	InceptionResNetV2	Score de Gleason	0,918%	0.608
Abordagem Proposta	PANDA	EfficientNet-B0 + Ordinal Focal Loss	ISUP (6 níveis)	0,669%	0.856

Tabela 5. Comparação do modelo proposto com trabalhos recentes da literatura.

5. Conclusão

Neste estudo, foi desenvolvida uma metodologia para a classificação automática dos graus ISUP em imagens histopatológicas de próstata, considerando desafios relevantes como o desbalanceamento de classes, o ruído nos rótulos e a natureza ordinal da progressão tumoral. A introdução de uma função de perda híbrida, combinando regressão ordinal e perda focal, contribuiu para melhorar o desempenho do modelo ao capturar explicitamente a hierarquia entre os graus de malignidade. Destaca-se que o maior ganho de desempenho foi obtido com a aplicação da perda ordinal, que aplicada em conjunto com a remoção de ruído elevou o índice κ_{quad} em aproximadamente 2,5%, mantendo elevada estabilidade (desvio padrão de 0,009). De forma geral, a abordagem proposta elevou o índice κ_{quad} de 0,826 para 0,857 (ganho de aproximadamente 3%) e a acurácia de 0,592 para 0,669 (ganho de cerca de 7%) em relação ao *baseline*. Na comparação entre arquiteturas da família EfficientNet, observou-se que o aumento da complexidade do modelo não resultou em melhor desempenho, havendo inclusive leve degradação nas variantes mais profundas. Esses resultados indicam que arquiteturas mais complexas requerem ajustes mais refinados de treinamento para alcançar seu potencial máximo. Apesar dos excelentes resultados, a principal limitação do estudo reside no uso de um único banco de dados, ainda que multicêntrico e heterogêneo, o que indica a necessidade de validações futuras em bases de dados externas para comprovar a robustez e a generalização do método.

Como trabalhos futuros, propõe-se investigar arquiteturas mais recentes baseadas em *Transformers*, especialmente *Vision Transformers* (ViT) e modelos híbridos *CNN-Transformer*, que podem capturar melhor dependências globais em imagens histopatológicas bem como técnicas de *ensemble learning* para aumentar a robustez e a capacidade de generalização do modelo. Essas abordagens têm potencial para melhorar o desempenho do sistema, sobretudo na classificação dos graus intermediários do ISUP, contribuindo para ampliar sua aplicabilidade como ferramenta de apoio à decisão diagnóstica em diferentes contextos clínicos.

Referências

- Afifi, A., Alrahmawy, M., and El-Baz, A. (2024). Prostate cancer detection using deep learning models on histopathological image slides: An experimental analysis. *International Journal of Advanced Computer Science and Applications*, 15(1):xxx–xxx.
- Albahri, O. S., Albahri, A. S., Mohammed, K. I., Zaidan, A., Zaidan, B. B., Hashim, M., Salman, O. H., Alaa, M., and Alsalem, M. A. (2022). Expert system research for prostate cancer: A literature review. *Computers in Biology and Medicine*, 145:105487.
- Ali, I., Khan, A., Khan, M., Ahmad, R., and Ullah, I. (2023). Shannon entropy in artificial intelligence and its applications based on information theory. *Entropy*, 25(2):364.
- Alici-Karaca, D. and Akay, B. (2024). An efficient deep learning model for prostate cancer diagnosis. *IEEE Access*, 12:150776–150790.
- Araújo, F. H., Silva, R. R., Medeiros, F. N., Neto, J. F. R., Oliveira, P. H. C., Bianchi, A. G. C., and Ushizima, D. (2021). Active contours for overlapping cervical cell segmentation. *International Journal of Biomedical Engineering and Technology*, 35(1):70–92.
- Baldi, P., Brunak, S., Chauvin, Y., Andersen, C. A. F., and Nielsen, H. (2000). Assessing the accuracy of prediction algorithms for classification: an overview. *Bioinformatics*, 16(5):412–424.
- Bray, F., Laversanne, M., Sung, H., Ferlay, J., Siegel, R. L., Soerjomataram, I., and Jemal, A. (2024). Global cancer statistics 2022: Globocan estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA: A Cancer Journal for Clinicians*, 74(3):229–263.
- Bulten, W., Pinckaers, H., van Boven, H., Vink, R., de Bel, T., van Ginneken, B., van der Laak, J., Hulsbergen-van de Kaa, C., and Litjens, G. (2020). Automated deep-learning system for Gleason grading of prostate cancer using biopsies: a diagnostic study. *The Lancet Oncology*, 21(2):233–241.
- Campanella, G., Hanna, M. G., Geneslaw, L., Mirafior, A., Silva, V. W. K., Busam, K. J., Brogi, E., Reuter, V. E., Klimstra, D. S., and Fuchs, T. J. (2019). Clinical-grade computational pathology using weakly supervised deep learning on whole slide images. *Nature Medicine*, 25(9):1301–1309.
- Chen, X. (2026). A transfer learning-based deep focal multiclass network for psychological emotion recognition in community-correction populations. *Alexandria Engineering Journal*, 135:235–242.
- Cohen, J. (1968). Weighted kappa: Nominal scale agreement with provision for scaled disagreement or partial credit. *Psychological Bulletin*, 70(4):213–220.
- Dina, A. S., Siddique, A., and Manivannan, D. (2023). A deep learning approach for intrusion detection in internet of things using focal loss function. *Internet of Things*, 22:100699.
- Efron, B. (1979). Bootstrap methods: Another look at the jackknife. *The Annals of Statistics*, 7(1):1–26.
- Epstein, J. I., Egevad, L., Amin, M. B., Delahunt, B., Srigley, J. R., and Humphrey, P. A. (2016). The 2014 International Society of Urological Pathology (ISUP) consensus

conference on gleason grading of prostatic carcinoma: Definition of grading patterns and proposal for a new grading system. *The American Journal of Surgical Pathology*, 40(2):244–252.

Kosoko, I., Garg, A., Jain, S., and Hewage, P. (2024). Leveraging deep learning and explainable ai for diagnosis of prostate cancer. In *Proceedings of the International Conference on Applied Artificial Intelligence in Medical Imaging*, Bolton, United Kingdom.

Lin, T.-Y., Goyal, P., Girshick, R., He, K., and Dollár, P. (2017). Focal loss for dense object detection. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 2980–2988.

PANDA Challenge (2020). Prostate cANcer grade assessment challenge. <https://www.kaggle.com/c/prostate-cancer-grade-assessment>. Accessed: 2024-01-01.

Siegel, R. L., Giaquinto, A. N., and Jemal, A. (2024). Cancer statistics, 2024. *CA: A Cancer Journal for Clinicians*, 74(1):12–49.

Xiang, J., Wang, X., Wang, X., Zhang, J., Yang, S., Yang, W., Han, X., and Liu, Y. (2023). Automatic diagnosis and grading of prostate cancer with weakly supervised learning on whole slide images. *Computers in Biology and Medicine*, 152:106340.